

› STATISTIK

Vorlesungsbegleitende Literatur:







AUER, B. & ROTTMANN, H. (2015). Statistik und Ökonometrie für Wirtschaftswissenschaftler. Leipzig: Springer

HÄRDLE, W.K., KLINKE, S., & RÖNZ, B. (2015). Introduction to Statistics. Heidelberg: Springer


KOSFELD, R., ECKEY, H. & TÜRCK, M. (2019). Wahrscheinlichkeitsrechnung und induktive Statistik. Wiesbaden: Springer

MATHAI, A.M. & HAUBOLD, H.J. (2018). Probability and Statistics. De Gruyter: Berlin

(siehe Syllabus und ILIAS-Link "Literatur")



› DESKRIPTIVE STATISTIK



WAS IST DESKRIPTIVE STATISTIK?

- > Ziele Deskriptive Statistik: Beschreibung von Daten (keine induktiven Schlüsse)
- > Deskriptive Statistik: Methoden, um Daten zusammenzufassen und zu visualisieren

Beispiel. Wir haben einen Datensatz mit dem Jahreseinkommen von 12'403 Menschen.

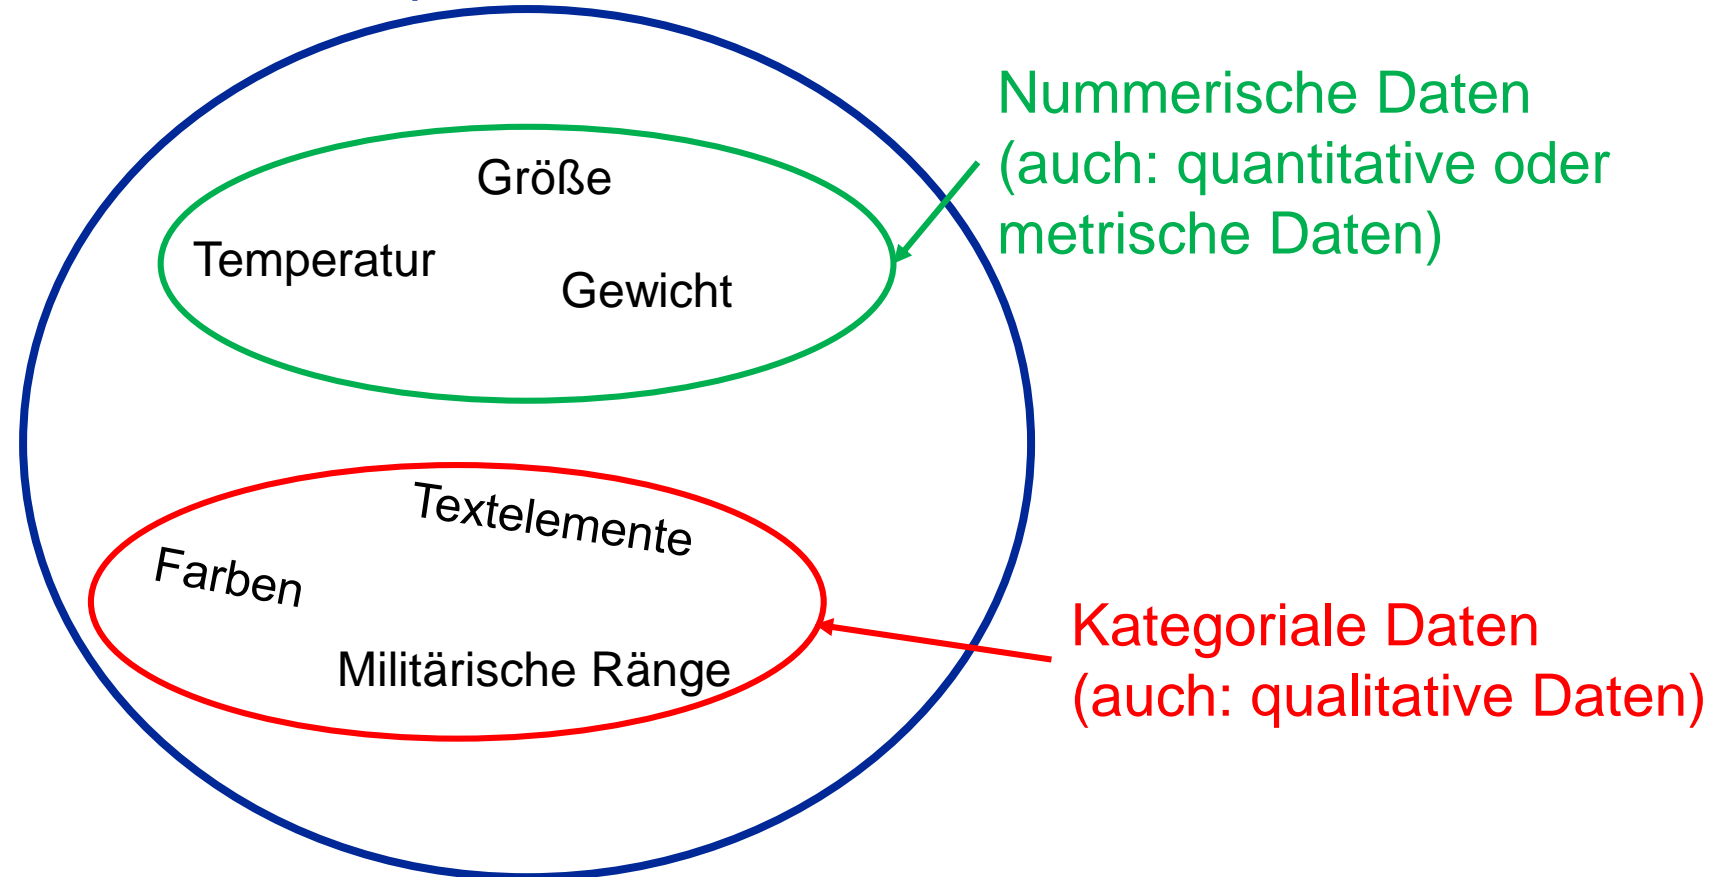
- > Niemand möchte 12'403 Einzeleinträge lesen
- > Stattdessen z.B. mittlere Jahreseinkommen anschauen

› DATEN

WAS SIND DATEN?

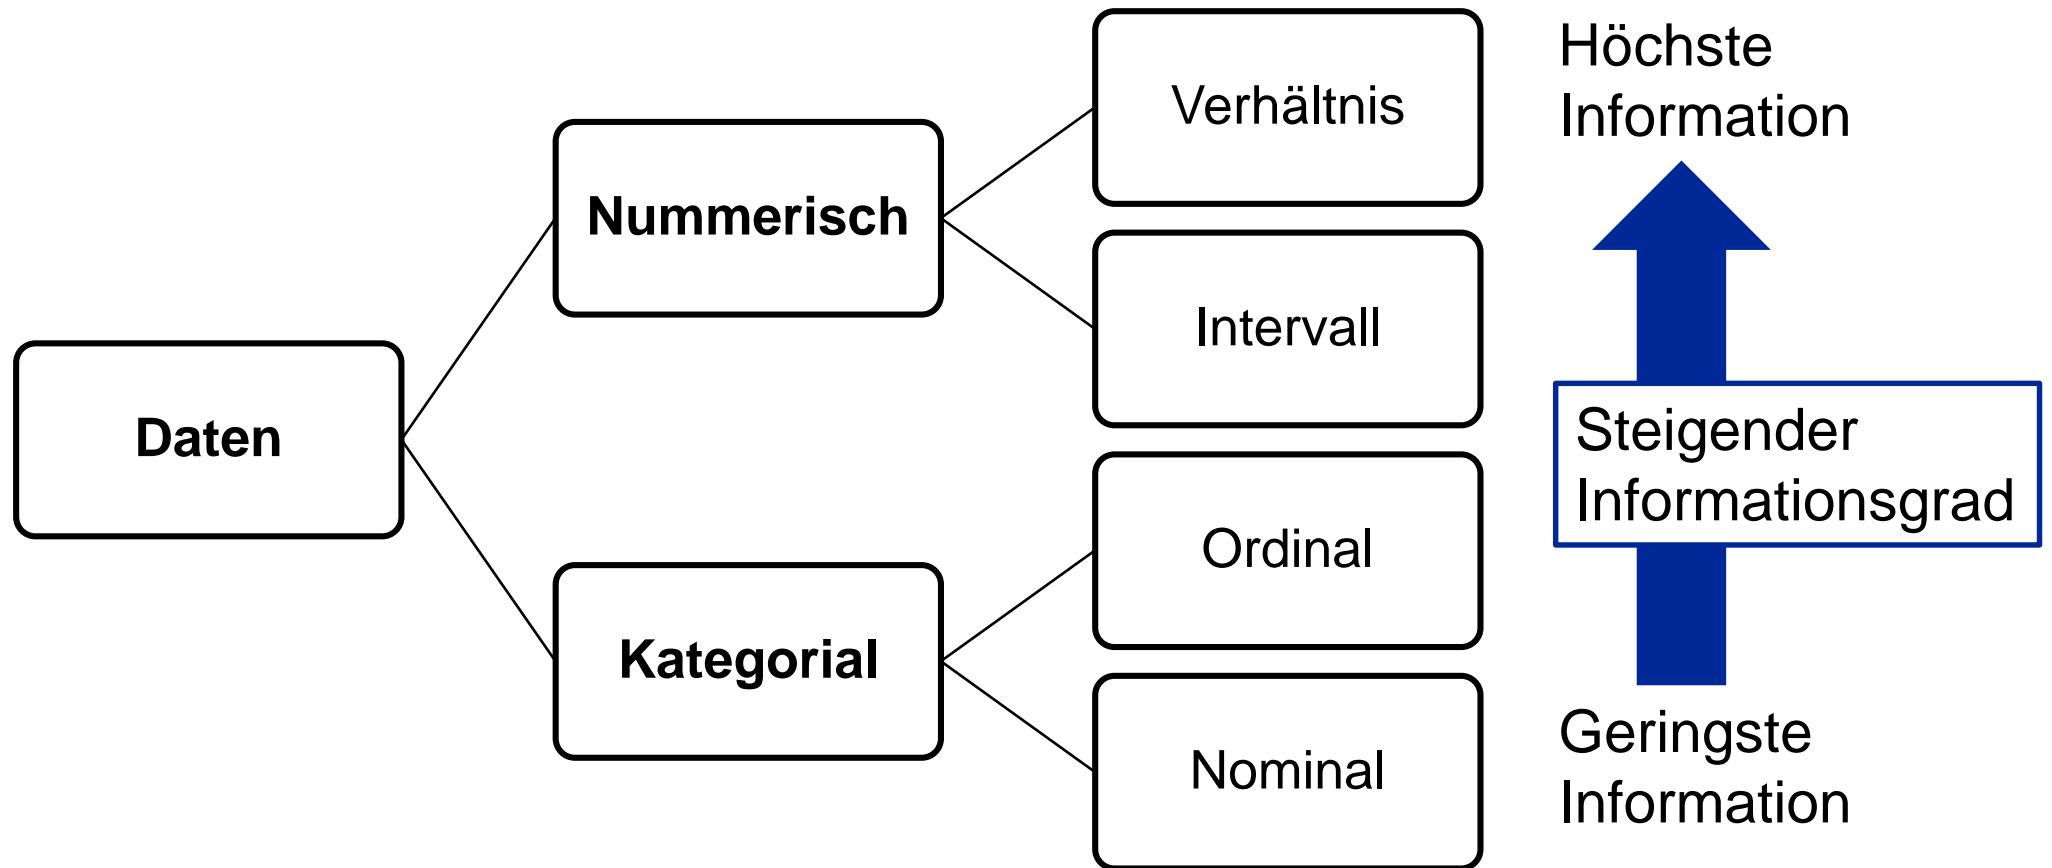
Daten sind Merkmale von Objekten, die durch Beobachtung erhoben werden

Beispiele Daten



	Messniveau	Zulässige Operationen	Definition	Beispiele
Qualitative Daten	Nominal	$=, \neq$	Kategorien ohne Rangordnung	Geschlecht, Farben
	Ordinal	$=, \neq$ \geq, \leq	Kategorien mit Rangordnung	Sterne eines Hotels, Militärische Ränge
Quantitative Daten	Intervall	$=, \neq$ \geq, \leq $+, -$	Nummerische Messungen. Differenzen sind interpretierbar. Kein absoluter Nullpunkt.	Temperatur in °C, IQ-Test
	Verhältnis	$=, \neq$ \geq, \leq $+, -$ \times, \div	Nummerische Messungen. Verhältnisse sind interpretierbar. Absoluter Nullpunkt.	Temperatur in K, Größe

- > Messniveaus haben unterschiedliche Informationsgrade:




Beispiel. Wettrennen.

Erfassung auf Niveau

Teilnehmer	Nominal	Ordinal	Verhältnis
A	> Teilgenommen	> 2. Platz	> 16.2 Sek.
B	> Teilgenommen	> 1. Platz	> 11.3 Sek.
C	> Disqualifiziert	> -	> -
D	> Teilgenommen	> 3. Platz	> 16.9 Sek.



Informativere Messniveaus können in niedrigere konvertiert werden, aber nicht umgekehrt



Beispiel.

Teilnehmer	Nominal	Ordinal	Verhältnis
A	> Teilgenommen	≠ > 2. Platz ←	> 16.2 Sek.
B	> Teilgenommen	≠ > 1. Platz ←	> 11.3 Sek.
C	> Disqualifiziert	≠ > - ←	> -
D	> Teilgenommen	≠ > 3. Platz ←	> 16.9 Sek.

DATEN: MESSNIVEAUS

Daten	Skalenniveau
Körpergröße (182cm, 167cm, ...)	
Geschlecht	
IQ (100, 99, 116, 89,...)	
Prozentsatz korrekter Testantworten	
Platzierung in einem Schönheitswettbewerb	
Reiseziele (New York, Berlin)	
Zustimmungsgrade (stimmte nicht zu, ..., stimme voll zu)	
Jahreszahlen (1640, 1920, 2020,...)	

Skalenniveau
Nominal
Ordinal
Intervall
Verhältnis

DATENARTEN: UNIVARIAT VS. MULTIVARIAT

> **Univariate Daten:** messen ein **einziges** Merkmal

Beispiel. Merkmal = Größe:


Person i	1	2	3	4	5
Height in cm (x_i)	172	175	177	186	191

> **Multivariate Daten:** messen **mehrere** Merkmale

Beispiel. Merkmal = Größe + Gewicht:

Person i	1	2	3	4	5
Height in cm (x_i)	172	175	177	186	191
Weight in kg (y_i)	67	74	72	81	86

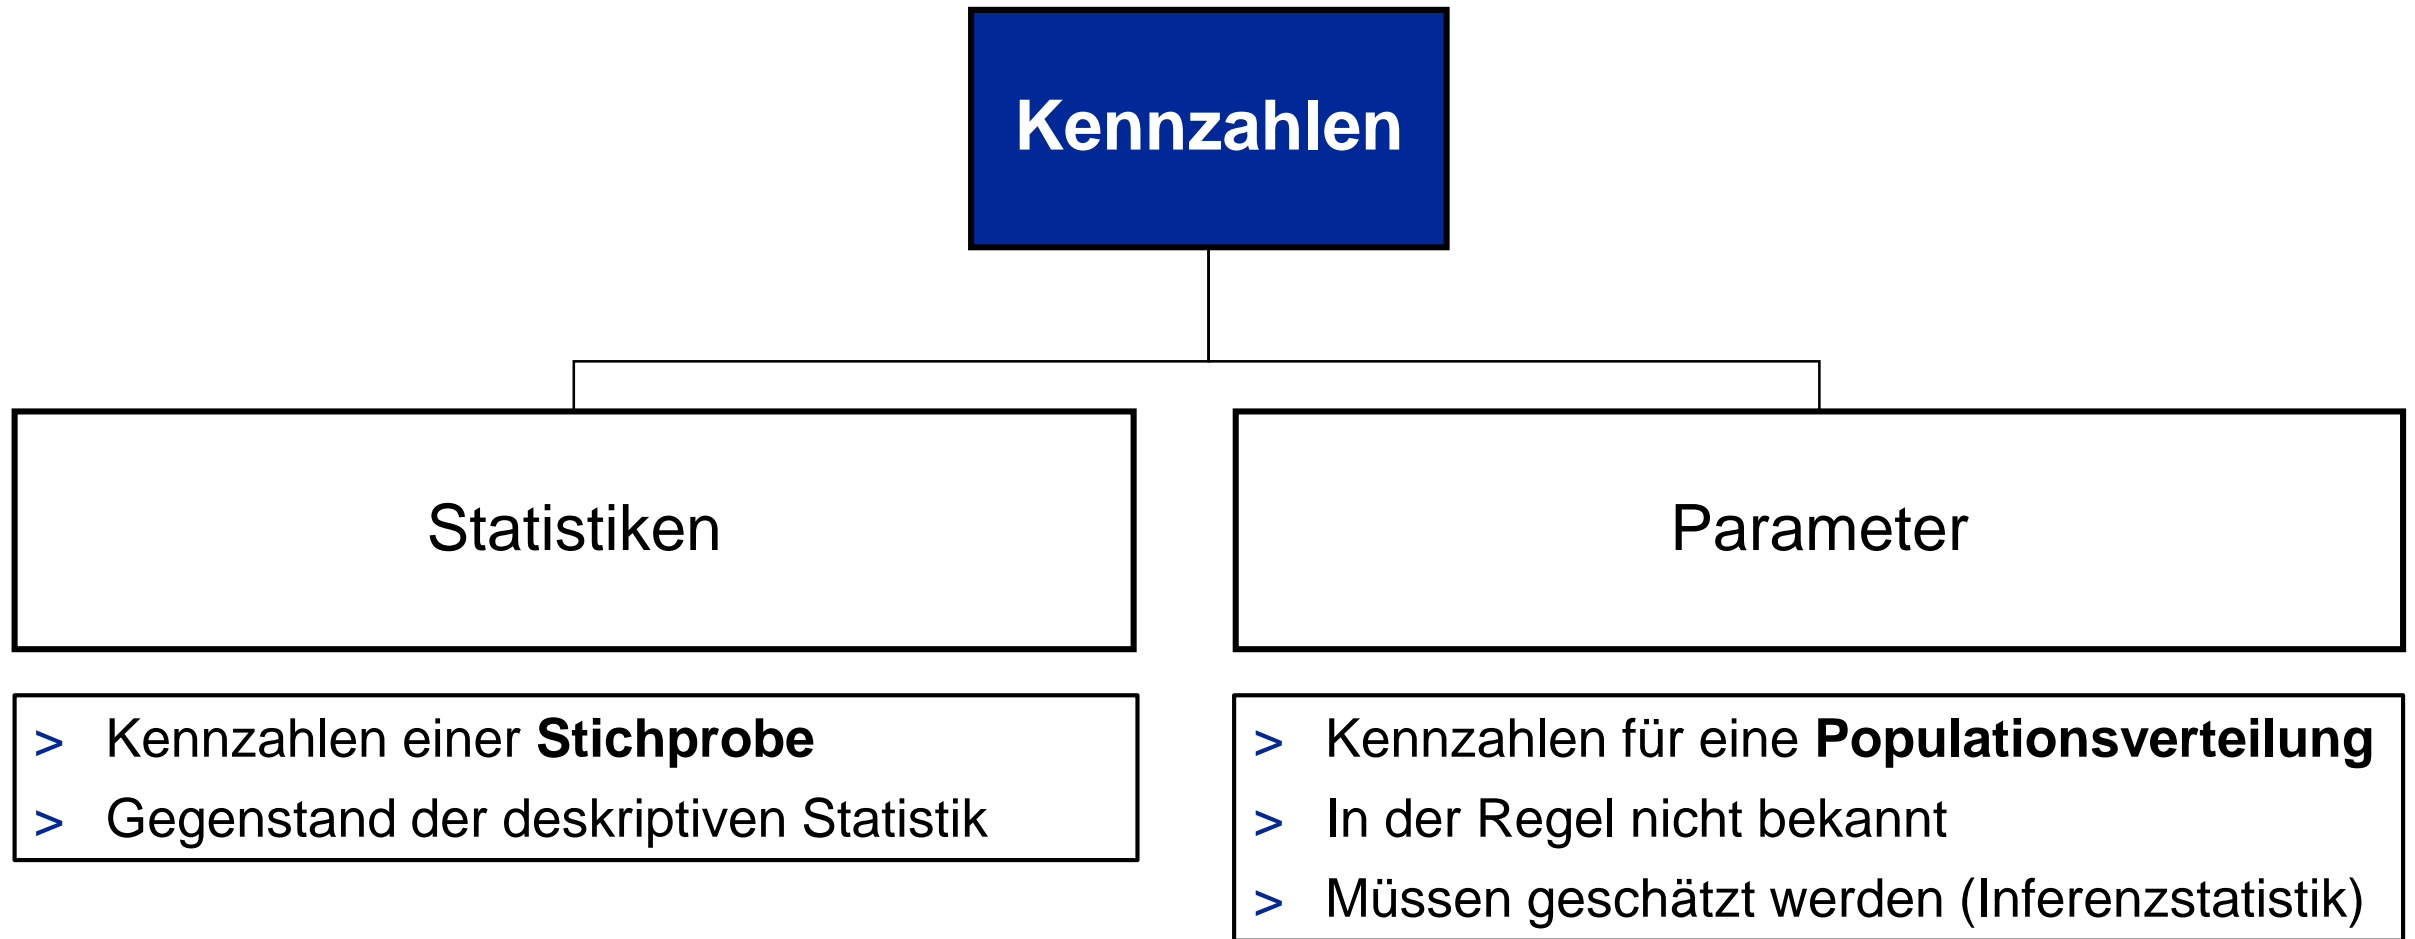
Statistik: Erhebung von Daten über **Zufallsstichproben**:



Zufallsstichprobe (intuitiv):

- > Stichprobe = Teilmenge einer Population (= Menge der Merkmalsträger)
- > Zufall = Jedes Element der Population wird mit gleicher Wahrscheinlichkeit gezogen

› STATISTIKEN UND PARAMETER



STATISTIKEN UND PARAMETER: BEISPIEL

> Verteilung der Körpergröße von Frauen

> Population = Welt

> Stichprobe = Deutschland

Durchschnittsgröße Welt = 160 cm \neq Durchschnittsgröße Deutschland = 165 cm

> Im Gegensatz zu Statistiken sind Parameter in der Regel **unbekannt**

> Die Inferenzstatistik zielt darauf ab Parameter zu **schätzen** (basierend auf Stichproben)

STATISTIKEN UND PARAMETER: ARTEN

Univariat		Multivariat	
Art	Kennzahlen	Art	Kennzahlen
Lagemaße: > Typische Werte einer Verteilung → charakterisieren deren Lage	> Modus / Modalwert > Median > Mittelwert / Erwartungswert	Zusammenhangsmaße: > Messen die Stärke des linearen Zusammenhangs zwischen 2 Merkmalen	> Kovarianz > Korrelationskoeffizient
Streuungsmaße: > Messen Streuung um ein Lagemaß → charakterisieren die Form der Verteilung	> Varianz > Standardabweichung		

AUSBLICK: PARAMETER UND STATISTIKEN DER VORLESUNG

Typ	Name	Notation in Lehrbüchern	
		Parameter	Statistik
Lage	Modus	-	\bar{x}_M
	Median	-	$\bar{x}_{0.5}$
	Mittelwert	μ	\bar{x}
	Anteil	π	\bar{p}
Streuung	Standard- abweichung	σ / SD	s
	Varianz	σ^2 / var	s^2
	Spannweite	-	<i>range</i>
Zusammenh.	Kovarianz	σ_{XY} / cov	s_{xy}
	Korrelationskoeff.	ρ_{XY}	r_{xy}

› UNIVARIATE STATISTIKEN / PARAMETER

LAGEMAßE: TYPISCHE WERTE EINER VERTEILUNG

Modus / Modalwert

Sei (x_1, \dots, x_n) ein Datensatz der Länge n . Der *Modus* \bar{x}_M ist derjenige Wert, der am häufigsten vorkommt (höchste absolute Häufigkeit).

Median

Sei (x_1, \dots, x_n) ein Datensatz der Länge n . Der *Median* $\tilde{x}_{0.5}$ ist der "mittlere" Wert, wenn die Werte der Stichprobe von klein nach groß sortiert wurden.

Mittelwert

Sei (x_1, \dots, x_n) ein Datensatz der Länge n . Der *Mittelwert* ist das arithmetische Mittel:

$$\text{Mittelwert} = \frac{x_1 + \dots + x_n}{n}$$

LAGEMAßE: ERWARTUNGSWERT

Beispiel 1. Wette: Gewinn 2€ mit 70%, Verlust 3 € mit 30%.

> Was würde man „erwarten“, wenn man die sehr (unendlich) oft annimmt?

Beispiel 2. Würfelwurf.

> Welche Durchschnitts-Augenzahl würde man erwarten, bei unendlicher Wiederholung?

Erwartungswert

Der Erwartungswert $E[X]$ eines Merkmals X ist die wahrscheinlichkeitsgewichtete Summe seiner Werte.

- > Der Erwartungswert kann als "wahrer" langfristiger Durchschnittswert gesehen werden

LAGEMAßE: ERWARTUNGSWERT

Beispiel 3. Durchschnittsnoten in Statistik der letzten Jahre:

Jahr	14	15	16	17	18	19	20	21	22	23
Durchschnittsnote	2,3	2,3	2,7	3,3	2,3	2,7	2,7	1,7	3,3	2,3

> Welche Durchschnittsnote würde man dieses Jahr „erwarten“?

Rechenregeln.

1. Der Erwartungswert einer Konstanten ist die Konstante:

$$E[\textit{Konstante}] = \textit{Konstante}$$

Anmerkung. Deshalb: $E[E[X]] = E[X]$



2. Konstante Multiplikatoren können vor den Erwartungswert geschrieben werden:

$$E[\textit{Konstante} \cdot X] = \textit{Konstante} \cdot E[X]$$

3. Der Erwartungswert ist additiv separabel:


$$E[X + Y] = E[X] + E[Y]$$

LAGEMAßE CHARAKTERISIEREN DIE LAGE DER VERTEILUNG




WARUM STREUUNGSMAßE?

Niedrige Streuung um den Mittelwert



Hohe Streuung um den Mittelwert



Beide Verteilungen haben den gleichen Mittelwert (4), aber streuen unterschiedlich

WARUM STREUUNGSMAßE?

> Es gibt 2 Statistik-Kurse (A und B) → Durchschnittsnote in beiden Kursen: 3.0

Class A	
Grade	Abs_Frequency
1	-
1.3	-
1.7	-
2	-
2.3	-
2.7	-
3	40
3.3	-
3.7	-
4	-
5	-
sum	40

Class B	
Grade	Abs_Frequency
1	20
1.3	-
1.7	-
2	-
2.3	-
2.7	-
3	-
3.3	-
3.7	-
4	-
5	20
sum	40

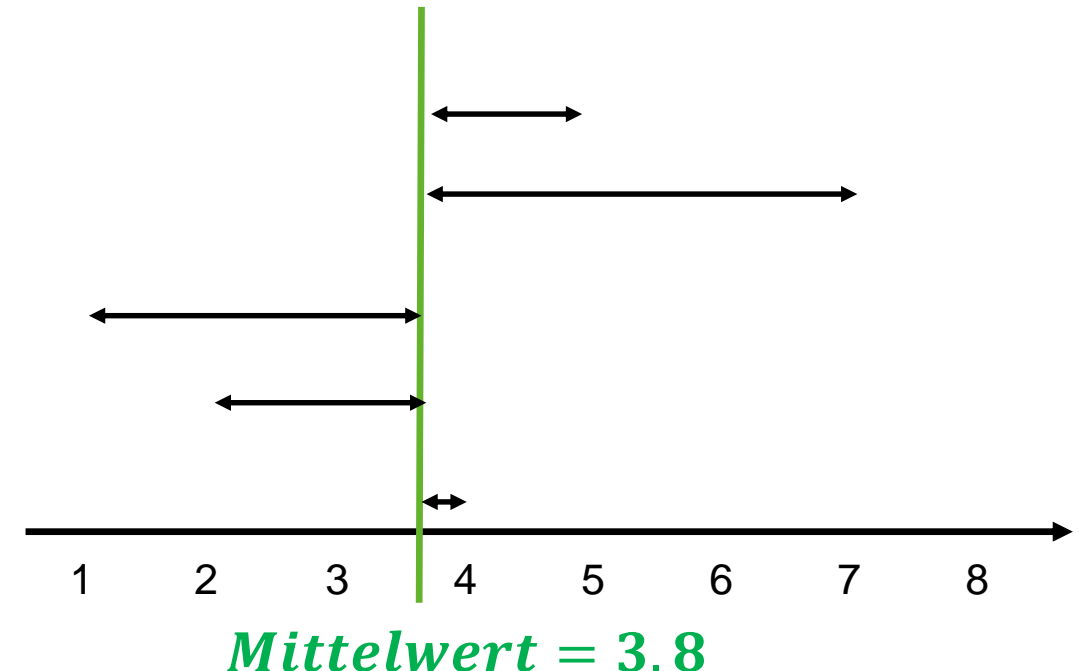
STREUUNGSMAß: MESSEN STREUUNG UM DEN MITTELWERT

Maß für die Streuung der Daten um ihren Mittelwert

> Durchschnitt der Summe der Abweichungen vom Mittelwert?

Beispiel.

	x_i	$x_i - \text{Mittelwert}$
	5	1.2
	7	3.2
	1	-2.8
	2	-1.8
	4	0.2
Summe / n	$\text{Mittelwert} = 19/5$ $= 3.8$	$0/5 = 0$



STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

- > Durchschnitt der Summe der Abweichungen vom Mittelwert ist immer 0
- > Lösung: Durchschnitt der Summe der **quadrierten** Abweichungen vom Mittelwerten

Beispiel.

Beobachtung:	Abweichungen:	Quadrierte Abweichungen:
x_i	$x_i - \text{Mittelwert}$	$(x_i - \text{Mittelwert})^2$
5	1.2	1.44
7	3.2	10.24
1	-2.8	7.84
2	-1.8	3.24
4	0.2	0.04
Summe / n	Mittelw. = 3.8 0	$\frac{(x_1 - \text{Mittelw.})^2 + \dots + (x_5 - \text{Mittelw.})^2}{n} = 4.56$

Varianz

STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

Beispiel. Kalorien von Lebensmitteln.

Lebensmittel	Kalorien (pro 10 Gramm) x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
Pizza Margherita	228	32	1024
Döner	215	19	361
Hamburger	241	45	2025
Spaghetti mit Pesto	181	-15	225
Salat mit Meeresfrüchten	115	-81	6561
Summe	980		10'196
Summe durch Anzahl (n)	$\bar{x} = 196$		$s^2 = 2'039.2$
Einheit	Kalorien		Kalorien²

STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

- > Varianz = 2039.2 Kalorien²
- > Kann nicht mit ursprünglichen Messungen (in Kalorien) in Verbindung gesetzt werden
- > Deshalb: Standardabweichung = positive Quadratwurzel der Varianz
- > Im Beispiel:

$$\text{Standardabweichung} = \sqrt{2039.2} \approx 45$$

- > 45 Kalorien = Durchschnittliche Entfernung der 5 Produkte vom Mittelwert

STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

Varianz

Sei (x_1, \dots, x_n) ein Datensatz der Länge n . Die *Varianz* ist die durchschnittliche quadratische Abweichung vom Mittelwert:

$$\text{Varianz} = \frac{(x_1 - \text{Mittelwert})^2 + \dots + (x_n - \text{Mittelwert})^2}{n}.$$

Standardabweichung

Sei (x_1, \dots, x_n) ein Datensatz der Länge n . Die *Standardabweichung* ist die positive Quadratwurzel der Varianz:

$$\text{Standardabweichung} = \sqrt{\text{Varianz}}$$

STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

Eigenschaften. Die Varianz / Standardabweichung

- > kann nur für numerische / quantitative Daten bestimmt werden
- > ist größer, je stärker die Daten um ihren Mittelwert streuen

VARIANZ: BERECHNUNG MITTELS ERWARTUNGSWERT

Die Varianz ist der Erwartungswert der quadratischen Abweichung vom Mittelwert:

$$\text{Var}(X) = E[(X - \text{Mittelwert})^2]$$

Dies kann wie folgt geschrieben werden:

$$\begin{aligned} & E[(X - \text{Mittelwert})^2] \\ &= E[X^2 - 2 \cdot X \cdot \text{Mittelwert} + \text{Mittelwert}^2] \\ &= E[X^2] - 2 \cdot E[X] \cdot \text{Mittelwert} + E[\text{Mittelwert}^2] \leftarrow \text{Konstante} \\ &= E[X^2] - \text{Mittelwert}^2 \leftarrow E[X] = \text{Mittelwert} \end{aligned} \quad \begin{array}{l} \text{Multiplikatoren} \\ \text{vor den} \\ \text{Erwartungswert} \end{array}$$

VARIANZ: BERECHNUNG MITTELS ERWARTUNGSWERT

Beispiel. Einkommensverteilung

Einkommen x (in 1000€)	$P(x)$	$P(x) \cdot x$	x^2	$P(x) \cdot x^2$
1	0.2	0.2	1	0.2
1.5	0.1	0.15	2.25	0.23
2	0.2	0.4	4	0.8
4	0.4	1.6	16	6.4
6	0.1	0.6	36	3.6
Summe		2.95		11.23

Mittelwert

$$E[X^2] = 11.23$$

$$\text{Varianz} = E[X^2] - \text{Mittelwert}^2 = 11.23 - 2.95^2 = 2.52$$

VARIANZ: VEREINFACHTE BERECHNUNG BEI ANTEILSWERTEN

Beispiel. Geschlechterverteilung:

Person i	1	2	3	4
Geschlecht	weiblich	männlich	weiblich	weiblich
Indikator Weiblich	1	0	1	1

> Hier Varianz = *Anteilswert* · (1 – *Anteilswert*)

$$1^2 = 1 \text{ und } 0^2 = 0$$

→

> Beweis:

$$\text{Varianz}(X)$$

$$= E[X^2] - \text{Anteilswert}^2$$

$$= \text{Anteilswert} - \text{Anteilswert}^2$$

$$= \text{Anteilswert} \cdot (1 - \text{Anteilswert})$$

$$= 0.75 \cdot 0.25 = 0.1875$$

$$E[X^2] = E[X]$$

$$= \text{Mittelwert} = \text{Anteilswert}$$


› MULTIVARIATE STATISTIKEN / PARAMETER

ZUSAMMENHANGSMAßE FÜR BIVARIATE DATEN

Häufig möchte man messen, ob zwei Merkmale eine Beziehung haben

Beispiel. Zusammenhang zwischen Größe und Gewicht.


Person i	1	2	3	4	5
Height in cm (x_i)	172	175	177	186	191
Weight in kg (y_i)	67	74	72	81	86




ZUSAMMENHANGSMAß: KOVARIANZ

Kovarianz: Misst Stärke der linearen Beziehung zwischen 2 Merkmalen X und Y


Positive Kovarianz:
 $X \uparrow \rightarrow Y \uparrow$



Kovarianz nahe 0:
Keine lin. Beziehung



Negative Kovarianz:
 $X \uparrow \rightarrow Y \downarrow$




Kovarianz

Sei $((x_1, y_1) \dots, (x_n, y_n))$ Datensatz mit 2 Merkmalen der Größe n . Die *Kovarianz* der Merkmale ist der Durchschnitt des Produkts Ihrer Abweichungen vom Mittelwert:



$$\text{cov}(X, Y) = \frac{(x_1 - \text{Mwert}_X) \cdot (y_1 - \text{Mwert}_Y) + \dots + (x_n - \text{Mwert}_X) \cdot (y_n - \text{Mwert}_Y)}{n}.$$

ZUSAMMENHANGSMAß: KOVARIANZ

Beispiel (Fortsetzung). Beziehung zw. Größe und Gewicht.





ZUSAMMENHANGSMAß: KOVARIANZ



Gewicht und GröÙer der **ersten 3 Personen** liegen **unter dem Durchschnitt**


ZUSAMMENHANGSMAß: KOVARIANZ




Gewicht und Größe der letzten **beiden Personen** liegen **über dem Durchschnitt**

ZUSAMMENHANGSMAß: KOVARIANZ

Berechnung.




×




=

Produkt Abweichungen: $(x_i - \bar{x}) \cdot (y_i - \bar{y})$	
	72
	10
	12
	30
	110
Summe/ n	Kovarianz $s_{height,weight}$: $234/5 = 46.8$



×



=

ZUSAMMENHANGSMAß: KOVARIANZ

Ausführliche Berechnung.

	Beobachtung: height x_i (in cm)	Abweichungen: $x_i - \bar{x}$	Beobachtung: weight y_i (in kg)	Abweichungen: $y_i - \bar{y}$	Produkt Abweichungen: $(x_i - \bar{x}) \cdot (y_i - \bar{y})$
	172	-8	67	-9	72
	175	-5	74	-2	10
	177	-3	72	-4	12
	186	6	81	5	30
	191	11	86	10	110
Summe / n	$Mittelwert_x$ = 180		$Mittelwert_y$ = 76		$Kovarianz = 46.8$

ZUSAMMENHANGSMAß: KOVARIANZ

Die Kovarianz hängt von der Einheit der Merkmale ab.

Beispiel.

	Beobachtung: height x_i (m statt cm)	Abweichungen: $x_i - \bar{x}$	Beobachtung: weight y_i (in kg)	Abweichungen: $y_i - \bar{y}$	Produkt Abweichungen: $(x_i - \bar{x}) \cdot (y_i - \bar{y})$
	1.72	-0.08	67	-9	0.72
	1.75	-0.05	74	-2	0.1
	1.77	-0.03	72	-4	0.12
	1.86	0.06	81	5	0.3
	1.91	0.11	86	10	1.1
Summe / n	$Mittelwert_x$ = 1.8		$Mittelwert_y$ = 76		$Kovarianz = 0.468$ (vorher: 46.8)

ZUSAMMENHANGSMAß: KORRELATIONSKOEFFIZIENT

- > Wir möchten ein normiertes Maß, das nicht von der Einheit abhängt
- > Korrelationskoeffizient = Normierte Kovarianz
- > Koeffizient = Kovarianz geteilt durch das Produkt der Standardabweichungen


Korrelationskoeffizient

Sei $((x_1, y_1) \dots, (x_n, y_n))$ Datensatz mit 2 Merkmalen der Größe n . Der *Korrelationskoeffizient* ist die Kovarianz geteilt durch das Produkt der Standardabweichungen:


$$\text{Korrelationskoeffizient} = \frac{\text{Kovarianz } x \text{ und } y}{\text{Standardabweichung } x \cdot \text{Standardabweichung } y}.$$

ZUSAMMENHANGSMAß: KORRELATIONSKOEFFIZIENT


$r_{x,y} = 1$
perfekt positiv linear



$r_{x,y} = 0$
nicht linear



$r_{x,y} = -1$
perfekt negativ linear



ZUSAMMENHANGSMAß: KORRELATIONSKOEFFIZIENT

Beispiel.

	height x_i (in cm)	height x_i (in m)	weight y_i (in kg)		
	172	1.72	67		
	175	1.75	74		
	177	1.77	72		
	186	1.86	81		
	191	1.91	86		
Standard- abweichung	7.139	0.071	6.723	height in cm vs weight	height in m vs weight
Kovarianz				46.8	0.468
Korrelations- koeffizienten				$\frac{46.8}{7.139 \times 6.723} = 0.975$	$\frac{0.468}{0.071 \times 6.723} = 0.975$

ZUSAMMENHANGSMAßE: KOVARIANZ UND KORRELATIONSKOEFFIZIENT

Eigenschaften. Der Korrelationskoeffizient / Die Kovarianz

- > kann nur für numerische / quantitative Daten bestimmt werden
- > Kovarianz nimmt Werte zwischen $-\infty$ und ∞ an
- > Korrelationskoeffizient nimmt Werte zwischen -1 und +1 an
- > Kovarianz hängt von der Einheit der Messungen ab, Korrelationskoeffizient nicht
- > Je negativer (positiver), desto stärker ist der negative (positive) lineare Zusammenhang

› STATISTIKEN UND MESSNIVEAUS

STATISTIKEN UND ERFORDERLICHE MESSNIVEAUS

		kann berechnet werden für		
Art	Statistik	Nummerische Daten	Kategoriale Daten	
			Ordinal	Nominal
Lagemaß	Modalwert	✓	✓	✓
	Median	✓	✓	✗
	Mittelwert	✓	✗	✗
Streuungsmaß	Alle	✓	✗	✗
Zusammenhang	Alle	✓	✗	✗



› S.2 WAHRSCHEINLICH- KEITSTHEORIE

› ZUFALLSEXPERIMENT UND WAHRSCHEINLICHKEIT

In Alltag sagen wir Sätze wie:

- > Ich bin sicher, dass Bayern München morgen gewinnt
- > Wahrscheinlich werde ich Statistik bestehen
- > Möglicherweise wird es morgen regnen



→ Ausdruck unterschiedlicher Grade von Unsicherheit über künftige Ereignisse

- > Wahrscheinlichkeiten formalisieren dieses Konzept

- > Wahrscheinlichkeit = Maß zwischen 0 und 1, das Unsicherheit repräsentiert
- > Je höher die Wahrscheinlichkeit eines Ereignisses, desto eher wird es eintreten



Notation. Die Wahrscheinlichkeit eines Ereignisses E bezeichnen wir mit $P(E)$

- > Ein Ereignis E mit $P(E) = 0$ heißt *unmöglich*
- > Ein Ereignis E mit $P(E) = 1$ heißt *sicher*

Ein *Zufallsexperiment* ist ein Vorgang der

- > unter identischen Bedingungen wiederholt werden kann und
- > dessen mögliche Ergebnisse im Vorhinein bekannt und unsicher sind

Stichprobenraum

Die Menge aller möglicher Ergebnisse eines Zufallsexperiments heißt *Stichprobenraum* S .

Beispiel. Würfelwurf. Stichprobenraum:

$$S = \{ \square, \square, \square, \square, \square, \square \}$$



Mehrstufiges Zufallsexperiment = fixierten Anzahl von Wiederholungen eines Experiments.

- > Mehrstufige Experimente haben größere Stichprobenräume

Beispiel. Münzwurf.



- > Stichprobenraum beim einfachen Münzwurf:

$$\text{Stichprobenraum} = \{H, T\},$$

wobei H = Kopf, T = Zahl

- > Stichprobenraum beim zweifachen Münzwurf (mehrstufiges Experiment):

$$\text{Stichprobenraum} = \{HH, HT, TH, TT\},$$

wobei HT = Kopf im ersten Wurf, Zahl im zweiten Wurf usw.

Mehrstufige Zufallsexperimente können in Baumdiagrammen dargestellt werden


Beispiel. Zweimaliger Münzwurf.

> Produktregel:

$$P(HH) = P(H) \times P(H) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

> Summenregel:

$$P(\{TH, TT\}) = P(TH) + P(TT) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$



Ereignis E

Ein *Ereignis* E ist eine Menge möglicher Ergebnisse eines Zufallsexperiments.

> Ein Ereignis ist also eine Teilmenge des Stichprobenraums: $E \subseteq S$

Beispiel. Würfelwurf.



> Ereignis $E =$ Würfelwurf: \square oder \boxdot (Kurz: $E = \{ \square, \boxdot \}$)

Besondere Ereignisse

> Einzelne Ergebnisse des Stichprobenraums $s \in S$ heißen *Elementarereignisse*

Beispiel. Würfelwurf. $s = \text{Wurf } \square$ (Kurz: $s = \{\square\}$)

> Der Stichprobenraum selbst ist ein Ereignis ("irgendetwas passiert"): $E = S$

> Die leere Menge \emptyset ist ein Ereignis ("nichts passiert"): $E = \emptyset$

Anmerkung. \emptyset ist eine Menge (die nichts enthält) und keine Zahl! $\emptyset \neq 0$

Linda ist 31 Jahre alt, Single, offen und sehr intelligent. Sie hat Philosophie studiert. Als Studentin hat sie sich intensive mit Diskriminierung und sozialer Gerechtigkeit beschäftigt sowie an Anti-Atomkraft-Demonstrationen teilgenommen.

Was ist wahrscheinlicher?


1. Linda ist eine Bankangestellte.
2. Linda ist eine Bankangestellte und aktive Feministin.

OPERATIONEN MIT EREIGNISSEN:

SCHNITT \cap

- > Ereignis E = Bankangestellte
- > Ereignis F = Aktive Feministin

Schnitt: $E \cap F$ = Bankangestellte **UND** aktive Feministin



Wahrscheinlichkeit Ereignis
= Fläche Ereignis / Fläche von S

- > Fläche von E ist größer als die Fläche von $E \cap F \rightarrow P(E) > P(E \cap F)$

OPERATIONEN MIT EREIGNISSEN:

SCHNITT \cap

Weiteres Beispiel. Würfelwurf



> Ereignis E = \square oder \blacksquare oder \boxtimes oder \boxdot

> Ereignis F = \square oder \boxtimes oder \boxdot

Wahrscheinlichkeiten?

> $P(E) = \frac{4}{6} = 2/3$

> $P(F) = \frac{3}{6} = 1/2$

Schnitt?

> Ereignis $E \cap F$ = \square oder \boxtimes

Gemeinsame Wahrscheinlichkeit?

> $P(E \cap F) = \frac{2}{6} = 1/3 < P(E) = 2/3$

Anmerkung. Zwei Ereignisse heißen *disjunkt* wenn ihr Schnitt leer ist ($E \cap F = \emptyset$).

Linda ist 31 Jahre alt, Single, offen und sehr intelligent. Sie hat Philosophie studiert. Als Studentin hat sie sich intensive mit Diskriminierung und sozialer Gerechtigkeit beschäftigt sowie an Anti-Atomkraft-Demonstrationen teilgenommen.


Was ist wahrscheinlicher?

1. Linda ist eine Bankangestellte.
2. Linda ist eine Bankangestellte oder aktive Feministin.

OPERATIONEN MIT EREIGNISSEN: VEREINIGUNG \cup

- > Ereignis E = Bankangestellte
- > Ereignis F = Aktive Feministin

Vereinigung: $E \cup F$ = Bankangestellte *ODER/UND* aktive Feministin



Wahrscheinlichkeit Ereignis
= Fläche Ereignis / Fläche von S

- > Fläche von E ist kleiner als die Fläche von $E \cup F \rightarrow P(E) < P(E \cup F)$

OPERATIONEN MIT EREIGNISSEN: VEREINIGUNG \cup

Weiteres Beispiel. Würfelwurf



> Ereignis $E = \square$ oder \square oder \square oder \square

> Ereignis $F = \square$ oder \square oder \square

Wahrscheinlichkeiten?

> $P(E) = \frac{4}{6} = 2/3$

> $P(F) = \frac{3}{6} = 1/2$

Vereinigung?

Vereinigungswahrscheinlichkeit?


> Ereignis $E \cup F = \square$ oder \square oder \square oder \square oder \square

> $P(E \cup F) = 5/6 > P(E) = 2/3$

OPERATIONEN MIT EREIGNISSEN: KOMPLEMENTÄREEREIGNIS E^c

> Ereignis E = Bankangestellte

Komplement: E^c = *keine* Bankangestellte



Weiteres Beispiel. Münzwurf.




> Ereignis E = \square oder \square oder \square oder \square

> Komplementärereignis = E^c = \square oder \square

WAS SIND WAHRSCHEINLICHKEITEN?

Andrey Kolmogorov (1903 – 1987)

> hat Wahrscheinlichkeiten anhand von mathematischen Eigenschaften (Axiome) definiert



WAS SIND WAHRSCHEINLICHKEITEN?

Wahrscheinlichkeitsaxiome (Kolmogorov, 1928):

(A1) **Nichtnegativität.** Die Wahrscheinlichkeit jedes Ereignisses E ist größer oder gleich 0:

$$P(E) \geq 0.$$

(A2) **Normalisierung.** Irgendetwas muss passieren: Der Stichprobenraum S ist sicher:

$$P(S) = 1.$$

(A3) **Additivität.** Die Wahrscheinlichkeit von disjunkten Ereignissen E, F ist:

$$P(E \cup F) = P(E) + P(F).$$

Erinnerung: Zwei Ereignisse sind disjunkt, wenn $E \cap F = \emptyset$

WAS FOLGT AUS DEN WAHRSCHEINLICHKEITSAXIOMEN?

- > Irgendetwas muss passieren → Wahrscheinlichkeit, dass nichts passiert ist 0:

$$P(\emptyset) = 0$$

- > Die Wahrscheinlichkeit jedes Ereignisses liegt zwischen 0 und 1:

$$0 \leq P(E) \leq 1$$

- > "Kleinere" Ereignisse haben kleinere Wahrscheinlichkeiten:

$$\textit{Wenn } E \textit{ Teilmenge von } F \textit{ ist, dann } P(E) \leq P(F)$$

WAS FOLGT AUS DEN WAHRSCHEINLICHKEITSAXIOMEN?

- > Die Vereinigungswahrscheinlichkeit von zwei Ereignissen E und F ist:

$$P(E \cup F) = P(E) + P(F) - P(E \cap F)$$

Beispiel. $E = \{\square, \square, \boxtimes\}$ und $F = \{\square, \square, \boxtimes, \boxplus\}$:

- > Wahrscheinlichkeiten? $P(E) = 1/2$ und $P(F) = 2/3$
- > Schnitt? $E \cap F = \{\square, \boxtimes\}$
- > Gemeinsame Wahrscheinlichkeit? $P(E \cap F) = 1/3$
- > Vereinigungswahrscheinlichkeit: $P(E \cup F) = P(E) + P(F) - P(E \cap F) = \frac{1}{2} + \frac{2}{3} - \frac{1}{3} = \frac{5}{6}$

Eine *Partition* des Stichprobenraums S ist eine Menge von Ereignissen,

- > die **paarweise disjunkt** sind und
- > deren **Vereinigung der Stichprobenraum** ist

Beispiele. Würfelwurf. *Stichprobenraum* $= \{\square, \square, \square, \square, \square, \square\}$. Partitionen:

- > $E_1 = \{\square, \square, \square\}$ und $E_2 = \{\square, \square, \square\}$
- > $E_1 = \{\square, \square\}$ und $E_2 = \{\square, \square, \square, \square\}$
- > Weitere?

WAS FOLGT AUS DEN WAHRSCHEINLICHKEITSAXIOMEN?

- > Die Summe der Wahrscheinlichkeiten jeder Partition ist 1:

$$P(E_1) + \dots + P(E_k) = 1$$

für jede Partition $\{E_1, \dots, E_k\}$ von S .

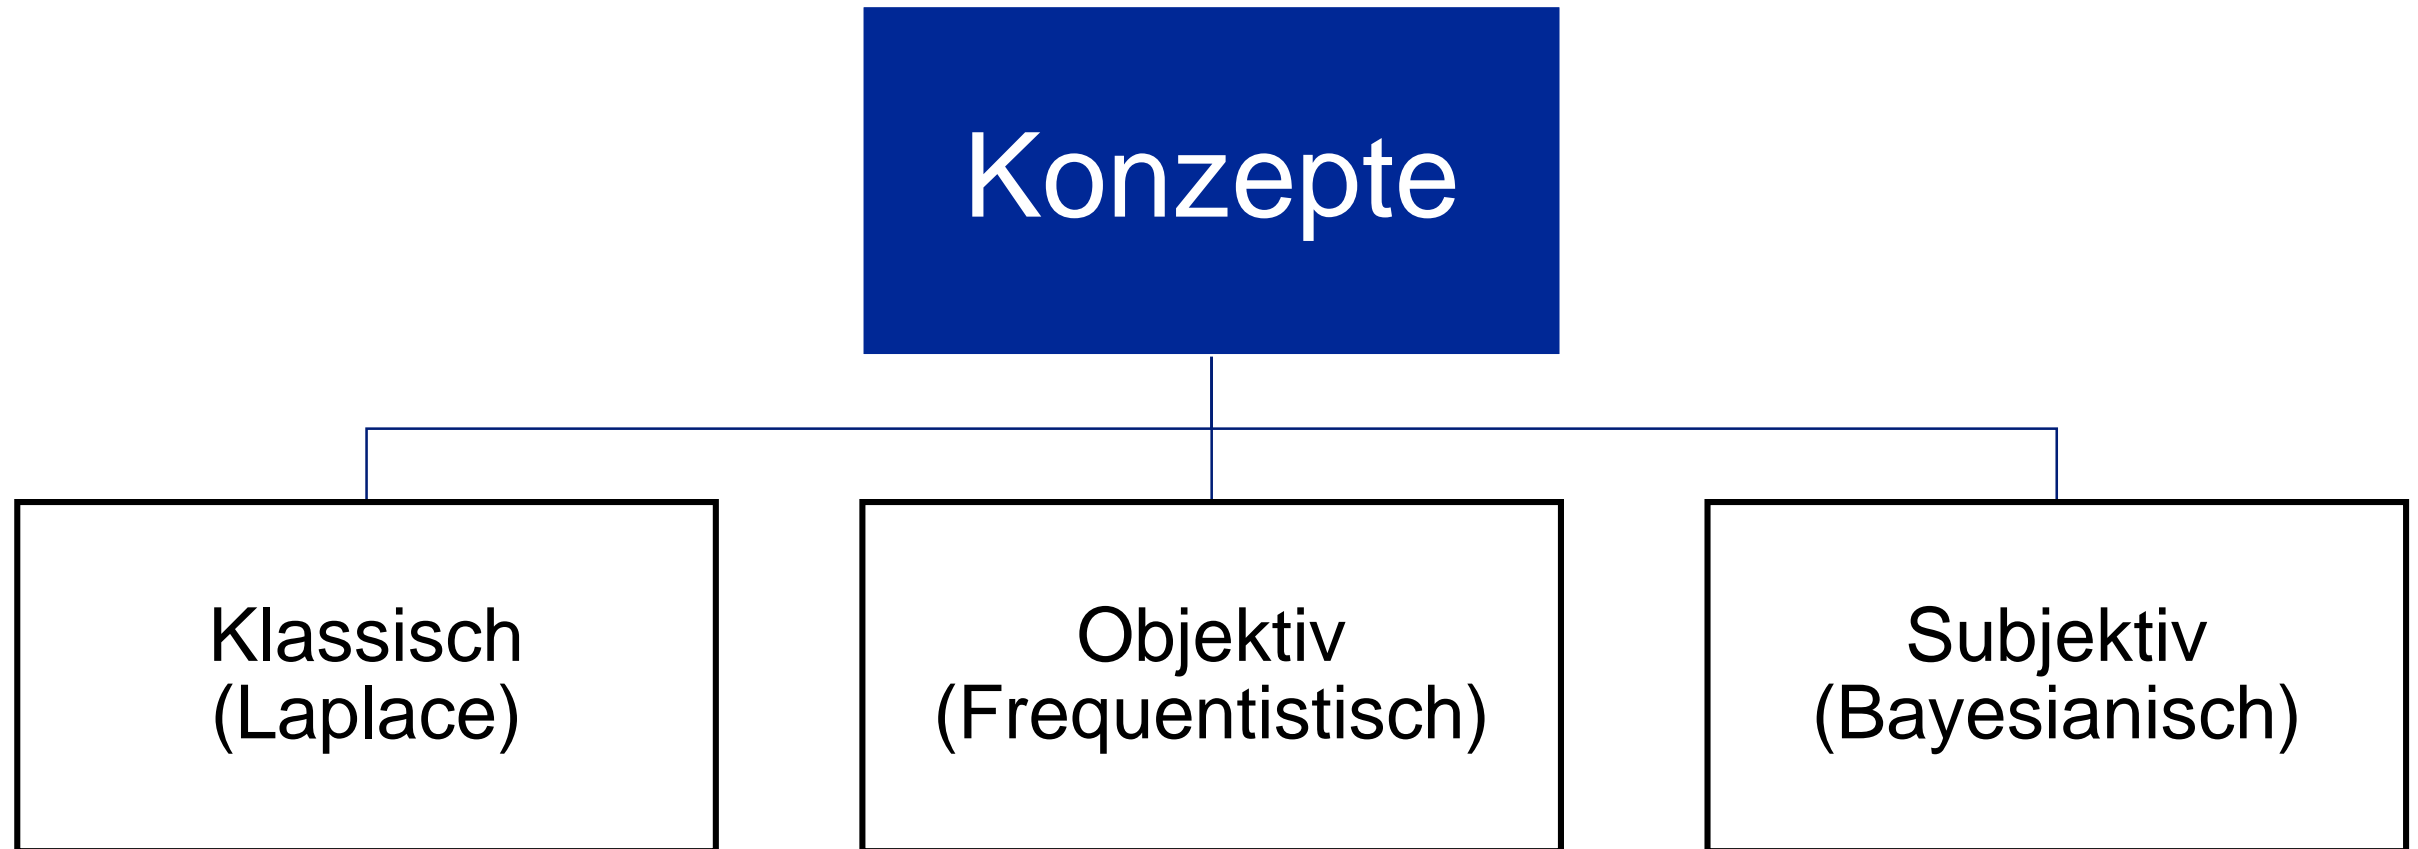
Beispiele (Fortsetzung).

- > $E_1 = \{\square, \square, \square\}$ und $E_2 = \{\square, \square, \square\} \rightarrow P(E_1) = P(E_2) = 1/2 \rightarrow \text{Summe} = 1$
- > $E_1 = \{\square, \square\}$ und $E_2 = \{\square, \square, \square, \square\} \rightarrow P(E_1) = 1/3$ and $P(E_2) = 2/3 \rightarrow \text{Summe} = 1$

Anmerkung. Die einfachste Partition ist ein Ereignis E und dessen Komplement E^c . Also:


$$P(E) + P(E^c) = 1$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN?



WOHER KOMMEN WAHRSCHEINLICHKEITEN? KLASSISCHER ANSATZ

Pierre-Simon Laplace (1749 – 1827)



Hypothese: Prinzip des unzureichenden Grundes

- > Reduktion Ereignisse auf gleichwahrscheinliche symmetrische Fälle
- > Prinzip des unzureichenden Grundes: Kein Grund für andere Wahrscheinlichkeit
- > Wahrscheinlichkeit Ereignisses E = Verhältnis günstiger Fälle (E tritt ein) zur Gesamtzahl

$$P(E) = \frac{\text{Anzahl günstige Fälle für } E}{\text{Gesamtzahl Fälle}}$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN?

KLASSISCHER ANSATZ

Beispiel. Klassischer Ansatz: Würfelwurf.

> Wahrscheinlichkeit des Ereignisses $E = \{\square, \blacksquare\}$ bestimmen (Augenzahl: 2 oder 4)?

> Gesamtanzahl an Fällen?

6 ($\square, \square, \square, \blacksquare, \blacksquare, \blacksquare$)

> Fälle, die für E günstig sind?

2 (\square, \blacksquare)



> Wahrscheinlichkeit:

$$P(E) = P(\{\square, \blacksquare\}) = \frac{2}{6} \approx 33\%$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? FREQUENTISTISCHER ANSATZ

Richard von Mises, Egon Pearson, John Venn,...

Hypothese: Relative Häufigkeiten & Gesetz der großen Zahl

> Häufige Wiederholung Zufallsexperiment:

Relative Häufigkeiten → "Wahre" Wahrscheinlichkeiten

> Die Wahrscheinlichkeit eines Ereignisses E kann wie folgt geschätzt werden:

$$P(E) = \frac{\text{Anzahl Versuche bei denen } E \text{ eingetreten ist}}{\text{Gesamtanzahl Versuche}}$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN?

FREQUENTISTISCHER ANSATZ

Beispiel. Frequentistischer Ansatz: Würfelwurf.

- > Wir möchten die Wahrscheinlichkeit des Ereignisses $E = \{\square, \blacksquare\}$ bestimmen (Augenzahl: 2 oder 4)
- > Der Würfel wird 600'000 Mal geworfen
- > Eine 2 oder 4 wurde 197'123 geworfen
- > Wahrscheinlichkeit:



$$P(E) = P(\{\square, \blacksquare\}) = \frac{197'123}{600'000} \approx 33\%$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Thomas Bayes (1701 – 1761)


Hypothese: Subjektives Urteil

- > Wahrscheinlichkeiten sind subjektive Einschätzungen über den Grad der Gewissheit mit welchem Ereignisse eintreten
- > Subjektive Wahrscheinlichkeitsurteile basieren auf individuellem Vorwissen



WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Bayesianischer Ansatz. Unterscheidung zwischen:



> Bedingte Wahrscheinlichkeit $P(E | F)$: W'keit von E nachdem F beobachtet wurde

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel. Bayesianischer Ansatz: Würfelwurf: $E = \{\square, \blacksquare\}$ und $F = \{\square\}$.

- > Wahrscheinlichkeiten von E und F ?
- > Wahrscheinlichkeit von E unter der Bedingung, dass F eingetreten ist?
- > Wahrscheinlichkeit von F unter der Bedingung, dass E eingetreten ist?



WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel. Bayesianischer Ansatz: Würfelwurf: $E = \{\square, \blacksquare\}$ und $F = \{\square\}$.

- > Wahrscheinlichkeiten von E und F ?

$$P(E) = 1/3 \text{ und } P(F) = 1/6$$

- > Wahrscheinlichkeit von E unter der Bedingung, dass F eingetreten ist?

$$P(E \mid F) = 1$$

- > Wahrscheinlichkeit von F unter der Bedingung, dass E eingetreten ist?

$$P(F \mid E) = 1/2$$



WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Bayes-Theorem und totale Wahrscheinlichkeit.

- > Das zentrale Konzept des Bayesianischen Ansatzes ist das Bayes-Theorem
- > Bayes-Theorem: Anpassung A-priori Wahrscheinlichkeiten im Lichte neuer Information
- > Theorem beschreibt also den Übergang von A-priori zu A-posteriori Wahrscheinlichkeiten
- > Anwendung Bayes-Theorem erfordert häufig den Satz der totalen Wahrscheinlichkeit

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel aus der Einführung. Erinnerung

- > Texas: 38% fahren einen SUV, 57% wählen die Republikaner
- > Umfrage unter SUV-Fahrern: 78% sind Republikaner

Wir müssen folgende Wahrscheinlichkeiten unterscheiden:

- > Bedingte W'keit Republikaner gegeben man ist SUV-Fahrer:

$$P(\text{Republikaner} \mid \text{SUV}) = 78\% \quad \text{Das misst die Studie}$$

- > Bedingte W'keit SUV-Fahrer gegeben man ist Republikaner:

$$P(\text{SUV} \mid \text{Republikaner}) = ? \quad \text{Das wollte die Studie messen}$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel aus der Einführung (Fortsetzung). **Bayes-Theorem.**

Bayes-Theorem

Die bedingte Wahrscheinlichkeit von Ereignis E nachdem F beobachtet wurde ist:

$$P(F | E) = \frac{P(E | F) \cdot P(F)}{P(E)} = \frac{P(E \cap F)}{P(E)}.$$

> Wir können nun dieses Theorem anwenden, um den Machern der Studie zu helfen:

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel aus der Einführung (Fortsetzung). **Bayes-Theorem.**

Bayes-Theorem

Die bedingte Wahrscheinlichkeit von Ereignis E nachdem F beobachtet wurde ist:

$$P(F | E) = \frac{P(E | F) \cdot P(F)}{P(E)} = \frac{P(E \cap F)}{P(E)}.$$

> Wir können nun dieses Theorem anwenden, um den Machern der Studie zu helfen:

$$\begin{aligned} P(SUV | Republikaner) &= \frac{P(\text{Republikaner} | SUV) \cdot P(SUV)}{P(\text{Republikaner})} \\ &= \frac{78\% \cdot 38\%}{57\%} = \mathbf{52\%} \end{aligned}$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Betrachten Sie einen Corona-Test der 90% sensitiv ist und 80% spezifisch.




- > 90% sensitiv: 90% der Leute, die Corona haben, erhalten ein positives Testresultat
- > 80% spezifisch: 80% der Leute, die gesund sind, erhalten ein negatives Testresultat
- > Außerdem hat ca. 5% der Bevölkerung Corona

Frage: Wahrscheinlichkeit, dass man Corona hat bei positivem Testresultat?

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel (Fortsetzung). Baumdiagramm



WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel (Fortsetzung).

Wir müssen folgende Wahrscheinlichkeiten unterscheiden:

- > Wahrscheinlichkeit einer Corona-Infektion (C):

$$P(C) = 5\%$$

- > Bedingte Wahrscheinlichkeit eines positiven Tests (+) gegeben man hat Corona (C):

$$P(+ | C) = 90\%$$

- > Bedingte Wahrscheinlichkeit einer Corona-Infektion (C) gegeben ein positiver Test (+):

$$P(C | +) = ? \quad \text{Diese möchten wir wissen}$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel (Fortsetzung). **Anwendung Bayes-Theorem.**

- > Wir möchten die bedingte Wahrscheinlichkeit $P(\text{Corona} \mid \text{positiver Test})$ berechnen
- > Bayes-Theorem:

$$P(\text{Corona} \mid +) = \frac{P(+ \mid \text{Corona}) \cdot P(\text{Corona})}{P(+)}$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Exkurs. Satz der totalen Wahrscheinlichkeit.

Satz der totalen Wahrscheinlichkeit

Gegeben zwei Ereignisse E, F und deren Komplemente E^c, F^c . Die W'keit von E ist:

$$(Bed. W'keit E auf F) \times (W'keit F) + (Bed. W'keit E auf F^c) \times (W'keit F^c),$$

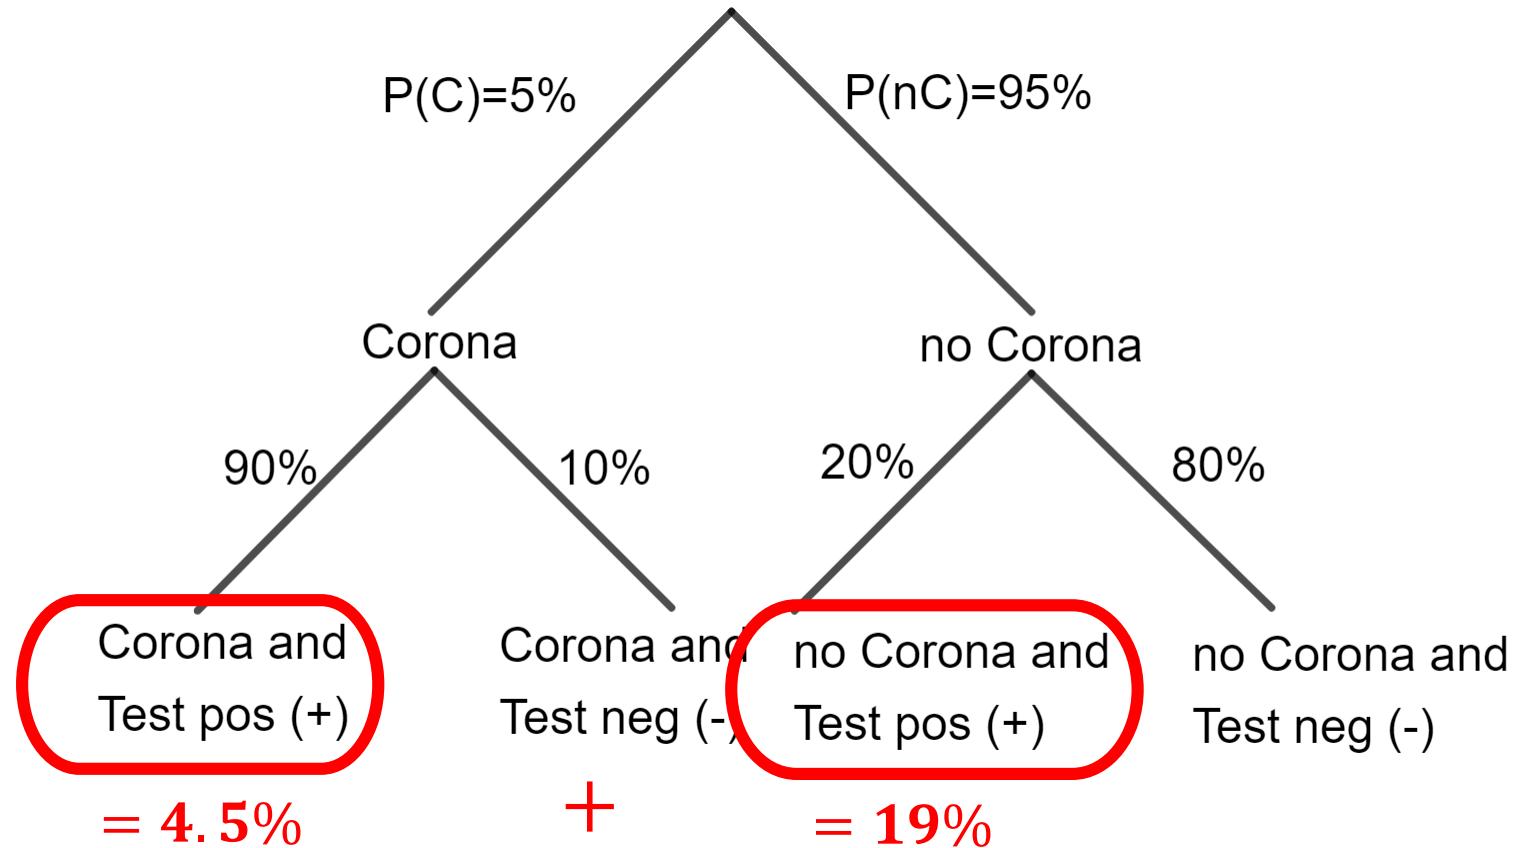
formal:

$$P(E) = P(E | F) \cdot P(F) + P(E | F^c) \cdot P(F^c) = P(E \cap F) + P(E \cap F^c).$$

WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel (Fortsetzung). Anwendung Satz der totalen W'keit zur Berechnung von $P(+)$.

> $P(+) = 4.5\% + 19\% = \mathbf{23.5\%}$



WOHER KOMMEN WAHRSCHEINLICHKEITEN? BAYESIANISCHER ANSATZ

Beispiel (Fortsetzung). Anwendung Bayes-Theorem.

- > Erinnerung: Wir möchten die bedingte W'keit $P(\text{Corona} \mid \text{positive test})$ bestimmen
- > Bayes-Theorem:

$$P(\text{Corona} \mid +) = \frac{\overset{90\%}{\boxed{P(+ \mid \text{Corona})}} \cdot \overset{5\%}{\boxed{P(\text{Corona})}}}{\underset{23.5\%}{\boxed{P(+)}}} = 19.15\%$$

→ Die W'keit Corona zu haben bei einem positiven Test ist 19.15%

Beispiel. 200 Menschen. 47 (= 23.5%) werden positiv getestet → 10 (= 5%) haben Corona.

› ZUFALLS- VARIABLEN

WAS SIND ZUFALLSVARIABLEN?

Meistens interessieren wir uns nicht für alle Details eines Zufallsexperiments.

Eine *Zufallsvariable*


- > hängt von den Ergebnissen eines Zufallsexperiments ab
- > misst relevante Charakteristika des Experiments

Beispiel. Mehrfacher Münzwurf.

- > Wie häufig wird "Kopf" geworfen?
- > Zufallsvariable, die zählt wie häufig "Kopf" geworfen wurde

WAS SIND ZUFALLSVARIABLEN?

Beispiel. Zweifacher Münzwurf. Zufallsvariable: Funktion X = Anzahl "Kopf".



WAS SIND ZUFALLSVARIABLEN?

Zufallsvariable

Eine *Zufallsvariable* X ist eine Funktion, die jedem Ergebnis $s \in S$ eines Zufallsexperiments ein Element s' einer Menge S' zuordnet (häufig eine Zahl: $S' = \mathbb{R}$):

$$X: S \rightarrow S'.$$





Beispiel. Zweimaliges Werfen einer Münze. X = Anzahl Kopf.


> X ist eine Stufenfunktion, die wie folgt geschrieben werden kann:

$$X(s) = \begin{cases} 2, & \text{wenn } s = HH \\ 1, & \text{wenn } s = HT \text{ oder } TH \\ 0, & \text{wenn } s = TT \end{cases}$$

Beispiel. Zweifacher Münzwurf.

Zufallsexperiment

$s \in S$	$P(s)$
	$\frac{1}{4}$
	$\frac{1}{4}$
	$\frac{1}{4}$
	$\frac{1}{4}$



Zufallsvariable $X = \text{Anzahl "Kopf"}$

$x \in S'$	$P'(X = x)$
2	$\frac{1}{4}$
1	$\frac{1}{2}$
0	$\frac{1}{4}$

Das Konzept einer Zufallsvariablen = Natürliche Erweiterung Zufallsexperiment

$$\text{Zufallsvariable: } X: S \rightarrow S'$$

> Wahl $S' = S \rightarrow$ Ursprüngliches Zufallsexperiment

Ab jetzt beziehen wir uns auf Zufallsvariablen (statt auf Zufallsexperimente)

- > Kombinationen von Zufallsvariablen

$$X + Y, X \cdot Y, \dots$$

sind ebenfalls Zufallsvariablen

- > Ebenso Kombinationen von Zufallsvariablen mit einer Konstanten

$$X + \textit{Konstante}, X \cdot \textit{Konstante}, \dots$$

ZUFALLSVARIABLEN: NOTATION

Objekt	Notation
Zufallsvariable	X, Y, Z, \dots (auch: X_1, X_2, \dots) (Großbuchstaben)
Platzhalter für einen Wert einer Zufallsvariablen	x, y, z, \dots (Kleinbuchstaben)
Wahrscheinlichkeit, dass die Zufallsvariable X einen Wert x annimmt	$P(X = x)$ Beispiel: $P(X = 2)$ Kurz: $P(2)$
Wahrscheinlichkeit, dass die Zufallsvariable X in einer Menge M liegt	$P(X \in M)$ Beispiel: $P(X \in [145, 180])$ Kurz: $P([145, 180])$

ARTEN VON ZUFALLSVARIABLEN: DISKRET UND STETIG

Diskrete Zufallsvariable

Nimmt eine **abzählbare** Anzahl (endlich oder unendlich) von Werten an.

Beispiel. Anzahl an Sechsen bei vierfachem Würfelwurf:

$0, 1, 2, 3, 4$

Stetige Zufallsvariable

Nimmt eine **nicht abzählbare** unendliche Anzahl von Werten an.

Beispiel. Größe einer zufällig ausgewählten Person:

$145 \text{ cm} \leq X \leq 220 \text{ cm}$

ZUFALLSVARIABLEN: DISKRET UND STETIG

Zufallsvariable	Art
Anzahl Verkäufe eines Verkäufers in einer Woche	
Die Größe eines zufällig ausgewählten Erwachsenen	
Die Zeit zwischen der Ankunft zweier Touristen an einem Urlaubsort	
Anzahl Kunden in einer Stichprobe, die ein bestimmtes Produkt gegenüber allen Wettbewerbern bevorzugen	
Neuer Wohnkomplex – die Zeit zwischen der Fertigstellung und dem Verkauf der letzten Wohnung	
Erwartete Anzahl Studierende in einer Vorlesung	
Die Tiefe, bis zu der gebohrt werden muss, bis man auf Öl stößt	

› WAHRSCHEINLICHKEITS- VERTEILUNGEN

- > *Diskrete Verteilung* = Verteilung einer diskreten Zufallsvariablen
- > *Stetige Verteilung* = Verteilung einer stetigen Zufallsvariablen

Eine diskrete Verteilung


- > ist definiert durch eine *Wahrscheinlichkeitsfunktion* $P(X = x)$
- > dies ist eine Liste aller Werte der Zufallsvariablen und Ihrer Wahrscheinlichkeiten

Beispiel. Zweifacher Münzwurf. X = Anzahl "Kopf". Wahrscheinlichkeitsverteilung:

x	$P(X = x)$
2	$\frac{1}{4}$
1	$\frac{1}{2}$
0	$\frac{1}{4}$

Wahrscheinlichkeitsfunktion – graphisch:

x	$P(X = x)$
2	$\frac{1}{4}$
1	$\frac{1}{2}$
0	$\frac{1}{4}$



Berechnung von Wahrscheinlichkeiten mit der Wahrscheinlichkeitsfunktion

x	$P(X = x)$
2	$\frac{1}{4}$
1	$\frac{1}{2}$
0	$\frac{1}{4}$

> Was ist die Wahrscheinlichkeit, dass mindestens 1x "Kopf" geworden wird $P(X \geq 1)$:

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: GLEICHVERTEILUNG

Diskrete Gleichverteilung

Eine diskrete Zufallsvariable ist gleichverteilt, wenn alle ihre Werte gleichwahrscheinlich sind.

Beispiele.



AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BERNOULLI-VERTEILUNG

Bernoulli-Verteilung

Eine Zufallsvariable ist *Bernoulli-verteilt*, wenn sie nur zwei Werte hat (0 and 1). Wert 1 heißt *Erfolg* und Wert 0 *Misserfolg*.

Beispiel.



Die Wahrscheinlichkeitsfunktion der Bernoulli-Verteilung ist

$$P(x) = \begin{cases} \pi & \text{für } x = 1 \\ (1 - \pi) & \text{für } x = 0 \end{cases}$$

> wobei π = Erfolgswahrscheinlichkeit der einzige Parameter ist

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Bernoulli-Prozess = Folge von n unabhängig und identisch verteilten Bernoulli-Variablen

> Eigenschaften Bernoulli-Prozess:

1. Fixierte Länge n
2. Nur 2 mögliche Ergebnisse pro Versuch: Erfolg und Misserfolg (Bernoulli-Variable)
3. Erfolgsw'keit π ist in allen Versuchen identisch (unabhängig und identisch verteilt)

Binomialverteilung

Eine Zufallsvariable X ist *binomialverteilt*, wenn sie die Anzahl der Erfolge in einem Bernoulli-Prozess der Länge n zählt.

Ist dies ein Bernoulli-Prozess?

- > Ein kleines Reisebüro hat 20 Reisekataloge bestellt.
- > Aufgrund schlechter Erfahrungen mit Fehldrucken möchte das Reisebüro 3 Kataloge auf Fehldruck prüfen, bevor es die Lieferung annimmt.
- > 3 Kataloge werden sequentiell zufällig aus-gewählt und auf Fehldruck geprüft.
- > Was das Reisebüro nicht weiß: 2 Kataloge sind Fehldrucke

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Beispiel. Fünffacher Münzwurf.

- > Die Münze ist leicht unfair: W'keit Kopf = $2/5$ (W'keit Zahl = $3/5$)
- > $X = \text{Anzahl Kopf}$

Was ist die Wahrscheinlichkeit 0-mal Kopf zu werfen $P(X = 0)$?

- > 0-mal Kopf (H) = 5-mal Zahl (T): 1 Ereignis: $TTTTT$

$$P(X = 0) = \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} = \frac{3^5}{5^5} = 1 \cdot \frac{2^0}{5} \cdot \frac{3^5}{5} \approx 7.78\%$$

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Beispiel (Fortsetzung). Fünffacher Münzwurf.

Was ist die Wahrscheinlichkeit exakt 1-mal Kopf zu werfen ($X = 1$)?

> 5 Ereignisse: $HTTTT, THTTT, TTHTT, TTTHT, TTTTH$

$$P(X = 1) = \frac{2}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} + \dots + \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{2}{5} = 5 \cdot \frac{2^1}{5} \cdot \frac{3^4}{5} \approx 25.92\%$$

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Beispiel (Fortsetzung). Fünffacher Münzwurf.

Was ist die Wahrscheinlichkeit exakt 2-mal Kopf zu werfen ($X = 2$)?

> 10 Ereignisse: $HHTTT, HTHTT, \dots, TTTHH$

$$P(X = 2) = \frac{2}{5} \cdot \frac{2}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} + \dots + \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{2}{5} \cdot \frac{2}{5} = 10 \cdot \frac{2^2}{5} \cdot \frac{3^3}{5} \approx 34.56\%$$

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Es existiert ein Muster!

Anzahl Erfolge (x)

Erfolgswahrscheinlichkeit (π)

Anzahl Misserfolge ($n - x$)

Misserfolgswahrscheinlichkeit ($1 - \pi$)

Anzahl Ereignisse

$$P(X = 0) = 1 \cdot \frac{2^0}{5} \cdot \frac{3^5}{5}$$
$$P(X = 1) = 5 \cdot \frac{2^1}{5} \cdot \frac{3^4}{5}$$
$$P(X = 2) = 10 \cdot \frac{2^2}{5} \cdot \frac{3^3}{5}$$

- > Wie können wir die **Anzahl der Ereignisse** berechnen?
- > Anzahl Möglichkeiten x Objekte (Erfolge) aus n Objekten (Versuche) zu ziehen:

= Binomialkoeffizient

Binomialkoeffizient

Der *Binomialkoeffizient* $\binom{n}{x}$ (lies " n über x ") bestimmt die Anzahl der Möglichkeiten x Objekte aus n Objekten ohne Reihenfolge zu ziehen:

$$\binom{n}{x} = \frac{n!}{x! (n - x)!}.$$

> wobei $n!$ (lies " n Fakultät") = $n \cdot (n - 1) \cdot (n - 2) \cdot \dots \cdot 2 \cdot 1$

Beispiel. 5 über 2:

$$\binom{5}{2} = \frac{5!}{2! 3!} = \frac{5 \cdot 4 \cdot 3!}{2 \cdot 1 \cdot 3!} = \frac{5 \cdot 4}{2 \cdot 1} = 10$$

Wahrscheinlichkeitsfunktion Binomialverteilung

Die *Wahrscheinlichkeit*, dass eine *binomialverteilte Zufallsvariable* X den Wert x annimmt ist:

$$P_{\pi,n}(x) = \text{Binomialkoeff.} \times W'keit\ Erfolg^{Erfolge(x)} \times W'keit\ Misserfolg^{Misserfolge(n-x)},$$

formal:


$$P_{\pi,n}(x) = \binom{n}{x} \cdot \pi^x \cdot (1 - \pi)^{n-x}.$$

Anmerkung. Die Binomialverteilung hat zwei Parameter:

Erfolgswahrscheinlichkeit π und Länge des Bernoulli-Prozesses n

AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Binomiale Wahrscheinlichkeitsfunktion für unterschiedliche Parameterkombinationen:



AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Berechnung binomialer Wahrscheinlichkeiten.

Beispiel. Einfluss von Frauen und Männern auf familiäre Kaufentscheidungen

- > Studie: In 70% der Fällen haben Männer einen maßgeblichen Einfluss beim Autokauf
- > 4 Familien sind im Begriff ein neues Auto zu kaufen

a) Was sind die Parameter dieser Binomialverteilung?



AUSGEWÄHLTE DISKRETE VERTEILUNGEN: BINOMIALVERTEILUNG

Beispiel (Fortsetzung).

- b) Wahrscheinlichkeit, dass der Mann in **genau** zwei Fällen die Entscheidung bestimmt?
- c) W'keit, dass der Mann in höchstens 3 Familien die Kaufentscheidung bestimmt?

Hausaufgabe.

- d) W'keit, dass der Mann in **mindestens** 2 Familien die Kaufentscheidung bestimmt?

Lösung: $P(X \geq 2) = 91.63\%$

Bei stetigen Verteilungen können wir keine Wahrscheinlichkeitsfunktion benutzen:

- > Unendlich viele Werte \rightarrow die Liste wäre unendlich lange
- > Jeder einzelne Wert hätte eine Wahrscheinlichkeit von 0

Beispiel. X = Größe ($145 \text{ cm} \leq X \leq 220 \text{ cm}$) eine zufällig ausgewählten Person.

- > Vereinfachende Annahme: Alle Größen sind gleichwahrscheinlich

Wahrscheinlichkeit, dass Person genau 180 cm groß ist?

- > Anzahl günstige Fälle für 180 cm: 1, Gesamtanzahl Fälle: ∞ (Intervall: $[145, 220]$)


Lösung: Wahrscheinlichkeit von Bereichen (Intervallen)

- > Ist definiert durch eine Wahrscheinlichkeitsdichtefunktion $f(x)$
- > W'keitsdichten identifizieren Regionen mit höherer bzw. niedrigerer W'keit:
 $f(2) > f(8)$: Wahrscheinlichkeit, dass Zufallsvariable Wert nahe 2 annimmt ist höher
- > Wahrscheinlichkeitsdichten \neq W'keiten! Es ist z.B. möglich, dass $f(x) > 1$

Die Wahrscheinlichkeit eines Bereichs ist die Fläche unter der Dichtefunktion

Beispiel. X = Größe ($145 \text{ cm} \leq X \leq 220 \text{ cm}$) eine zufällig ausgewählten Person.

- > Vereinfachende Annahme: Alle Größen sind gleichwahrscheinlich
- > Dichtefunktion: $f(x) = \frac{1}{75}$ für alle Größen x




- > $P(\text{Größe zwischen } 160 \text{ und } 180)?$

AUSGEWÄHLTE STETIGE VERTEILUNGEN: GLEICHVERTEILUNG

Stetige Gleichverteilung


Eine stetige Zufallsvariable X ist gleichverteilt auf einem Intervall, wenn alle Werte x des Intervalls die gleiche Wahrscheinlichkeitsdichte $f(x)$ haben.

Beispiel. Siehe vorherige Folie



AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG



In der Realität haben die meisten Verteilungen eine Glockenform:



- > Derartige Verteilungen heißen *Normal-* oder *Gaußverteilung*
- > Glockenform: Extremwerte (Ränder) sind unwahrscheinlicher als mittlere Werte

AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG



Parameter der Normalverteilung. Erwartungswert μ und Standardabweichung σ :



AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Symmetrie der Normalverteilung.

- > Die Normalverteilung ist perfekt symmetrisch um Ihren Erwartungswert μ :



Normalverteilung

Eine Zufallsvariable X heißt *normalverteilt*, wenn sie folgende Dichtefunktion hat:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

Wenn $\mu = 0$ und $\sigma = 1$, dann heißt die Zufallsvariable standardnormalverteilt.

wobei

- > e (≈ 2.7183) und π (≈ 3.1416) mathematische Konstanten sind
- > μ der Erwartungswert und σ die Standardabweichung der Normalverteilung ist

AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Berechnung von Wahrscheinlichkeiten.

- > Im Allgemeinen: Integrale bezüglich Dichtefunktion $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$

=



Gute Nachrichten! Wir können Integralrechnung vermeiden:

- > Tabelle mit Wahrscheinlichkeiten (Flächen) für Standardnormalverteilung


Z-Transformation: Konvertiert Normalverteilung in Standardnormalverteilung

Z-Transformation

Gegeben eine Zufallsvariable X mit Erwartungswert μ und Standardabweichung σ . Der z-Wert eines Wertes x von X ist:

$$z(x) = \frac{x - \mu}{\sigma}.$$

- > $z(x)$ = Distanz zwischen μ und x in Standardabweichungen σ
- > Zufallsvariable $Z = \frac{X - \mu}{\sigma}$ ist standard-normalverteilt, wenn X normalverteilt ist

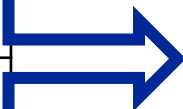


AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Beispiel. Z-Transformation.

Wahrscheinlichkeitsverteilung:

x	p	$p \cdot x$
2	0.1	0.2
4	0.2	0.8
6	0.4	2.4
8	0.2	1.6
10	0.1	1
Summe		$\mu_x = 6$
		$\sigma_x = 2.19$



$$z(x) = \frac{x - \mu_x}{\sigma_x}$$

Z-transformierte Wahrscheinlichkeitsverteilung:

$z(x)$	p	$p \cdot z(x)$
-1.83	0.1	-0.18
-0.91	0.2	-0.18
0	0.4	0
0.91	0.2	0.18
1.83	0.1	0.18
Summe		$\mu_z = 0$
		$\sigma_z = 1$

AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Z-Tabelle: Wahrscheinlichkeit $P([0, z])$



> Z-Wert bis 1. Nachkommastelle

> 2. Nachkommastelle

Z	0.00	0.01	0.02	0.03	0.04
0.00	0.0000	0.0040	0.0080	0.0120	0.0160
0.10	0.0398	0.0438	0.0478	0.0517	0.0557
0.20	0.0793	0.0832	0.0871	0.0910	0.0948
0.30	0.1179	0.1217	0.1255	0.1293	0.1331
0.40	0.1554	0.1591	0.1628	0.1664	0.1700
0.50	0.1915	0.1950	0.1985	0.2019	0.2054
0.60	0.2257	0.2291	0.2324	0.2357	0.2389
0.70	0.2580	0.2611	0.2642	0.2673	0.2704
0.80	0.2881	0.2910	0.2939	0.2967	0.2995
0.90	0.3159	0.3186	0.3212	0.3238	0.3264
1.00	0.3413	0.3438	0.3461	0.3485	0.3508
1.10	0.3643	0.3665	0.3686	0.3708	0.3729
1.20	0.3849	0.3869	0.3888	0.3907	0.3925
1.30	0.4032	0.4049	0.4066	0.4082	0.4099
1.40	0.4192	0.4207	0.4222	0.4236	0.4251
1.50	0.4332	0.4345	0.4357	0.4370	0.4382

Beispiel. $P([0, 1.22]) = 0.3888$

Berechnung Wahrscheinlichkeiten. Einzelwahrscheinlichkeiten.

Beispiel. Eine Person wird zufällig ausgewählt. $X = \text{Größe}$.

> Größe ist normalverteilt mit $\mu_X = 167\text{cm}$ und $\sigma_X = 10\text{cm}$.

- a) Berechne die W'keit, dass die Person zwischen 167 und 178cm ist. $P_X([167,178])$
- b) Wahrscheinlichkeit, dass X zwischen 150 und 181 cm ist?: $P_X([150,181])$
- c) Bestimme die Wahrscheinlichkeit, dass die Person größer als 175 ist: $P_X(X > 175)$
- d) Wahrscheinlichkeit, dass X zwischen 170 und 175 cm ist?: $P_X([170,175])$

AUSGEWÄHLTE STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Berechnung Wahrscheinlichkeiten. Vergleich von Gruppen.

Beispiel. Aggressivitäts-Score. $X = \text{Score Frauen}$, $Y = \text{Score Männer}$

> X ist normalverteilt mit $\mu_X = 38.82$ und $\sigma_X = 7.91$ (*)

> Y ist normalverteilt mit $\mu_Y = 40.86$ und $\sigma_Y = 8.69$ (*)

(*) Siehe “Gender Differences in Aggression-related Responses on EEG and ECG” in *Exp Neurobiol.* 27

Eine Frau und ein Mann werden zufällig ausgewählt.

> Wie wahrscheinlich ist es, dass der Mann aggressiver ist als die Frau?

ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)

Empirische Regel: Abschätzung der Normalverteilung


Wahrscheinlichkeit, dass eine normalverteilte Variable im Intervall

Mittelwert (μ) bis $\mu + 1$ Standardabweichung? +2 St.abw.? +3 St.abw.?

> Z-Werte für $[\mu, \mu + \sigma]$?

$$z(\mu) = 0$$

$$z(\mu + \sigma) = \frac{\mu + \sigma - \mu}{\sigma} = 1$$



ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)

Empirische Regel: Abschätzung der Normalverteilung

Analog:

1.00

0.3413


2.00

0.4772


3.00

0.4987


$$P[\mu, \mu + \sigma] = 0.3413$$




$$P[\mu, \mu + 2\sigma] = 0.4772$$



$$P[\mu, \mu + 3\sigma] = 0.4987$$



ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)



ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)

Zusammenfassung Empirische Regel. Gegeben eine Normalverteilung:

- > **Ca. 68%** der Daten sind höchstens **1 Standardabweichung** vom Mittelwert entfernt:

$$P([\mu - \sigma, \mu + \sigma]) \approx 68\%$$

- > **Ca. 95%** der Daten sind höchstens **2 Standardabweichungen** vom Mittelwert entfernt:

$$P([\mu - 2\sigma, \mu + 2\sigma]) \approx 95\%$$

- > **Ca. 99%** der Daten sind höchstens **3 Standardabweichungen** vom Mittelwert entfernt:


$$P([\mu - 3\sigma, \mu + 3\sigma]) \approx 99\%$$

ABSCHÄTZUNG STETIGER VERTEILUNGEN: CHEBYSHEVS UNGLEICHUNG

- > Die empirische Regel gilt nur für die Normalverteilung
- > Gibt es eine Regel für andere Verteilungen

Ja! Chebyshevs Ungleichung:

- > k = positive reelle Zahl



ABSCHÄTZUNG STETIGER VERTEILUNGEN: CHEBYSHEVS UNGLEICHUNG

Anwendung von Chebyshevs Ungleichung

> k = Anzahl Standardabweichungen, die die Daten höchstens vom Mittelwert entfernt sind

k	Wahrscheinlichkeit
1	$\geq 0\%$
2	$\geq 75\%$
3	$\geq 88.89\%$

ABSCHÄTZUNG STETIGER VERTEILUNGEN: CHEBYSHEVS UNGLEICHUNG

Beispiel. Nahrungsmittelunternehmen geben im Schnitt 135 € (Standardabweichung: 16 €) für Ads pro Internet-Nutzer aus. Die Art der Verteilung ist unbekannt.

- a) Bestimmen Sie die Mindestwahrscheinlichkeit, dass eine zufällig ausgewählte Firma zwischen 115 € und 155 € ausgibt.

- b) Bestimmen Sie die Ausgabenspanne (Intervall) in welche mindestens 50% der Unternehmen fallen

› MULTIVARIATE VERTEILUNG UND STOCHASTISCHE UNABHÄNGIGKEIT

MULTIVARIATE VERTEILUNG: GEMEINSAME VERTEILUNG ZWEIER VARIABLEN

- > Gemeinsame Wahrscheinlichkeitsfunktion $P_{X,Y}(x, y)$ von 2 Zufallsvariablen X und Y
- > Gibt die gemeinsamen Wahrscheinlichkeiten an: $P(X = x, Y = y)$

Beispiel. Zweimaliger Münzwurf. $X = \text{Anzahl Kopf in Wurf 1}$. $Y = \text{Anzahl Kopf in Wurf 2}$.

		X		Randverteilung Y
		1	0	P_Y
Y	1	0.25	0.25	0.5
	0	0.25	0.25	0.5
Randverteilung X P_X		0.5	0.5	1

MULTIVARIATE VERTEILUNG: GEMEINSAME VERTEILUNG ZWEIER VARIABLEN

Beispiel. Statistik-Klausur. Zufallsvariablen:

> $X = \{\text{Bestanden}, \text{Nicht Bestanden}\}$ und $Y = \{\text{Viel gelernt}, \text{Wenig}\}$

		X		Randverteilung Y P_Y
		Bestanden	Nicht	
Y	Viel	0.4	0.1	0.5
	Wenig	0.2	0.3	0.5
Randverteilung X P_X		0.6	0.4	1

Zwei Zufallsvariablen sind stochastisch unabhängig, wenn

- > die Realisierung einer Zufallsvariable keinen Einfluss auf die W'keiten der anderen hat

Beispiel. Zweifacher Münzwurf. Zufallsvariablen

$$X = \text{Anzahl Kopf in Wurf 1}$$

$$Y = \text{Anzahl Kopf in Wurf 2}$$

$$Z = \text{Anzahl Zahl in beiden Würfeln}$$

- > Wir beobachten $X = 1$
- > Was sind nun die Wahrscheinlichkeiten $P(Y = 1)$ und $P(Z = 2)$?

Eine Zufallsvariable X ist unabhängig von Y , wenn bedingte W'keit = unbedingte W'keit:

$$P(X = x \mid Y = y) = P(X = x) \text{ für alle } x, y.$$

> Außerdem gemäß Bayes-Theorem:

$$P(X = x \mid Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}$$

> Zusammen:

Stochastische Unabhängigkeit

Zwei Zufallsvariablen X und Y sind *stochastisch unabhängig*, wenn

$$P(X = x, Y = y) = P(X = x) \times P(Y = y) \text{ für alle } x, y.$$

STOCHASTISCHE UNABHÄNGIGKEIT: BEISPIEL

Beispiel. Zweimaliger Münzwurf.

		X		P_Y
		1	0	
Y	1	0.25	0.25	0.5
	0	0.25	0.25	0.5
P_X		0.5	0.5	1

Stochastisch **Unabhängig**:

$$P_{X,Y}(x, y)$$

$=$

$$P_X(x) \cdot P_Y(y) = 0.5 \cdot 0.5 = 0.25$$

für alle $x, y \in \{0, 1\}$

Beispiel. Klausur.

		X		P_Y
		Bestanden (B)	Nicht	
Y	Viel (V)	0.4	0.1	0.5
	Wenig	0.2	0.3	0.5
P_X		0.6	0.4	1

Stochastisch **Abhängig**:

$$P_{X,Y}(B, V) = 0.4$$

\neq


$$P_X(B) \cdot P_Y(V) = 0.6 \cdot 0.5 = 0.3$$


STOCHASTISCHE UNABHÄNGIGKEIT UND KORRELATION

- > Zwei Zufallsvariablen X und Y sind korreliert, wenn deren Kovarianz ungleich 0 ist
- > **Korrelierte** Zufallsvariablen sind immer **stochastisch abhängig**
- > **Stochastisch abhängige** Zufallsvariablen können aber **unkorreliert** sind


Beispiel.

- > X und Y sind perfekt abhängig aber unkorreliert
- > Erinnerung: Korrelation = Lineare Beziehung
- > Nicht alle Beziehungen sind linear!






› INFERENZSTATISTIK



WAS IST INFERENZSTATISTIK?

> Inferenzstatistik: Rückschlüsse von Stichproben auf die Population



Beispiel. In einer Stichprobe verdienen Frauen im Schnitt 211 € mehr als Männer.

> Können wir daraus schließen, dass Frauen im Allgemeinen mehr verdienen?

Solche und ähnliche Fragen werden mit inferenzstatistischen Methoden beantwortet.

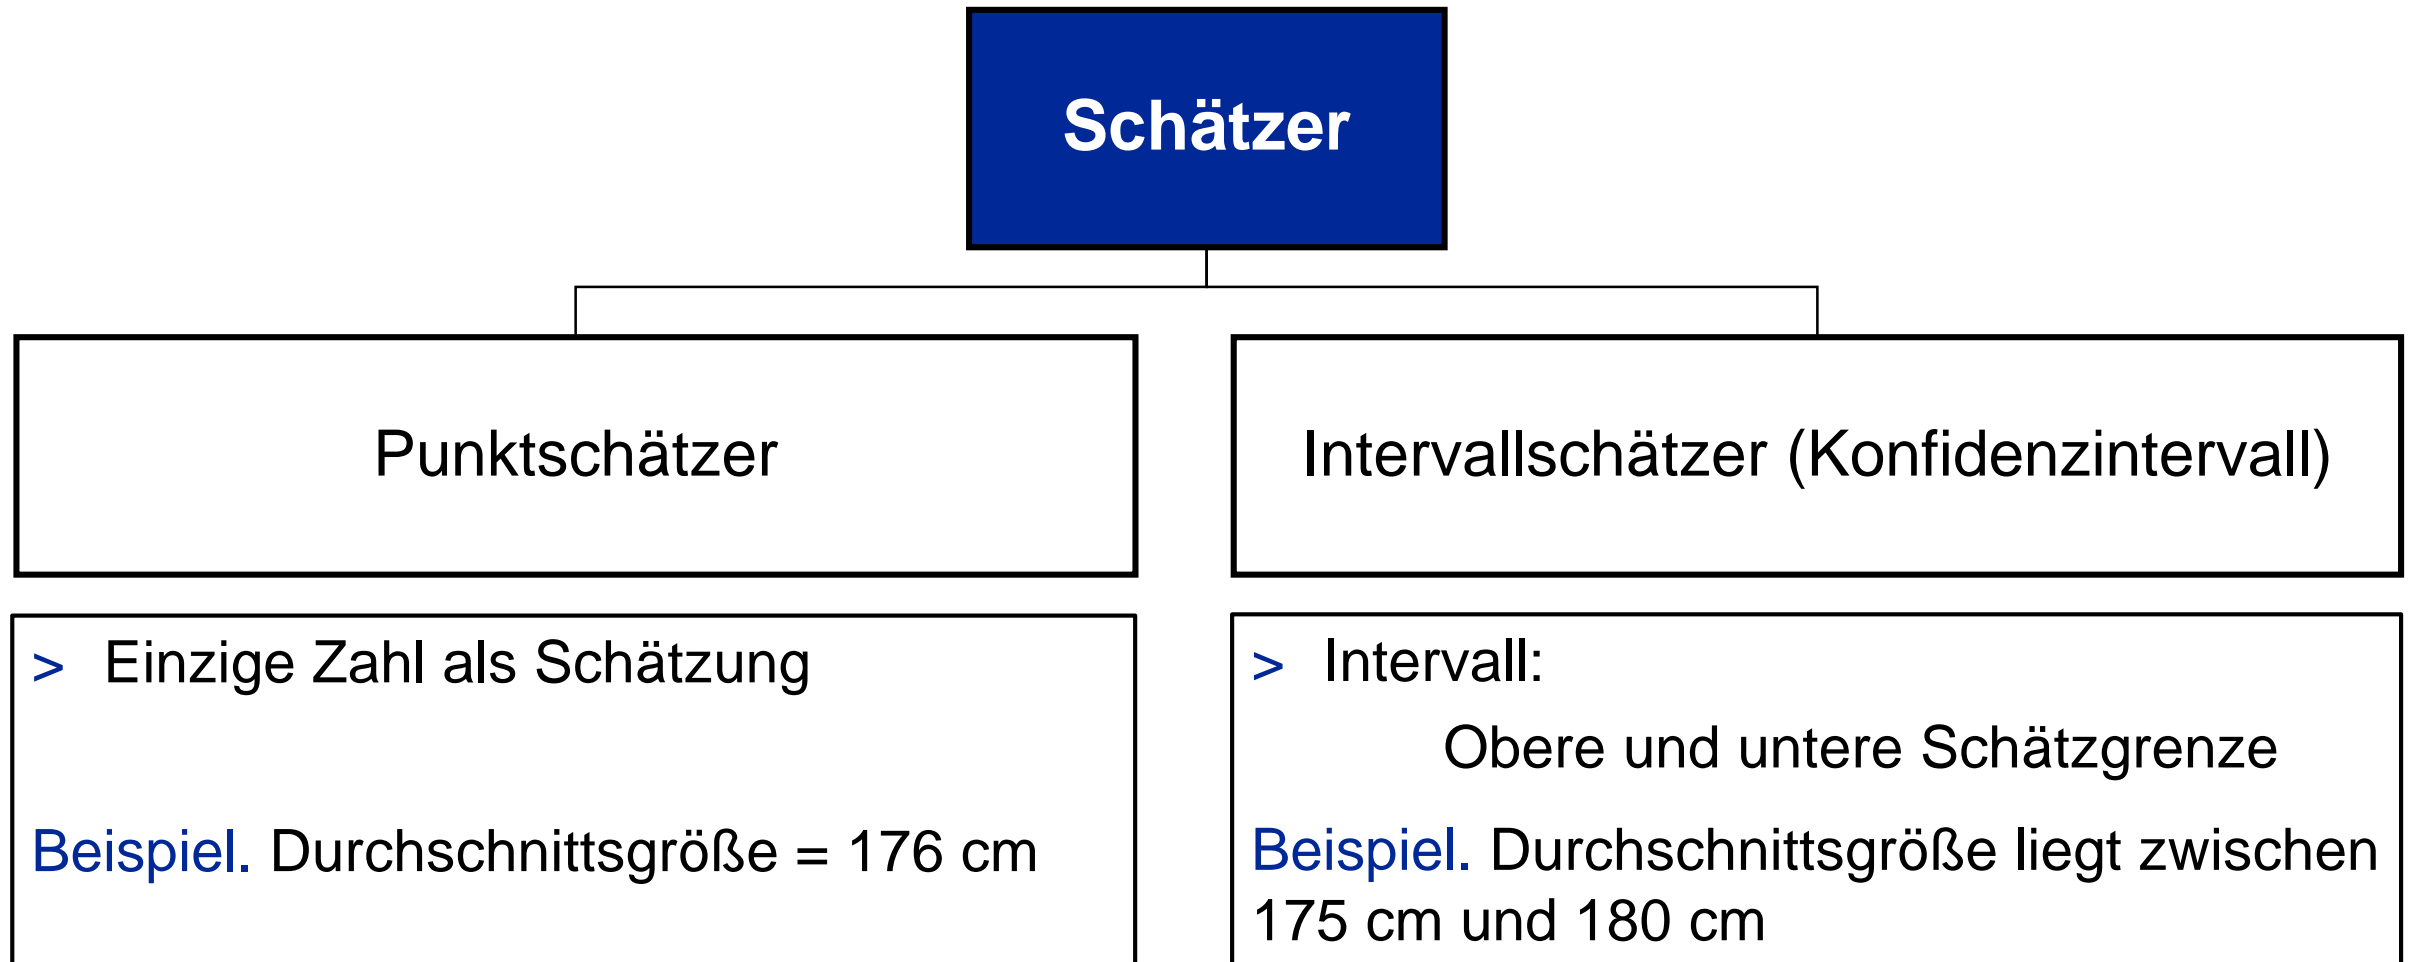
› STATISTISCHE SCHÄTZER


Täglich werden Entscheidungen basierend auf Daten getroffen:

- > Die Regierung möchte Güterströme von Auslandsmärkten vorhersagen
- > Aktienhändler möchten Aktienentwicklungen vorhersagen
- > Konsumenten möchten eine Einschätzung über Güter erlangen

Im Allgemeinen sind die Parameter dieser Verteilungen (μ, σ, π, \dots) unbekannt

Schätzer = Regel zur Schätzung eines Parameters basierend auf einer Stichprobe






Notation. Schätzwerte werden mit überdachten griechischen Buchstaben $\hat{\cdot}$ bezeichnet.

Beispiel. $\hat{\mu}$ ist der Schätzwert für den Erwartungswert μ .

Beispiel. Betrachten Sie folgende Population:




> Der Populationsmittelwert ist:

$$\mu = \frac{150 + 160 + 170 + 180 + 190}{5} = 170$$

Beispiel (Fortsetzung).

- > Der Mittelwert $\mu = 170$ sei **unbekannt**.
- > Wir möchten den Mittelwert schätzen
- > Ziehe eine Stichprobe, z.B. Größe $n = 3$



Der **Schätzer** für den **Populationsmittelwert** ist der **Stichprobenmittelwert**:

$$\hat{\mu} = \bar{x} = \frac{170 + 180 + 190}{3} = 180$$

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE

- > Unsere Stichprobe überschätzt den wahren Mittelwert
- > Andere unterschätzen den wahren Mittelwert


Ist es möglich etwas über einen möglichen Schätzfehler zu sagen?

- > Ja → Wir müssen die Verteilung der Schätzwerte untersuchen:

**Je stärker die Schätzwerte um den Populationsparameter streuen,
desto wahrscheinlicher ist ein hoher Schätzfehler**

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE

Beispiel.




> Wie viele unterschiedliche Stichproben mit $n = 3$ können wir ziehen?

$$\binom{\text{Populationsgröße}}{\text{Stichprobengröße}} = \binom{5}{3} = \frac{5!}{3! 2!} = \frac{5 \cdot 4}{2} = 10$$

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE

Verteilung der Stichproben.



Verteilung Stichproben		
i	Stichprobe i	$P(i)$
1	150, 160, 170	10%
2	150, 160, 180	10%
3	150, 160, 190	10%
4	150, 170, 180	10%
5	150, 170, 190	10%
6	150, 180, 190	10%
7	160, 170, 180	10%
8	160, 170, 190	10%
9	160, 180, 190	10%
10	170, 180, 190	10%

Zufallsstichprobe = Jedes Element der Population wird mit gleicher W'keit ausgewählt

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE

Verteilung Stichprobenmittelwerte (Stichprobenmittelw. = Schätzer Populationsmittelw.).

Verteilung Stichproben			
i	Stichprobe i	$P(i)$	Mittelw. \bar{x}_i
1	150, 160, 170	10%	160
2	150, 160, 180	10%	163.34
3	150, 160, 190	10%	166.67
4	150, 170, 180	10%	166.67
5	150, 170, 190	10%	170
6	150, 180, 190	10%	173.34
7	160, 170, 180	10%	170
8	160, 170, 190	10%	173.34
9	160, 180, 190	10%	176.67
10	170, 180, 190	10%	180




Verteilung Stichprobenmittelwerte	
\bar{x}	$P(\bar{x})$
160	10%
163.34	10%
166.67	20%
170	20%
173.34	20%
176.67	10%
180	10%

7 unterschiedliche Stichprobenmittelwerte

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE


Verteilung Stichprobenmittelwerte (Stichprobenmittelw. = Schätzer Populationsmittelw.).

Verteilung Stichprobenmittelwerte	
\bar{x}	$P(\bar{x})$
160	10%
163.34	10%
166.67	20%
170	20%
173.34	20%
176.67	10%
180	10%



PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE


Verteilung Stichprobenmittelwerte (Stichprobenmittelw. = Schätzer Populationsmittelw.).



20% W'keit dass *Schätzwert* \bar{x} = *Populationsmittelwert* $\mu = 170$

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE

Verteilung Stichprobenmittelwerte (Stichprobenmittelw. = Schätzer Populationsmittelw.).




> Wahrscheinlichkeit, dass der Schätzfehler mindestens 5cm ist?

40%

PUNKTSCHÄTZER: VERTEILUNG DER SCHÄTZWERTE

Verteilung Stichprobenmittelwerte (Stichprobenmittelw. = Schätzer Populationsmittelw.).



- > Mittelwert der Verteilung der Stichprobenmittelwerte $\mu_{\bar{x}} = \text{Populationsmittelwert } \mu$
- > **Standardfehler** = Standardabweichung der Verteilung \rightarrow Streuung um μ
- > Je höher der Standardfehler, desto wahrscheinlicher ist ein großer Schätzfehler

Standardfehler = Standardabweichung der Verteilung der Schätzwerte

> Hier: Schätzwerte = Stichprobenmittelwerte

Berechnung Standardfehler:

- > Wenn Verteilung Schätzwerte bekannt → Berechnung Standardabweichung wie bekannt
- > Üblicherweise nicht bekannt, dann Berechnung Standardfehler (standard error) SE:

$$SE_{\bar{X}} = \frac{\textit{Populationsstandardabweichung}}{\sqrt{\textit{Stichprobengröße}}} = \frac{\sigma}{\sqrt{n}}$$

Anmerkung. Berechnung des Standardfehlers.


Wenn die Stichprobe groß ist ($n > 5\%$ der Population), dann

> müssen wir die Standardfehler mit folgendem **Korrekturfaktor** multiplizieren:

$$\sqrt{\frac{N - n}{N - 1}},$$

N = Populationsgröße, n = Stichprobengröße

Beispiel. Berechnung Standardfehler (bekannte Pop.varianz).



- > Pop.Varianz: $\sigma^2 = 200 \rightarrow$ Standardabweichung: $\sigma = \sqrt{\sigma^2} \approx 14.14$
- > Stichprobengröße $n = 3$ groß oder klein?
- > Groß ($n = 60\%$ der Population). Somit:

$$\text{Standardfehler korrigiert} = SE_{\bar{X}} \cdot \text{Korrekturfaktor} = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}} = \frac{14.14}{\sqrt{3}} \sqrt{\frac{5-3}{5-1}} \approx 5.77$$

PUNKTSCHÄTZER: DIFFERENZ VON MITTELWERTEN

Gruppen werden häufig anhand der Differenz ihrer Mittelwerte verglichen

- > Schätzer für Mittelwertdifferenz ($\mu = \mu_X - \mu_Y$) = Differenz Stichprobenmittelwerte:

$$\hat{\mu} = \textit{Stichprobenmittelwert } x - \textit{Stichprobenmittelwert } y$$

- > Standardfehler der Verteilung der Differenzen = gepoolter Standardfehler SE_{X-Y} :

$$SE_{X-Y} = \sqrt{(\textit{Standardfehler } X)^2 + (\textit{Standardfehler } Y)^2}$$

- > Der Schätzer für die Varianz $\hat{\sigma}^2$ ist die **Bessel-korrigierte** Stichprobenvarianz:

$$\hat{\sigma}^2 = \textit{Stichprobenvarianz} \cdot \frac{n}{n-1}$$


- > Der Schätzer für die Standardabweichung $\hat{\sigma}$ ist somit:

$$\hat{\sigma} = \textit{Stichprobenstandardabweichung} \cdot \sqrt{\frac{n}{n-1}}$$


- > Den komplizierten Standardfehler der Stichprobenvarianzverteilung lassen wir aus

EXKURS: ZENTRALER GRENZWERTSATZ

Beispiel 1:




Population:
Gleichverteilung



Stichproben
($n = 3$)



Verteilung Stichprobenmittelwerte:
Keine Gleichverteilung




EXKURS: ZENTRALER GRENZWERTSATZ

Beispiel 2. Zweimaliger Würfelwurf: Stichprobenmittelwert = Durchschnitt der Augenzahlen.




Population:
Gleichverteilung



100'000
Stichproben



Verteilung Stichprobenmittelwerte:
Keine Gleichverteilung



Zentraler Grenzwertsatz

Summe und Mittelwert von n unabhängig und identisch verteilten Zufallsvariablen sind approximativ normalverteilt, wenn n hinreichend groß ist.

Implikationen:

- > Normalverteilung Population → Stichprobenverteilung normal (n egal)
- > Keine Normalverteilung Population → Stichprobenverteilung normal (wenn n groß)


Daumenregel: Die Stichprobenverteilung ist annähernd normalverteilt, wenn

$$\text{Stichprobengröße} \geq 30$$

EXKURS: ZENTRALER GRENZWERTSATZ

Illustration. Populationen: Bernoulli-verteilt mit $\pi = 50\%$ und $\pi = 75\%$


> Relative Häufigkeitsverteilung des Stichprobenmittels bei 100'000 Stichproben:



PUNKTSCHÄTZER: SCHÄTZFEHLER UND ZENTRALER GRENZWERTSATZ

Schätzfehler = Schätzwert – Wahrer Parameter

- > Mittelwert: $Schätzfehler = Schätzer - \mu = \text{Stichprobenmittelwert } (\bar{x}) - \mu$
- > Welche der folgenden Verteilungen ergibt im Schnitt den kleinsten Schätzfehler?



PUNKTSCHÄTZER: SCHÄTZFEHLER UND ZENTRALER GRENZWERTSATZ

Beispiel. Körpergröße ist verteilt mit Mittelwert 167cm (Standardabweichung = 10cm).

- > Stichprobe mit $n = 36$ Personen
- > Wahrscheinlichkeit, dass der Mittelwert um mindestens 3cm überschätzt wird?

PUNKTSCHÄTZER: SCHÄTZFEHLER UND ZENTRALER GRENZWERTSATZ

Beispiel. Monatliches Einkommen von Männern (M) und Frauen (W).

- > Mittelwerte: $\mu_M = 3'201\text{€}$ und $\mu_W = 3'001\text{€}$
- > Standardabweichungen: $\sigma_M = 420\text{€}$ und $\sigma_W = 305\text{€}$
- > Stichprobe mit 36 Frauen und 49 Männer
- > Wahrscheinlichkeit, dass Durchschnittseinkommen Frauen \geq Männer?

MAXIMALER SCHÄTZFEHLER (= ERROR BOUND EB)

- > In den meisten Fällen: Populationsmittelwert nicht bekannt
- > Schätzfehler = Stichprobenmittelwert - Populationsmittelwert
- > Ist es möglich den Schätzfehler bei unbekanntem Populationsmittelwert abzuschätzen?

Überraschenderweise ja

Betrachten Sie den z-Wert der Zufallsvariable des Stichprobenmittels (\bar{X}):

$$Z(\bar{X}) = \frac{\bar{X} - \mu}{\text{Standardfehler (SE)}}$$

Zufallsvariable des Schätzfehlers

MAXIMALER SCHÄTZFEHLER (= ERROR BOUND EB)

Betrachten Sie den z-Wert der Zufallsvariable des Stichprobenmittels (\bar{X}):

$$Z(\bar{X}) = \frac{\bar{X} - \mu}{SE}$$

Zufallsvariable des Schätzfehlers

Also:


$$Z = \frac{\text{Schätzfehler}}{SE} \Leftrightarrow \text{Schätzfehler} = Z \cdot SE$$

- > Der Standardfehler SE ist bekannt
- > ABER Z ist eine Zufallsvariable → bisher kann der Schätzfehler nicht berechnet werden

MAXIMALER SCHÄTZFEHLER (= ERROR BOUND EB)

Konfidenzniveau festlegen.

- > Wir können ein Konfidenzniveau $(1 - \alpha)$ festlegen
- > $(1 - \alpha) = 95\%$ bedeutet z.B., dass der Schätzfehler zu 95% in dem Bereich liegt
- > Wir lassen eine Fehlerwahrscheinlichkeit von $\alpha/2 = 2.5\%$ auf jeder Seite zu:



MAXIMALER SCHÄTZFEHLER (= ERROR BOUND EB)

Bereich bestimmen.


> Wie finden wir die Grenzen $-z_{\alpha/2}$ und $z_{\alpha/2}$ für ein festgelegtes Konfidenzniveau?

ERROR BOUND (EB)

Bereich bestimmen.

Beispiel. $\alpha = 5\% \rightarrow z_{2.5}$?

> Nun: Z-Wert für Fläche finden!



> Also:

$z_{2.5} = 1.96$

Z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.10	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.20	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.30	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.40	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.50	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.60	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.70	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.80	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.90	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.00	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.10	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.20	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.30	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.40	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.50	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.60	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.70	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.80	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.90	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767
2.00	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.10	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.20	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.30	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.40	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936
2.50	0.4938	0.4940	0.4941	0.4943	0.4945	0.4946	0.4948	0.4949	0.4951	0.4952
2.60	0.4953	0.4955	0.4956	0.4957	0.4959	0.4960	0.4961	0.4962	0.4963	0.4964
2.70	0.4965	0.4966	0.4967	0.4968	0.4969	0.4970	0.4971	0.4972	0.4973	0.4974
2.80	0.4974	0.4975	0.4976	0.4977	0.4977	0.4978	0.4979	0.4979	0.4980	0.4981
2.90	0.4981	0.4982	0.4982	0.4983	0.4984	0.4984	0.4985	0.4985	0.4986	0.4986
3.00	0.4987	0.4987	0.4987	0.4988	0.4988	0.4989	0.4989	0.4989	0.4990	0.4990

MAXIMALER SCHÄTZFEHLER (= ERROR BOUND EB)

Fixiere ein Konfidenzniveau $(1 - \alpha)$ und bestimme hierfür $z_{\alpha/2}$

> dann können wir den maximalen Schätzfehler (error bound eb) berechnen:

$$\text{error bound für } (1 - \alpha) = z_{\alpha/2} \cdot \text{Standardfehler}$$

> Interpretation:

Mit W'keit $(1 - \alpha)$ ist der maximale Schätzfehler nicht höher als $z_{\alpha/2} \cdot \text{Standardfehler}$

MAXIMALER SCHÄTZFEHLER (ERROR BOUND EB)

Berechnung des error bound.

Beispiel. $z_{2.5} = 1.96$, Größe Stichprob. $n = 64$, Standardabweichung $\sigma = 16$.

$$eb = z_{2.5} \cdot SE = z_{2.5} \cdot \frac{\sigma}{\sqrt{n}} = 1.96 \cdot \frac{16}{\sqrt{64}} = 3.92$$

> Interpretation:

Maximaler Schätzfehler ist mit 95% W'keit nicht höher als 3.92

ERROR BOUND UND OPTIMALE STICHPROBENGROÖßE

Frage wenn Daten erhoben werden → Welche Stichprobengröße?

> Frage:

Wie akkurat sollen die Schätzungen sein?

> Wir können den error bound benutzen, um diese Frage zu beantworten

ERROR BOUND UND OPTIMALE STICHPROBENGROÖßE

Beispiel. Sie besitzen eine große Brauerei und möchten Ihre Tagesproduktion schätzen.

- > Ihre durchschnittliche Tagesproduktion der letzten 30 Tage ist 871 Kubikliter Bier
- > Standardabweichung: 21 Kubikliter

Wie viele Tage müssen Sie die Tagesproduktion beobachten, um die langfristige Tagesproduktion mit 95% zu schätzen bei einem error bound von 4 Kubiklitern?

Die folgenden Aussagen sind äquivalent:

1. Zu 95% ist der Schätzfehler nicht höher als 3.92 (Interpretation eb)
2. Zu 95% liegt der Populationsmittelwert in einem Intervall Stichprobenmittel ± 3.92

Aussage 2. legt einen Intervallschätzer nahe mit den folgenden Schätzgrenzen:

Punktschätzer \pm Error Bound

Beispiel. Zahlungsbereitschaft von Kunden für eine Übernachtung im Hotel bestimmen.

- > In einer Stichprobe von $n = 39$ Befragten liegt die Zahlungsbereitschaft bei 86 €
- > Standardabweichung = 26 €

a) Bestimmen Sie das 99%-Konfidenzintervall

Hausaufgabe.

b) Bestimmen Sie das 90%-Konfidenzintervall

Lösung: 90%-Konfidenzintervall = $[79, 93]$

Beispiel. Wir möchten den durchschnittlichen IQ von Studierenden der Hochschule Heilbronn schätzen.

- > In einer Stichprobe mit 47 Studierenden ist der durchschnittliche IQ 102
- > Standardabweichung = 13

a) Bestimmen Sie das 90%-Konfidenzintervall

Hausaufgabe.

b) Bestimmen Sie das 95%-Konfidenzintervall

Lösung: 95%-Konfidenzintervall = [98.28, 105.72]

Optimales Konfidenzintervall: So **schmal wie möglich** und **Konfidenzniveau nahe 1**

- > Je größer das Konfidenzniveau, desto sicherer ist wahrer Parameter enthalten
- > Je enger das Konfidenzintervall, desto exakter ist die Schätzung
- > Je größer die Stichprobe, desto enger ist das Intervall

Aber:

- > Je höher das Konfidenzniveau, desto breiter das Intervall

› HYPOTHESEN- TESTS

WARUM HYPOTHESENTESTS?

In einer Stichprobe mit 35 Frauen und 44 Männer ist das Durchschnittseinkommen der Frauen um 200 € niedriger als das der Männer

- > Ist dies ein Beleg dafür, dass Frauen allgemein im Schnitt weniger verdienen?

Der Umsatz einer Firma war im letzten Jahr 300'000 € höher als der Durchschnitt ihres langfristigen jährlichen Umsatzes

- > Ist dies ein Beleg dafür, dass sich die Nachfrage für die Produkte erhöht hat?

Derartige Fragen werden anhand von Hypothesentests beantwortet

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

Die Denklogik eines Hypothesentests ist anders als wir im Alltag gewöhnt sind:

- > Keine direkten Belege für eine Hypothese (**Alternativ- bzw. Forschungshypothese**)
- > Stattdessen: Ist das Gegenteil (**Nullhypothese**) unwahrscheinlich gegeben die Daten?

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

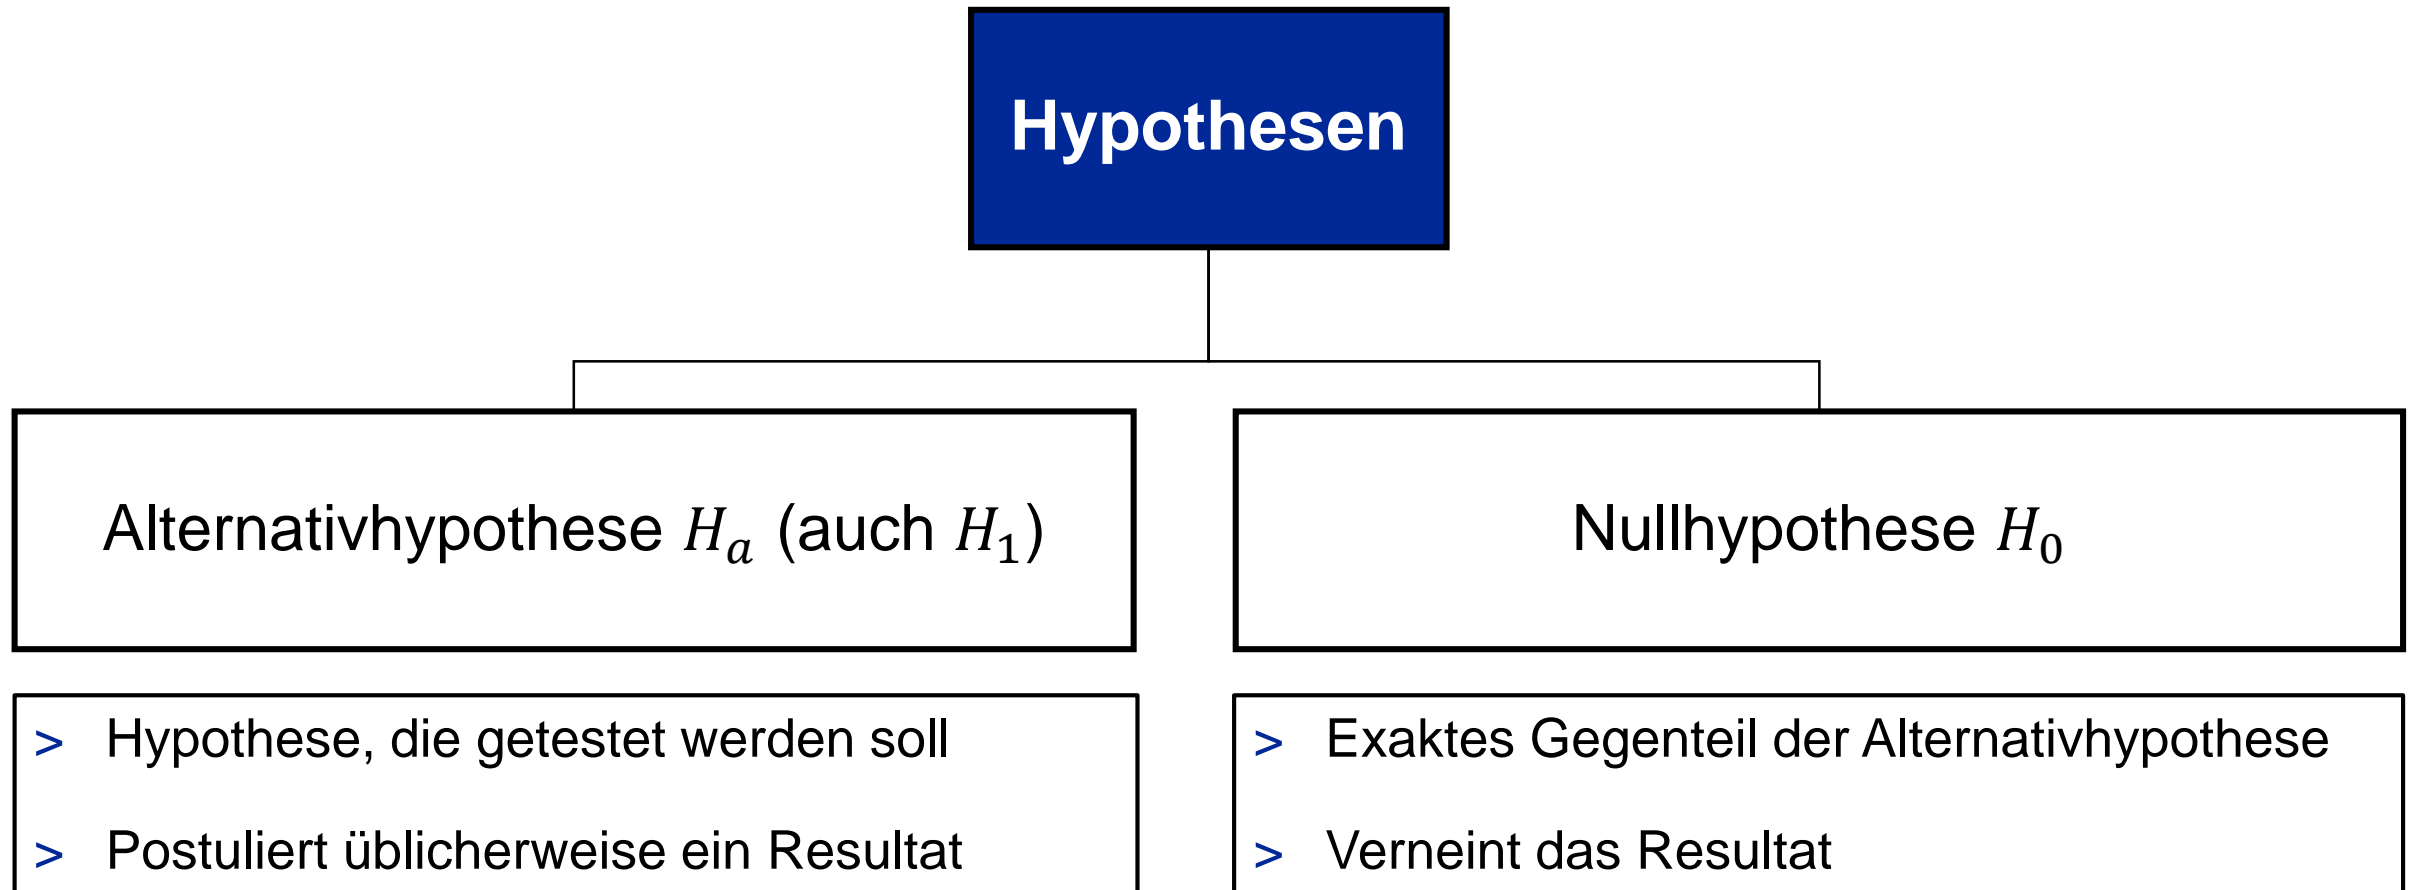
Beispiel. Wir möchten untersuchen, ob Frauen weniger verdienen als Männer.

> Alternativhypothese: $\text{Durchschnittseinkommen}_{\text{Frauen}} < \text{Durchschnittseinkommen}_{\text{Männer}}$

Wir untersuchen nun wie wahrscheinlich das Gegenteil ist:

> Nullhypothese: $\text{Durchschnittseinkommen}_{\text{Frauen}} \geq \text{Durchschnittseinkommen}_{\text{Männer}}$

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE



HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

Beispiele.

Wir möchten wissen...	Alternativhypothese (H_a)	Nullhypothese (H_0)
ob Absolventen der HS Heilbronn im Schnitt (μ_{Alter}) älter sind als 26 (μ_0)	$\mu_{Alter} > 26$	$\mu_{Alter} \leq 26$
ob sich der Durchschnitts-IQ (μ_{IQ}) von Studierenden verändert hat (langfristiger Durchschnitt: $\mu_0 = 101$)	$\mu_{IQ} \neq 101$	$\mu_{IQ} = 101$
ob die Nachfrage (μ_{Nach}) für das Produkt einer Firma abgenommen hat (langfristiger Durchschnitt: $\mu_0 = 41'000$)	$\mu_{Nach} < 41'000$	$\mu_{Nach} \geq 41'000$

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

Beispiel. In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen 2.9 T€ (*Varianz* = 0.7) und das der Männer 3.1 T€ (*Varianz* = 0.4).

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?

a) Schreiben Sie die Null- und die Alternativhypothese zu dieser Fragestellung auf.

> Alternativhypothese:

Durchschnittseinkommen Pop. Frauen μ_f < Durchschnittseinkommen Pop. Männer μ_m

> Nullhypothese:

Durchschnittseinkommen Pop. Frauen $\mu_f \geq$ Durchschnittseinkommen Pop. Männer μ_m


HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

Null- und Alternativhypothese repräsentieren **zwei unterschiedliche Welten**:

Welt 0 (Nullhypothese H_0):

Frauen verdienen nicht weniger.


> Gleiche Einkommensverteilung




Welt 1 (Alternativhypothese H_a):

Frauen verdienen weniger.

> Unterschiedliche Einkommensverteilungen.




HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE



Welt 0 (Nullhypothese H_0)

**In welcher Welt
leben wir?**



Welt 1 (Alternativhypothese H_a)

- > Ein Hypothesentest sagt uns, ob wir die Nullhypothese ablehnen können
- > Wenn wir die Nullhypothese ablehnen können, dann ist der Test erfolgreich

HYPOTHESENTEST: FEHLER 1. UND 2. ART

Welche Fehler sind möglich bei der Entscheidung, ob man die Nullhypothese ablehnt?

Entscheidung	Nullhypothese (H_0)	
	Wahr	Falsch
Nullhypothese ablehnen	Fehler 1. Art (α-Fehler): Falsch-positives Resultat (Wahrscheinlichkeit: α)	Richtige Entscheidung (Wahrscheinlichkeit: $1 - \beta$)
Nullhypothese nicht ablehnen	Richtige Entscheidung (Wahrscheinlichkeit: $1 - \alpha$)	Fehler 2. Art (β-Fehler): Falsch-negatives Resultat (Wahrscheinlichkeit: β)

HYPOTHESENTEST: FEHLER 1. UND 2. ART

Type I error
(false positive)



Type II error
(false negative)



Welches Kriterium bestimmt, ob wir die Nullhypothese (Welt 1) ablehnen können?

Wir berechnen eine Statistik, genannt **Teststatistik**, mit welcher wir die

> W'keit der beobachteten Daten oder extremeren Werten in Welt 0 berechnen (= **p-Wert**)

Die Nullhypothese kann abgelehnt werden, wenn der p-Wert hinreichend gering ist

> Das heißt wir minimieren die W'keit eines Fehlers 1. Art

Warum minimieren wir nicht auch die W'keit eines Fehlers 2. Art?

- > Es ist nicht möglich beide zu minimieren: W'keit Fehler 1. Art $\downarrow \rightarrow$ W'keit Fehler 2. Art \uparrow

Vorteile Minimierung Fehler 1. Art (statt 2. Art):

- > **konservativer** \rightarrow Nullhypothese wird weniger oft abgelehnt
- > **exakter** $\rightarrow \alpha$ kann berechnet werden, β muss geschätzt werden

Erinnerung:

Teststatistik → p-Wert → Entscheidung, ob Nullhypothese abgelehnt werden kann

> Die Teststatistik ist eine Statistik (Zahl die Daten einer Stichprobe zusammenfasst)



Beispiel (Fortsetzung). In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen 2.9 T€ (*Varianz* = 0.7) und das der Männer 3.1 T€ (*Varianz* = 0.4).

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?

- a) Schreiben Sie die Null- und die Alternativhypothese zu dieser Fragestellung auf.
- b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.



HYPOTHESENTEST: TESTSTATISTIK

Welt 0 (H_0)




Differenzen

Welt 1 (H_a)



HYPOTHESENTEST: TESTSTATISTIK

Wenn Nullhypothese = wahr, dann ist die wahre Verteilung:



Teststatistik = z-Wert der Differenz der Stichprobenmittelwerte

Beispiel (Fortsetzung). In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen 2.9 T€ (*Varianz* = 0.7) und das der Männer 3.1 T€ (*Varianz* = 0.4).

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?

b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.

Was wissen wir?

> Differenz Stichprobenmittel: $\bar{x}_f - \bar{x}_m = 2.9 - 3.1 = -0.2$

> Stichprobengrößen: $n_f = 35$ und $n_m = 44$

> Varianzen: $\sigma_f^2 = 0.7$ und $\sigma_m^2 = 0.4$

Gepoolter Standardfehler:

$$SE_{f-m} = \sqrt{\frac{\sigma_f^2}{n_f} + \frac{\sigma_m^2}{n_m}} = 0.17$$

b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.

Was wissen wir?

> Differenz Stichprobenmittel: $\bar{x}_f - \bar{x}_m = 2.9 - 3.1 = -0.2$

> Gepoolter Standardfehler: $SE_{f-m} = 0.17$

Teststatistik = z-Wert der Differenz der Stichprobenmittel:

$$\begin{aligned} z(\text{Differenz der Stichprobenmittel}) &= \frac{\text{Differenz der Stichprobenmittel} - \text{Pop. Diff. unter } H_0}{\text{Gepoolter Standardfehler}} \\ &= \frac{-0.2 - 0}{0.17} = -1.17 \end{aligned}$$

Basierend auf der Teststatistik können wir den p-Wert berechnen

P-Wert

Der *p-Wert* ist die Wahrscheinlichkeit (unter der Nullhypothese), dass die Teststatistik einen mindestens so extremen Wert annimmt wie denjenigen, der beobachtet wurde.

> Der p-Wert ist also eine bedingte Wahrscheinlichkeit:

$$P(\text{Teststatistik} = \text{wie beobachtet oder extremer} \mid \text{Nullhypothese wahr})$$

Beispiel (Fortsetzung). In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen 2.9 T€ (*Varianz* = 0.7) und das der Männer 3.1 T€ (*Varianz* = 0.4).

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?


b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.

Schritt 1. Teststatistik = $z(\text{Differenz Stichprobenmittel}) = -1.17$ ✓

Schritt 2. Berechne p-Wert.

HYPOTHESENTEST: P-WERT

$$\text{p-value} = P(z(\text{sample mean difference}) \leq -0.2 \mid H_0 \text{ true})$$



HYPOTHESENTEST: P-WERT

b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.

Schritt 1. Teststatistik = $z(\text{Differenz Stichprobenmittel}) = -1.17$ ✓

Schritt 2. Berechne p-Wert.

> Fläche Tabelle:

1.00	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577
1.10	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790
1.20	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980

> Damit:

$$p - \text{Wert} = 0.5 - 0.379 = 12.1\%$$

HYPOTHESENTEST: P-WERT

Was sagt uns p-Wert = 12.1%?

> Wenn $p\text{-Wert} \leq \text{konventionelle Obergrenzen} \rightarrow \text{Ablehnung Nullhypothese}$

p-Wert \leq Obergrenze α (*)	Interpretation
5%	Statistisch signifikant
1%	Stark statistisch signifikant

(*) Die Obergrenze α heißt **Signifikanzniveau**

$p\text{-Wert} = 12.1\% > 5\% \rightarrow \text{der Einkommensunterschied ist nicht statistisch signifikant}$

> Nullhypothese kann nicht abgelehnt werden \rightarrow keine Evidenz für einen Unterschied

› ARTEN VON HYPOTHESENTESTS

ARTEN VON HYPOTHESENTESTS: EINSEITIG UND ZWEISEITIG

- > *Einseitige Tests* haben eine Richtung: mehr/weniger, höher/niedriger, ...
- > *Zweiseitige Tests* haben keine Richtung: Unterschied ja/nein

Beispiel. Überprüfen Sie, ob die folgenden Tests einseitig oder zweiseitig sind:

Wir möchten wissen...	Alternativhypothese (H_a)	Nullhypothese (H_0)
ob Absolventen der HS Heilbronn im Schnitt (μ_{Alter}) älter sind als 26 (μ_0)	$\mu_{Alter} > 26$	$\mu_{Alter} \leq 26$
ob sich der Durchschnitts-IQ (μ_{IQ}) von Studierenden verändert hat (langfristiger Durchschnitt: $\mu_0 = 101$)	$\mu_{IQ} \neq 101$	$\mu_{IQ} = 101$
ob die Nachfrage (μ_{Nach}) für das Produkt einer Firma abgenommen hat (langfristiger Durchschnitt: $\mu_0 = 41'000$)	$\mu_{Nach} < 41'000$	$\mu_{Nach} > 41'000$

ARTEN VON HYPOTHESENTESTS: EINSEITIG UND ZWEISEITIG

- > *Einseitige Tests* haben eine Richtung: mehr/weniger, höher/niedriger, ...
- > *Zweiseitige Tests* haben keine Richtung: Unterschied ja/nein

Beispiel. Überprüfen Sie, ob die folgenden Tests einseitig oder zweiseitig sind:

	Wir möchten wissen...	Alternativhypothese (H_a)	Nullhypothese (H_0)
einseitig	ob Absolventen der HS Heilbronn im Schnitt (μ_{Alter}) älter sind als 26 (μ_0)	$\mu_{Alter} > 26$	$\mu_{Alter} \leq 26$
zweiseitig	ob sich der Durchschnitts-IQ (μ_{IQ}) von Studierenden verändert hat (langfristiger Durchschnitt: $\mu_0 = 101$)	$\mu_{IQ} \neq 101$	$\mu_{IQ} = 101$
einseitig	ob die Nachfrage (μ_{Nach}) für das Produkt einer Firma abgenommen hat (langfristiger Durchschnitt: $\mu_0 = 41'000$)	$\mu_{Nach} < 41'000$	$\mu_{Nach} > 41'000$

ARTEN VON HYPOTHESENTESTS: LINKSSEITIG UND RECHTSSEITIG

Einseitige Tests können links- oder rechtsseitig sein:

- > *Linksseitiger Test* (" $<$ " in Alternativhypothese) → Ablehnungsbereich/p-Wert links
- > *Rechtsseitiger Test* (" $>$ " in Alternativhypothese) → Ablehnungsbereich/p-Wert rechts

ARTEN VON HYPOTHESENTESTS: EINSTICHPROBEN- UND ZWEISTICHPROBEN

Vergleich Mittelwert **einer Population** mit einer Zahl → **Einstichproben-Test**

Beispiele. Fragen:

- > Hat sich der durchschnittliche IQ (bisher: $101 = \mu_0$) von Studierenden verändert?
- > Verbringen Studierende mehr als 4h / Tag ($= \mu_0$) in sozialen Netzwerken?

Vergleich von **zwei Populationen** → **Zweistichproben-Test**

Beispiele. Fragen:

- > Gibt es einen Unterschied im Einkommen von Frauen und Männern?
- > Sind Nutzer von sozialen Netzwerken glücklicher?

ARTEN VON HYPOTHESENTESTS: Z-TESTS

Tests werden oft nach der Verteilung der Teststatistik benannt

- > Z-Tests sind eine Familie von Tests mit z-verteilter Teststatistik (= standardnormalverteilt)

Wir fokussieren uns auf z-Tests, aber für den fortgeschrittenen Kurs:

- > Wenn die **Varianz unbekannt** ist und geschätzt werden muss → t-verteilte Teststatistik
- > Damit: t-Test → Einziger Unterschied zum Vorgehen beim z-Test:

Benutze t-Tabelle (statt z-Tabelle), um p-Wert / kritischen Wert zu bestimmen

Voraussetzungen Ein- und Zweistichproben Z-Test

- (Z1) Die Daten sind quantitativ (Intervall- oder Verhältnisskala).
- (Z2) Die Daten sind (in jeder Gruppe) normalverteilt.
- (Z3) Die Standardabweichung(en) der Population(en) ist (sind) bekannt.
- (Z4) Die Messungen innerhalb der Gruppen und zwischen den Gruppen sind unabhängig.
- (Z5) Keine Extremwerte (Outlier).

Anmerkung. Anteilswert-Test: Die ursprünglichen Merkmale können binär qualitativ sein

> Anteilswerte = Verhältnisskala

› BEISPIELAUFGABEN

EINSTICHPROBEN Z-TEST: BEISPIEL 1

Das Einstiegsgehalt von Absolventen der Hochschule Heilbronn betrug im langfristigen Durchschnitt ca. 31 T€/Jahr (Standardabweichung: 21 T€). Das durchschnittliche Einstiegsgehalt in einer Stichprobe mit 44 Absolventen ist 26 T€/Jahr.

Ist das ein Beleg, dass sich das Einstiegsgehalt signifikant verschlechtert hat?

- a) Handelt es sich um einen einseitigen oder zweiseitigen Test?
- b) Schreiben Sie die Null- und Alternativhypothese auf.
- c) Führen Sie einen Test durch, um die Frage zu beantworten.

EINSTICHPROBEN Z-TEST: BEISPIEL 2

Bei einem Online-Anbieter waren 54 der letzten 87 Kunden unter 30.

Ist dies Evidenz, dass die Kaufrate bei unter 30 Jährigen von 50% abweicht?

- a) Handelt es sich um einen einseitigen oder zweiseitigen Test?
- b) Schreiben Sie die Null- und Alternativhypothese auf.
- c) Führen Sie einen Test durch, um die Frage zu beantworten.

ZWEISTICHPROBEN Z-TEST

BEISPIEL 1

In einer Stichprobe mit 32 Mitarbeitern der Firma A und 35 Mitarbeitern der Firma B werden folgende Durchschnittsjahresgehälter gemessen: Firma A: 43 T€ (Varianz: 450.11), Firma B: 29.8 T€ (Varianz: 294.05).

Unterscheiden sich die Durchschnittsgehälter von Firma A und B (1%-Niveau)?

- a) Handelt es sich um einen einseitigen oder zweiseitigen Test?
- b) Schreiben Sie die Null- und Alternativhypothese auf.
- c) Führen Sie einen Test durch, um die Frage zu beantworten.

ZWEISTICHPROBEN Z-TEST

BEISPIEL 2

In einer Stichprobe sind 63 von 90 Frauen und 27 von 52 Männer umweltbewusst. Die Stichprobenvarianz entspricht jeweils ungefähr der Populationsvarianz.

Sind Frauen umweltbewusster?

- a) Handelt es sich um einen einseitigen oder zweiseitigen Test?
- b) Schreiben Sie die Null- und Alternativhypothese auf.
- c) Führen Sie einen Test durch, um die Frage zu beantworten.

Z-TESTS: ZUSAMMENFASSUNG

Test auf	Einstichproben-Tests Teststatistik	Zweistichproben-Tests Teststatistik
Mittelwert	$z = \frac{\bar{x} - \mu_0}{SE_{\bar{x}}}$	$z = \frac{\bar{x}_A - \bar{x}_B - \mu_0}{SE_{A-B}}$
Anteilswert	$z = \frac{\bar{p} - \pi_0}{\sqrt{\frac{\pi_0 (1 - \pi_0)}{n}}}$	$z = \frac{\bar{p}_A - \bar{p}_B - \pi_0}{SE_{A-B}}$

› TESTEN VON ZUSAMMENHÄNGEN

Im Falle von bivariaten Daten, möchten wir häufig überprüfen, ob ein Zusammenhang da ist

Zwei kategoriale Variablen → Chi²-Test

> Beantwortet die Frage, ob zwei Variablen stochastisch abhängig sind

Beispiel. Frage: Hängen Krebserkrankungen mit Rauchen zusammen?

Zwei numerische Variablen → Korrelationstest

> Beantwortet die Frage, ob zwei Variablen korreliert sind

Beispiel. Frage: Sind Marketingausgaben mit Verkaufsumsätzen korreliert?

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST (KATEGORIALE VARIABLEN)

Beispiel. Stichprobe mit 50 Männern und 52 Frauen. Jeder Teilnehmer gibt an, ob er/sie mehr als 2h/Tag auf Social-Media-Plattformen verbringt oder nicht:

	Männer	Frauen	Gesamt
$\leq 2h$	33	27	60
$> 2h$	17	25	42
Gesamt	50	52	102

Sind Geschlecht und Social-Media-Nutzungsdauer unabhängig (5%)?

- a) Schreiben Sie die Null- und die Alternativhypothese auf.
- b) Führen Sie einen Test durch, um die Frage zu beantworten.

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST (KATEGORIALE VARIABLEN)

Sind Geschlecht und Social-Media-Nutzungsdauer unabhängig (5%)?

a) Schreiben Sie die Null- und die Alternativhypothese auf.

H_0 : Social–Media–Nutzungsdauer und Geschlecht sind unabhängig

H_a : Social–Media–Nutzungsdauer und Geschlecht sind abhängig

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST (KATEGORIALE VARIABLEN)

Sind Geschlecht und Social-Media-Nutzungsdauer unabhängig (5%)?

b) Führen Sie einen Test durch, um die Frage zu beantworten.

Idee Chi2-Test:

- > Berechne erwartete Häufigkeiten bei Unabhängigkeit
- > Großer Unterschied erwartete und beobachtete Häufigkeit → Abhängigkeit
- > Kleiner Unterschied erwartete und beobachtete Häufigkeit → Unabhängigkeit

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST (KATEGORIALE VARIABLEN)

b) Führen Sie einen Test durch, um die Frage zu beantworten.

Schritt 1. Berechne erwartete Häufigkeiten bei Unabhängigkeit

Beispiel. Spalte 1, Zeile 1. Beobachtet:

> $P(\text{Geschlecht} = \text{Mann}) = 50/102$

> $P(\text{Nutzung} = "\leq 2h") = 60/102$

	M	F	Σ
$\leq 2h$	33	27	60
$> 2h$	17	25	42
Σ	50	52	102

Für Unabhängigkeit muss gelten (siehe stochastische Unabhängigkeit!):

$$P(G = \text{Mann}, N = "\leq 2h") = P(G = \text{Mann}) \times P(N = "\leq 2h") = \frac{50 \times 60}{102}$$

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST

b) Führen Sie einen Test durch, um die Frage zu beantworten.

Schritt 1. Berechne erwartete Häufigkeiten bei Unabhängigkeit

Beobachtete Häufigkeiten:

	M	F	Σ
$\leq 2h$	33	27	60
$> 2h$	17	25	42
Σ	50	52	102

Erwartete Häufigkeiten bei Unabhängigkeit:

	M	F	Σ
$\leq 2h$	$E_{11} = \frac{60 \cdot 50}{102} = 29.41$	$E_{12} = 30.59$	60
$> 2h$	$E_{21} = 20.59$	$E_{22} = 21.41$	42
Σ	50	52	102

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST

b) Führen Sie einen Test durch, um die Frage zu beantworten .

Schritt 1. Berechne erwartete Häufigkeiten bei Unabhängigkeit ✓

Schritt 2. Berechne Teststatistik:

$$\chi^2 = \sum \frac{(Beobachtet_{ij} - Erwartet_{ij})^2}{Erwartet_{ij}}$$

$$\chi^2 = \frac{(33 - 29.41)^2}{29.41} + \frac{(17 - 20.59)^2}{20.59} + \frac{(27 - 30.59)^2}{30.59} + \frac{(25 - 21.41)^2}{21.41} = 2.09$$

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST

b) Führen Sie einen Test durch, um die Frage zu beantworten.

Schritt 1. Berechne erwartete Häufigkeiten bei Unabhängigkeit ✓

Schritt 2. Berechne Teststatistik. $\chi^2 = 2.09$ ✓

Schritt 3. Bestimme kritischen Wert:

> Signifikanzniveau: $\alpha = 5\%$ (siehe Aufgabe)

> Freiheitsgrade (Degrees of freedom df):

Chi2-Tabelle:

DF / α	0.1	0.05	0.025
1	2.70554	3.84146	5.02389
2	4.60517	5.99146	7.37776
3	6.25139	7.81473	9.34840
4	7.77944	9.48773	11.14329
5	9.23636	11.07050	12.83250

$$df = (\text{Anzahl Zeilen} - 1) \times (\text{Anzahl Spalten} - 1) = 1$$

Kritischer Wert: $\chi^2_{0.05,1} \approx 3.84$

TESTEN VON ZUSAMMENHÄNGEN: CHI2-TEST

b) Führen Sie einen Test durch, um die Frage zu beantworten.

Schritt 1. Berechne erwartete Häufigkeiten, wenn unabhängig ✓

Schritt 2. Berechne Teststatistik. $\chi^2 = 2.09$ ✓

Schritt 3. Bestimme kritischen Wert. Kritischer Wert = 3.84 ✓

Schritt 4. Vergleiche Teststatistik und kritischer Wert (immer rechtsseitig):

$$\chi^2 = 2.09 < 3.84 = \textit{kritischer Wert}$$

Wir können die Nullhypothese nicht auf 5% Niveau ablehnen

→ keine Evidenz für Abhängigkeit

Null- und Alternativhypothese	Teststatistik
<p>$H_0: X, Y$ stochastisch unabhängig</p> <p>$H_a: X, Y$ stochastisch abhängig</p>	$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$ <ul style="list-style-type: none">> O_{ij}: Beobachtete Häufigkeit Zeile i, Spalte j> E_{ij}: Erwartete Häufigkeit Zeile i, Spalte j

Voraussetzungen Chi²-Unabhängigkeitstest

- (C1) Beide Variablen sind kategorial (Nominal- oder Ordinalskala).
- (C2) Die Stichprobe ist hinreichend groß ($n > 50$).
- (C3) Die erwarteten Zellhäufigkeiten sind > 5 .
- (C4) Die Messungen innerhalb der Gruppen und zwischen den Gruppen sind unabhängig.

› APPENDIX: KRITISCHE WERTE

Eine Alternative zum p-Wert sind sogen. *kritische Werte*

- > Beide Wege sind äquivalent

Vorgehen mit kritischen Werten:

- > Fixiere ein Signifikanzniveau (5%, 1%)
- > Bestimme Bereich für Teststatistik, um das Signifikanzniveau zu erreichen

Beispiel (Fortsetzung). In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen 2.9 T€ (*Varianz* = 0.7) und das der Männer 3.1 T€ (*Varianz* = 0.4).

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?

b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.


Schritt 1. Teststatistik = $z(\text{Differenz Stichprobenmittel}) = -1.17$ ✓

Schritt 2. Berechne kritischen Wert für Signifikanzniveau 5%.

HYPOTHESENTEST: KRITISCHE WERTE

Schritt 2. Berechne kritischen Wert für Signifikanzniveau 5%.

> Kritischer Wert ist links (H_a : Stichprobenmittel Frauen < Stichprobenmittel Männer)



KRITISCHE WERTE

> Z-Wert für 0.45:

$$z_5 = 1.645$$


> Linksseitig:

$$-z_5 = -1.645$$

Z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.10	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.20	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.30	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.40	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.50	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.60	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.70	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.80	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.90	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.00	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.10	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.20	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.30	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.40	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.50	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.60	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.70	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.80	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.90	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767
2.00	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.10	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.20	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.30	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.40	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936
2.50	0.4938	0.4940	0.4941	0.4943	0.4945	0.4946	0.4948	0.4949	0.4951	0.4952
2.60	0.4953	0.4955	0.4956	0.4957	0.4959	0.4960	0.4961	0.4962	0.4963	0.4964
2.70	0.4965	0.4966	0.4967	0.4968	0.4969	0.4970	0.4971	0.4972	0.4973	0.4974
2.80	0.4974	0.4975	0.4976	0.4977	0.4977	0.4978	0.4979	0.4979	0.4980	0.4981
2.90	0.4981	0.4982	0.4982	0.4983	0.4984	0.4984	0.4985	0.4985	0.4986	0.4986
3.00	0.4987	0.4987	0.4987	0.4988	0.4988	0.4989	0.4989	0.4989	0.4990	0.4990

HYPOTHESENTEST: KRITISCHE WERTE

Schritt 3. Vergleiche Teststatistik und kritische Werte:



- > Teststatistik: $z(\text{Differenz}) = -1.17 > -z_5 = -1.645$
- > Damit können wir die Nullhypothese nicht auf 5% Niveau ablehnen

P-WERT UND KRITISCHE WERTE: ZUSAMMENFASSUNG RECHENSCHRITTE

P-Wert:

1. Berechne Teststatistik (z-Wert)
2. Berechne p-Wert
3. Vergleiche p-Wert mit konventionellen Obergrenzen für das Signifikanzniveau

Kritische Werte:

1. Berechne Teststatistik (z-Wert)
2. Berechne kritischen Wert für α
3. Vergleiche Teststatistik mit kritischem Wert

THE END!



Please refer any questions to:
Prof. Dr. Florian Kauffeldt
Faculty of International Business
Florian.kauffeldt@hs-heilbronn.de