HOCHSCHULE HEILBRONN

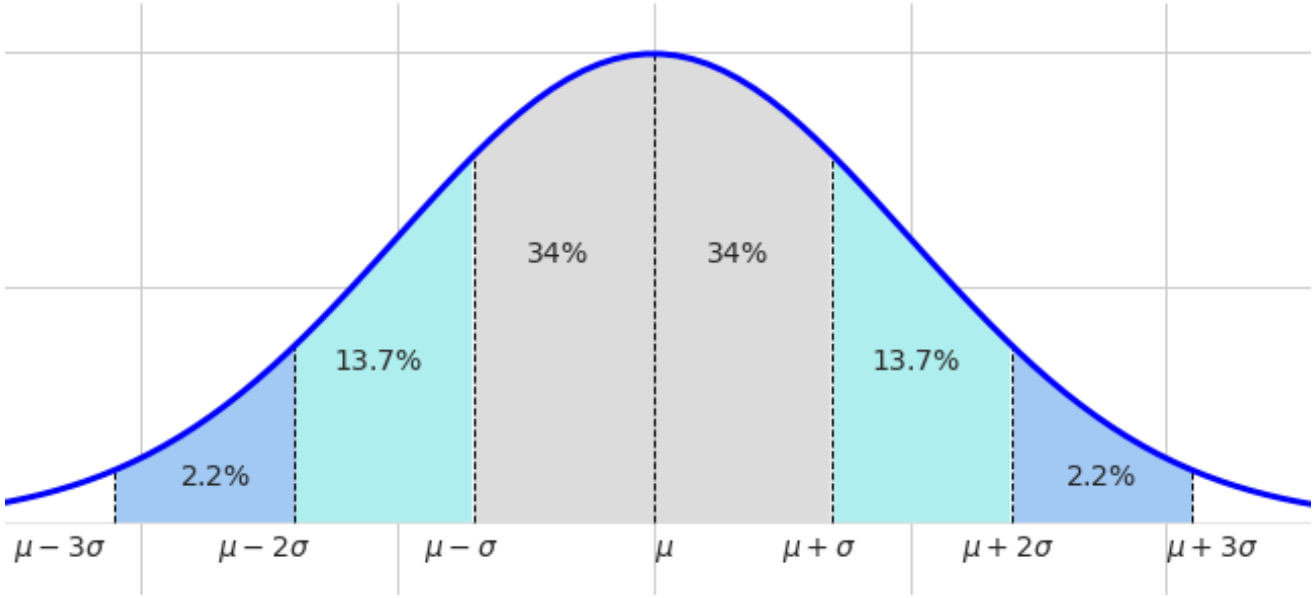

› STATISTIK

HOCHSCHULE HEILBRONN

› EINFÜHRUNG

Statistik | Prof. Dr. Florian Kauffeldt

VORLESUNG: BEDEUTUNG BERUF

HOCHSCHULE HEILBRONN

Warum ist Wissen über Datenanalyse wichtig für ihr künftiges Arbeitsleben?

1. Grundlagenwissen Statistik ist obligatorisch für Führungspositionen
2. Tendenz steigend aufgrund von neue Technologien wie z.B. Machine Learning

Warum?

> Unternehmen: Bestmöglichen Entscheidungen basierend auf vorliegenden Daten

> Zunehmende Computerisierung: Datenverarbeitung in Echtzeit

ZITATE GESCHÄFTSWELT

HOCHSCHULE HEILBRONN

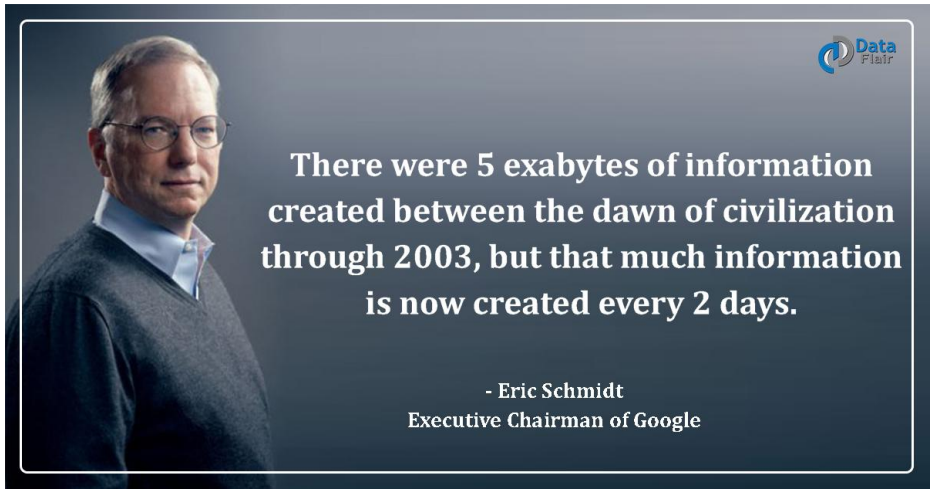

VORLESUNG: VERBINDUNG ZU ANDEREN KURSEN

HOCHSCHULE HEILBRONN

- Sozialwissenschaftliche Forschung ist häufig empirisch (basiert auf Daten)
- Unabdingbar, um wissenschaftliche Forschungsarbeiten zu verstehen
- Methodologische Verbindung zu den meisten anderen Vorlesungen
- Fundamentale Instrumente für empirisches Arbeiten

WARUM STATISTIK?

HOCHSCHULE HEILBRONN

Gender Pay Gap

= Differenz durchschnittlicher Verdienst Frauen und Männer geteilt durch Verdienst Männer

> Fakt:

Frauen verdienen 18 % weniger je Stunde als Männer (2020)

(Quelle: https://www.destatis.de/DE/Themen/Arbeit/Arbeitsmarkt/Qualitaet-Arbeit/Dimension-1/gender-pay-gap.html)

> Interpretation: "Systematische Benachteiligung von Frauen"

Ist das zwangsläufig so?

WARUM STATISTIK?

HOCHSCHULE HEILBRONN

> Fakt:

Heilbronn ist die Stadt mit dem höchsten Durchschnittseinkommen in Deutschland

(siehe z.B.: https://de.wikipedia.org/wiki/Liste_der_Landkreise_nach_Einkommen)

> Interpretation: "Heilbronn ist die reichste Stadt Deutschlands"

Stimmt das?

WARUM STATISTIK?

HOCHSCHULE HEILBRONN

Anhand von Statistik konnte ein Doktor (Shipman) überführt werden

> Er hat mindestens 215 seiner Patienten mit einer Opiat-Überdosis ermordet

> Meiste Tote am frühen Nachmittag

> Nach seinen Hausbesuchen…

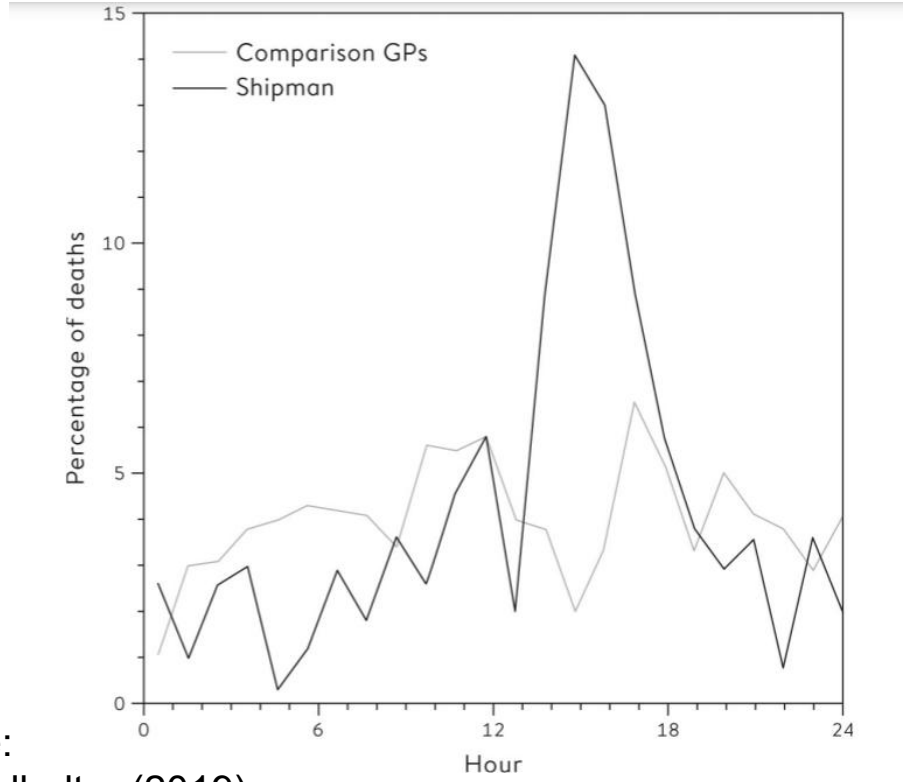

Quelle:
Spiegelhalter (2019)

WARUM STATISTIK?

HOCHSCHULE HEILBRONN

Basierend auf einer wahren Geschichte (anderer Zeit, Ort und Partei)

(siehe https://www.rwi-essen.de/unstatistik/)

- Texas: 38% der Population fahren einen SUV
- 57% sind Republikaner
- Eine Umfrage unter SUV Fahrern ergibt, dass 78% für die Republikaner gestimmt haben

Zeitungsartikel: „78% der Republikaner sind nicht umweltbewusst"

Was ist falsch?

WARUM STATISTIK?

HOCHSCHULE HEILBRONN

> Fakt:

Fakultät IB: Ca. 7 der 10 besten Studierenden in Statistik waren weiblich

Sind Frauen besser in Statistik als Männer?

VORLESUNG: ZUSATZMATERIAL

HOCHSCHULE HEILBRONN

- *BasicMath.pdf* enthält mathematische Grundlagen
- *StatisticalTables.pdf* enthält statistische Tabellen (z.B. Standardnormalverteilung)
- *AppendixStatistics.pdf* enthält wichtige statistische Formeln

VORLESUNG: VORKENNTNISSE MATHEMATIK

HOCHSCHULE HEILBRONN

- Erforderlichen mathematischen Kenntnisse: Gymnasialniveau Mathematik
- Es wird vorausgesetzt, dass Sie diese Konzepte kennen und verstehen
- Ansonsten: Eigenständige Nacharbeit der Konzepte
- Hilfreiches Dokument *Basic Math.pdf*!

HOCHSCHULE HEILBRONN

MATHEMATICS FOR STATISTICS

©Florian Kauffeldt

VORLESUNG: QUELLEN

HOCHSCHULE HEILBRONN

AUER, B. & ROTTMANN, H. (2015). Statistik und Ökonometrie für Wirtschaftswissenschaftler. Leipzig: Springer

HÄRDLE, W.K., KLINKE, S., & RÖNZ, B. (2015). Introduction to Statistics. Heidelberg: Springer

KOSFELD, R., ECKEY, H. & TÜRCK, M. (2019). Wahrscheinlichkeitsrechnung und induktive Statistik. Wiesbaden: Springer

MATHAI, A.M. & HAUBOLD, H.J. (2018). Probability and Statistics. De Gruyter: Berlin

VORLESUNG: INHALT

HOCHSCHULE HEILBRONN

1. Deskriptive Statistik

2. Wahrscheinlichkeitstheorie

3. Inferenzstatistik / Schließende Statistik

THE END!

Please refer any questions to:
Prof. Dr. Florian Kauffeldt
Faculty of International Business
florian.kauffeldt@hs-heilbronn.de

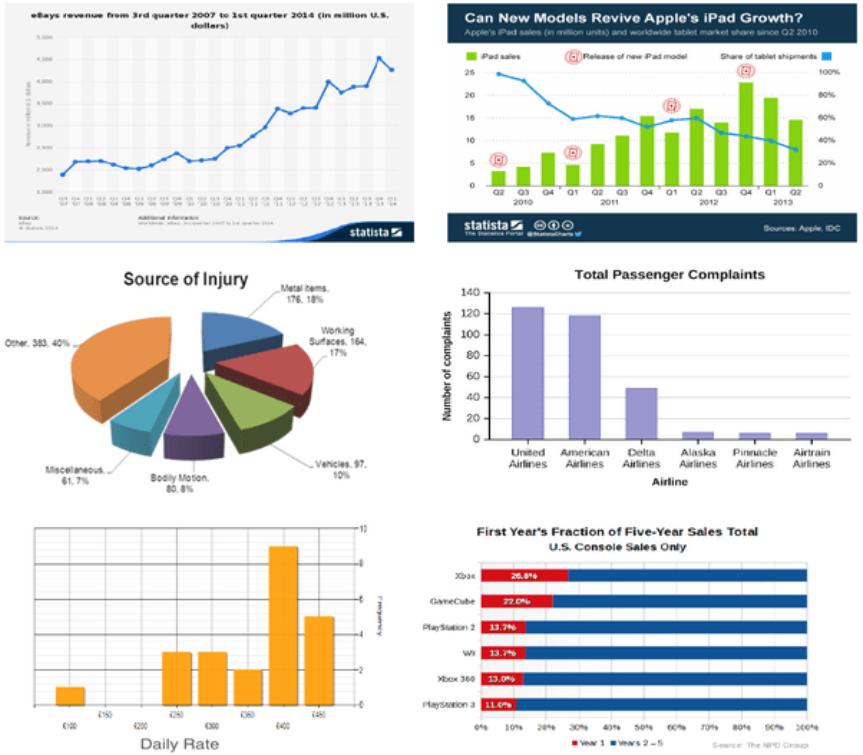

HOCHSCHULE HEILBRONN

› DESKRIPTIVE STATISTIK

Statistik | Prof. Dr. Florian Kauffeldt

TEILGEBIETE DER STATISTIK

HOCHSCHULE HEILBRONN

Statistik

Deskriptive Statistik	Inferenzstatistik
> Beschreibung von Daten	> Induktive Rückschlüsse basierend auf Daten

WAS IST DESKRIPTIVE STATISTIK?

HOCHSCHULE HEILBRONN

- Ziele Deskriptive Statistik: Beschreibung von Daten (keine induktiven Schlüsse)

- Deskriptive Statistik: Methoden, um Daten zusammenzufassen und zu visualisieren

DESKRIPTIVE STATISTIK
INHALT

HOCHSCHULE HEILBRONN

1. Daten und Messniveaus

2. Statistiken und Parameter

3. Univariate Statistiken
   - Lagemaße (Modus, Median, Mittelwert, Quantile)
   - Streuungsmaße (Standardabweichung, Varianz)

4. Multivariate Statistiken
   - Kovarianz
   - Korrelationskoeffizient

› DATEN

WAS SIND DATEN?

HOCHSCHULE HEILBRONN

Daten sind Merkmale von Objekten, die durch Beobachtung erhoben werden

Beispiele Daten

Numerische Daten
(auch: quantitativ oder metrisch)

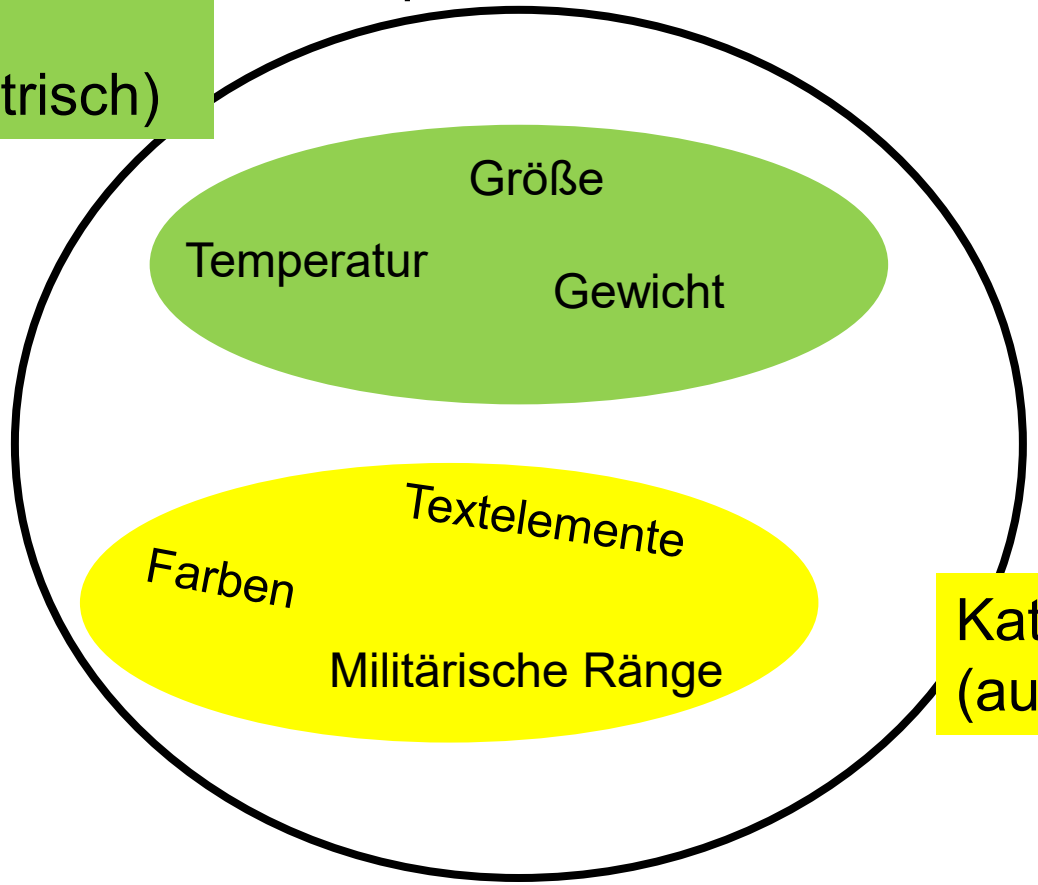

Kategoriale Daten
(auch: qualitative Daten)

DATEN: MESSNIVEAUS

HOCHSCHULE HEILBRONN

Art	Skala	Messung von	Unter-scheiden	Sor-tieren	Ab-stände	Verhält-nisse	Beispiel
Kategorial	Nominal	Kategorien ohne Rangfolge	✓	X	X	X	Farben
	Ordinal	Kategorien mit Rangfolge	✓	✓	X	X	Militär-ränge
Numerisch	Intervall	Zahlen ohne natürlichen Nullpunkt	✓	✓	✓	X	Temp. °C
	Verhältnis	Zahlen mit natürlichen Nullpunkt	✓	✓	✓	✓	Temp. Kelvin

DATEN: MESSNIVEAUS

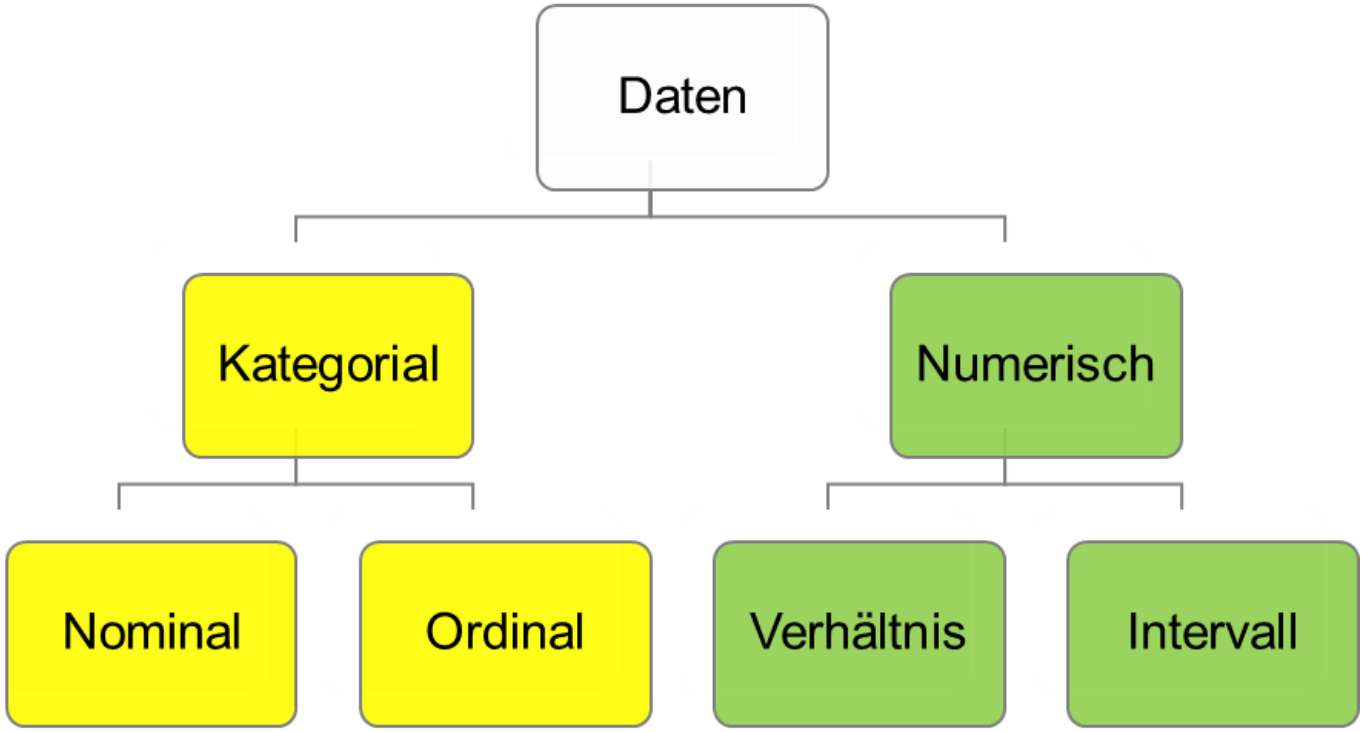

DATEN: MESSNIVEAUS

HOCHSCHULE HEILBRONN

Beispiel. Wettrennen.

Erfassung auf Skala

Teilnehmer	Nominal	Ordinal	Verhältnis
A	> Teilgenommen	> 2. Platz	> 16.2 Sek.
B	> Teilgenommen	> 1. Platz	> 11.3 Sek.
C	> Disqualifiziert	> -	> -
D	> Teilgenommen	> 3. Platz	> 16.9 Sek.

DATEN: MESSNIVEAUS

HOCHSCHULE HEILBRONN

Daten	Art	Skala
Körpergröße (182cm, 167cm, …)		
Geschlecht		
IQ (100, 99, 116, 89,…)		
Prozentsatz korrekter Testantworten		
Platzierung in einem Schönheitswettbewerb		
Reiseziele (New York, Berlin)		
Zustimmungsgrade (stimmte nicht zu, …, stimme voll zu)		
Jahreszahlen (1640, 1920, 2020,…)		

DATENARTEN: DISKRET UND STETIG

HOCHSCHULE HEILBRONN

Numerische Daten

Diskret

Bestimmte Zwischenwerte

Beispiel: Anzahl Studenten zw. 63 und 65
64

Stetig

Beliebige Zwischenwerte

Beispiel: Größe zwischen 1,70 und 1,80
1,7000001; 1,751111; 1,78787878; ….

DATENARTEN: UNIVARIAT UND MULTIVARIAT

HOCHSCHULE HEILBRONN

Daten

Univariat

Messen ein **einziges** Merkmal

Beispiel: Größe

Multivariat

Messen **mehrere** Merkmale

Beispiel: Größe + Gewicht

DATENERHEBUNG: ZUFALLSSTICHPROBEN

HOCHSCHULE HEILBRONN

Erhebung von Daten über **Zufallsstichproben:**

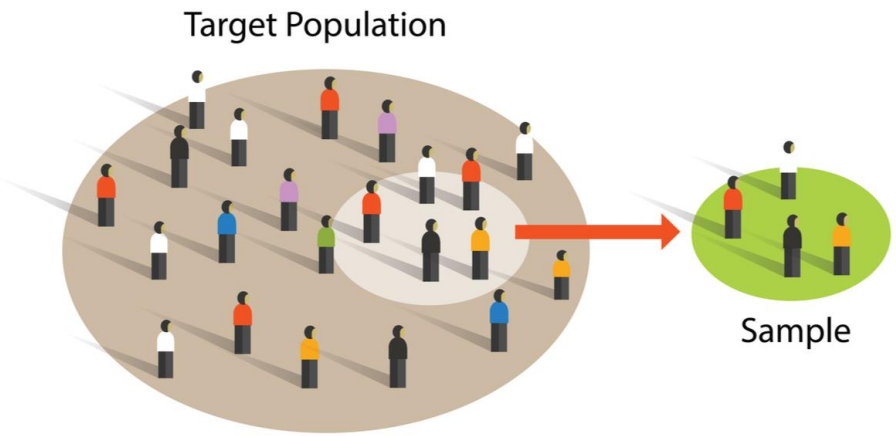

> Stichprobe = Teilmenge einer Population (= Menge der Merkmalsträger)

> Zufall = Jedes Element der Population wird mit gleicher Wahrscheinlichkeit gezogen

› STATISTIKEN UND PARAMETER

STATISTIKEN UND PARAMETER

HOCHSCHULE HEILBRONN

!Wichtige Unterscheidung!

Statistik	Parameter
- Kennzahl einer Stichprobe - Bekannt	- Kennzahl einer Population - I.d.R. unbekannt - Schätzung basierend auf Stichprobe

STATISTIKEN UND PARAMETER: NOTATIONELLE UNTERSCHEIDUNG

HOCHSCHULE HEILBRONN

- **Lateinische** Symbole → **Statistiken**

- **Griechische** Symbole → **Parameter**

Beispiel. Mittelwert

- $\bar{x}$ = Stichprobenmittelwert

- μ = Populationsmittelwert

STATISTIKEN UND PARAMETER: ARTEN (AUSBLICK)

HOCHSCHULE HEILBRONN

Datenart	Messung von	Statistik / Parameter
Univariat	Lage	Mittelwert, Modus, Median, Quantile
	Streuung	Varianz, Standardabweichung
Multivariat	Zusammenhang	Kovarianz, Korrelationskoeffizient (Pearson, Spearman Rho)

› UNIVARIATE STATISTIKEN / PARAMETER

Lagemaße = Typische Werte einer Verteilung

LAGEMAßE CHARAKTERISIEREN DIE LAGE DER VERTEILUNG

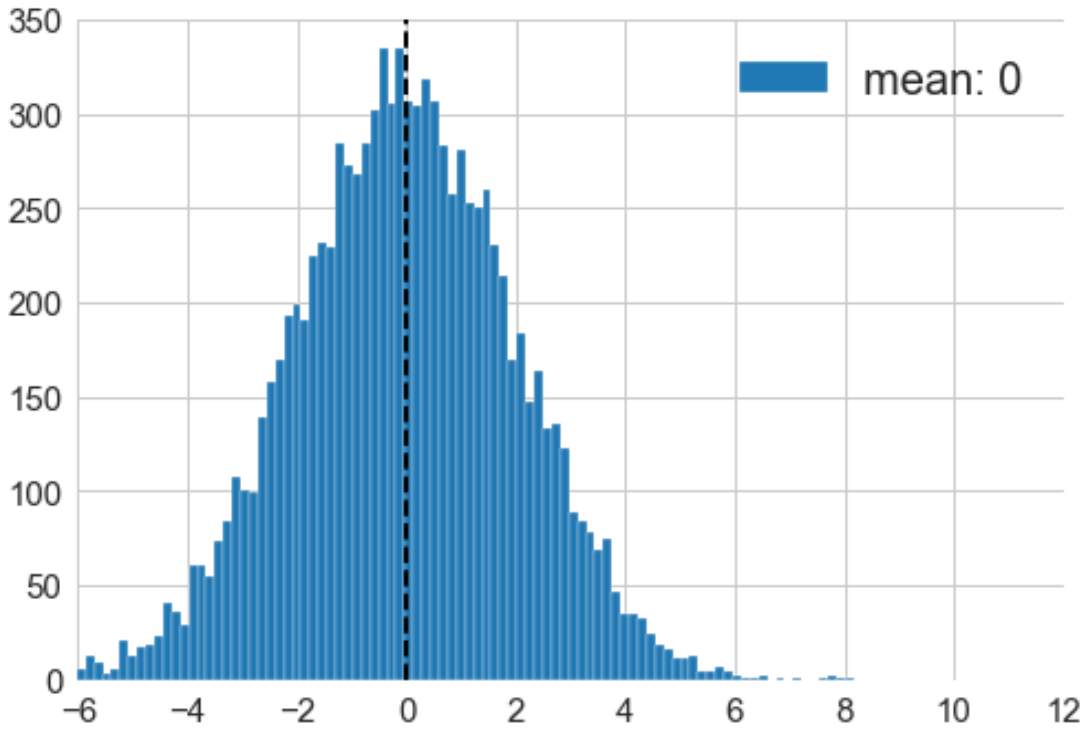

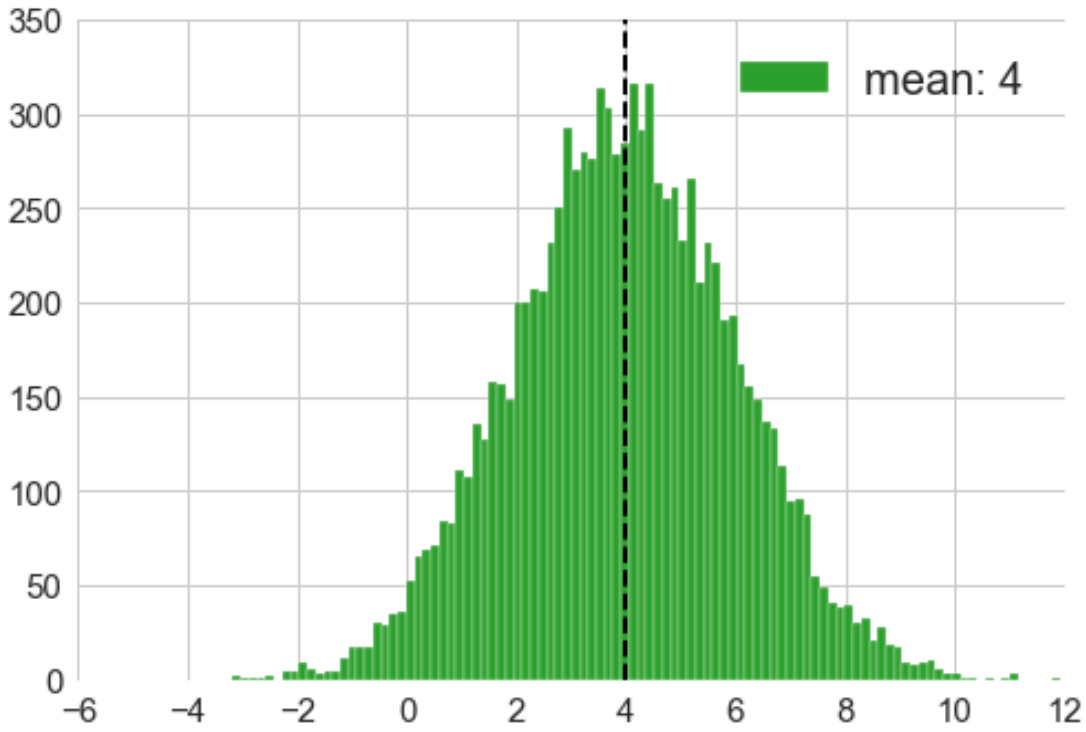

LAGEMAßE: MODUS, MEDIAN, MITTELWERT

HOCHSCHULE HEILBRONN

Gegeben ein Datensatz $(x_1, \dots, x_n)$ der Länge n:

- $Modus$ (auch Modalwert) = Wert, der am häufigsten vorkommt
- $Median$ = Wert in der Mitte, wenn die Werte von klein nach groß sortiert wurden
- $Mittelwert$ = Arithmetisches Mittel:

$$Mittelwert = \frac{x_1 + \cdots + x_n}{n}$$

LAGEMAßE: QUANTILE

HOCHSCHULE HEILBRONN

$i - Quantil$ =

> Wert unter dem $i\%$ der Werte einer Stichprobe liegen (und $(1 - i)\%$ darüber),

  wenn die Werte von klein nach groß sortiert wurden

Beispiele.

> 50-Quantil → 50% darunter, 50% darüber → Median

> 25-Quantil → 25% darunter, 75% darüber → 1. Quartil

LAGEMAßE: QUARTILE (25-, 50- UND 75-QUANTIL)

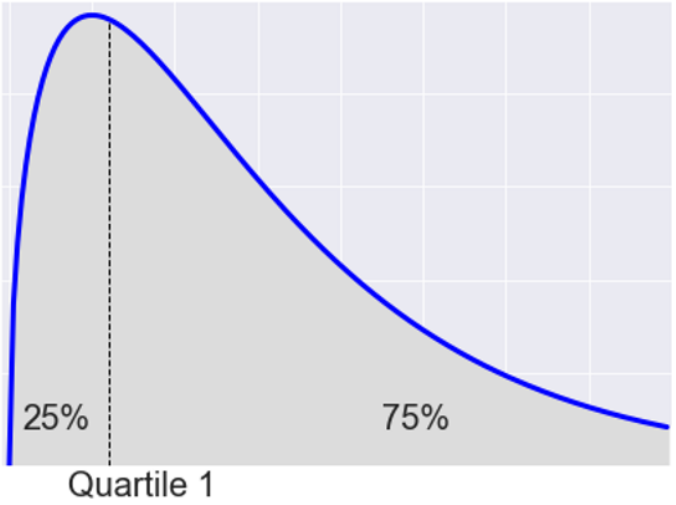

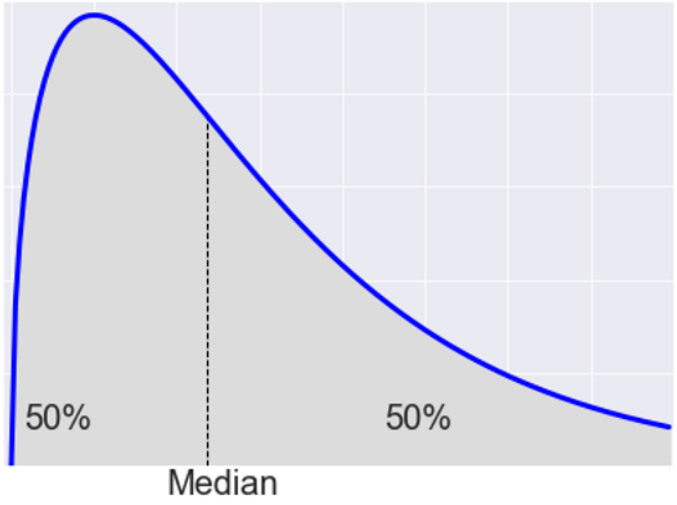

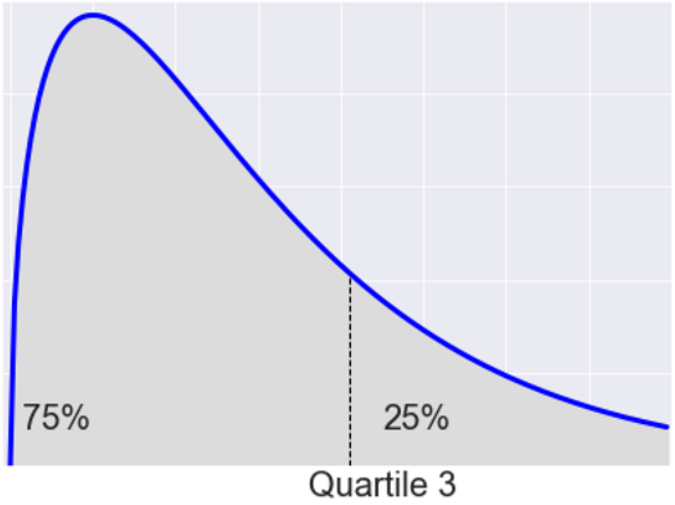

LAGEMAßE: ERFORDERLICHE MESSNIVEAUS

HOCHSCHULE HEILBRONN

- Der häufigste Wert (Modalwert) kann immer berechnet werden
- Quantile setzen eine Ordnung des Datensatzes voraus → Mindestens ordinale Daten
- Der Mittelwert kann nur für numerische Daten berechnet werden

WARUM STREUUNGSMAßE?

HOCHSCHULE HEILBRONN

Niedrige Streuung um den Mittelwert

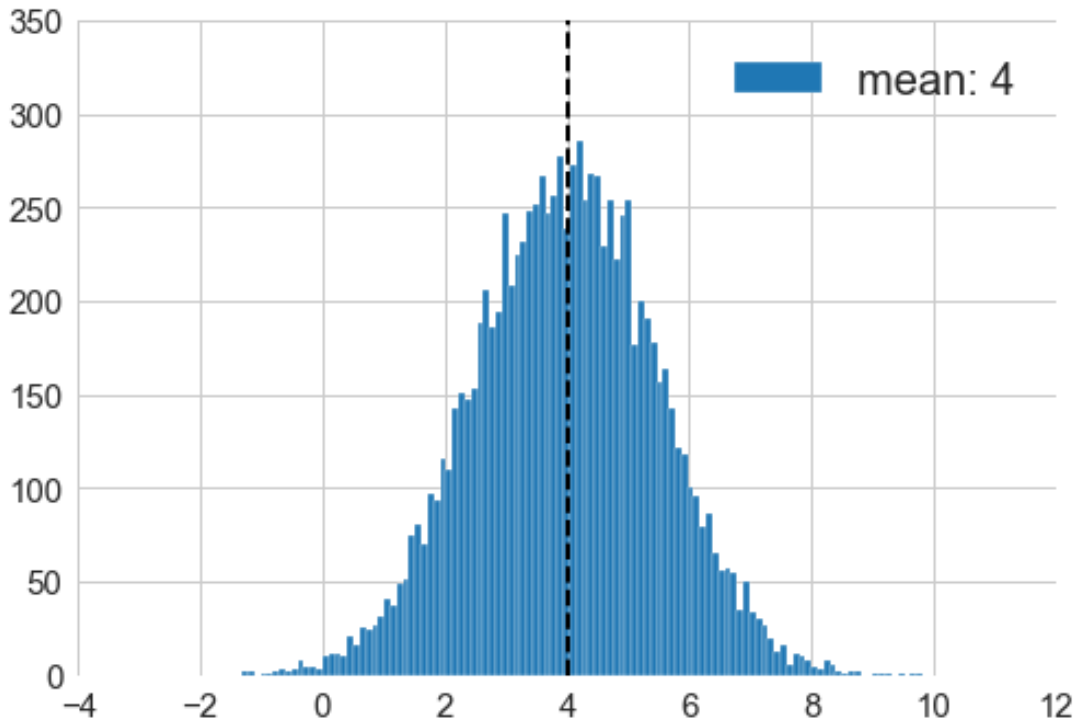

Hohe Streuung um den Mittelwert

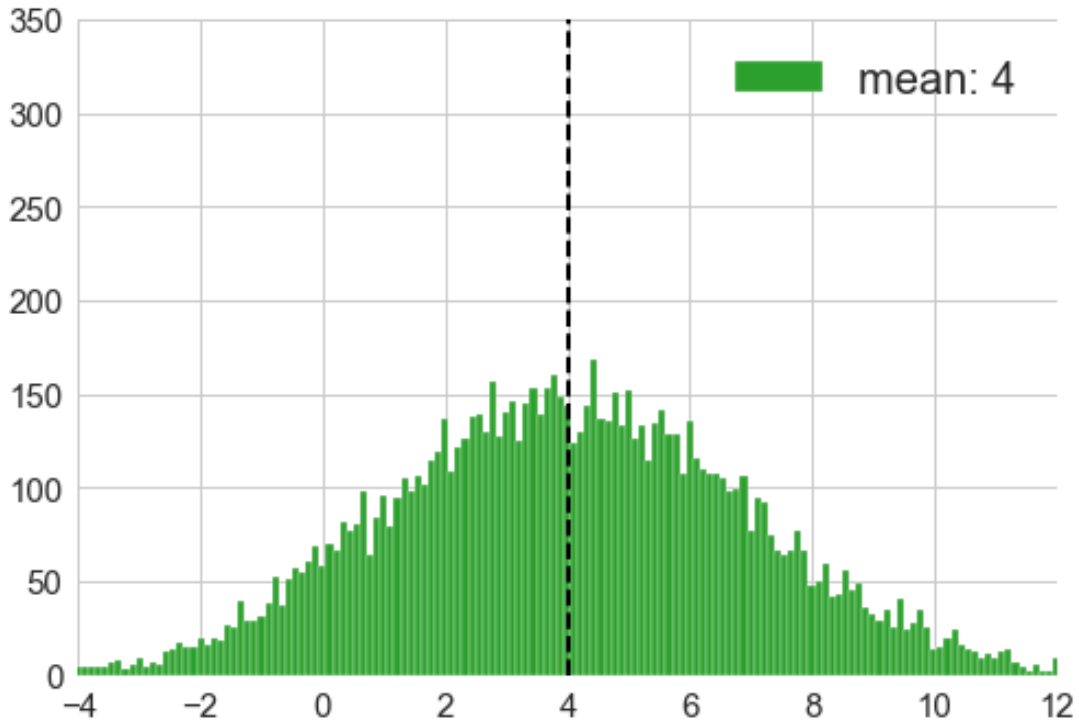

Beide Verteilungen haben den gleichen Mittelwert (4), aber streuen unterschiedlich

Streuungsmaße = Schwankungsbreite Verteilung

STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

HOCHSCHULE HEILBRONN

Maß für die Streuung der Daten um ihren Mittelwert

> Durchschnitt der Summe der Abweichungen vom Mittelwert?

Beispiel.

	$Gewicht_i$	$Gewicht_i - Mittelwert$
	55	-17
	78	6
	91	19
	62	-10
	74	2
Summe / n	$Mittelwert = 72$	$0/5 = 0$

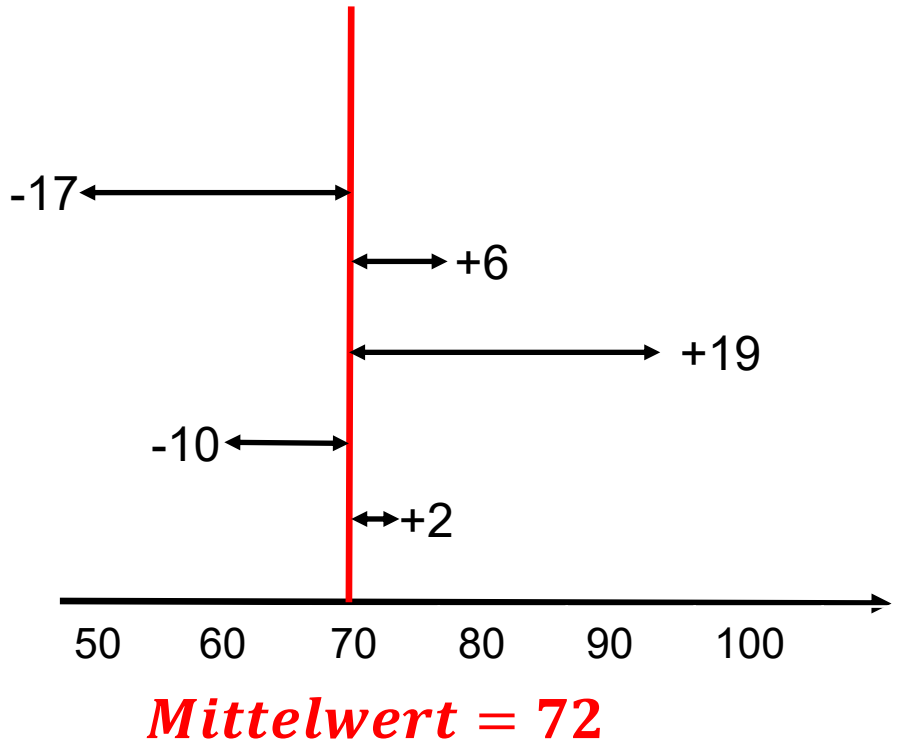

STREUUNGSMAßE: MESSEN STREUUNG UM DEN MITTELWERT

HOCHSCHULE HEILBRONN

Varianz = durchschnittliche **quadratische** Abweichung vom Mittelwert

Beispiel.

	Beobachtung: $Gewicht_i$	Abweichungen: $Gewicht_i - Mittelwert$	Quadrierte Abweichungen: $(Gewicht_i - Mittelwert)^2$
	55	-17	289
	78	6	36
	91	19	361
	62	-10	100
	74	2	4
Summe / n	$Mw. = 72$	0	$\frac{(Gewicht_1 - Mittelw.)^2 + \cdots + (Gewicht_5 - Mittelw.)^2}{n} = 158$

Varianz

STREUUNGSMAßE: INTERPRETATION

HOCHSCHULE HEILBRONN

Varianz = 158 Kg^2

> Was bedeutet das?

Standardabweichung = $\sqrt{158}\,Kg$ = 12,6 Kg

STREUUNGSMAßE: FORMELN

HOCHSCHULE HEILBRONN

Sei $(x_1, \dots, x_n)$ ein Datensatz der Länge n:

> $Varianz$ = durchschnittliche quadratische Abweichung vom Mittelwert:

$$Varianz = \frac{(x_1 - Mittelwert)^2 + \cdots + (x_n - Mittelwert)^2}{n}.$$

> $Standardabweichung$ = positive Quadratwurzel der Varianz:

$$Standardabweichung = \sqrt{Varianz}$$

STREUUNGSMAßE: ERFORDERLICHE MESSNIVEAUS

Für die Berechnung von Varianz und Standardabweichung braucht man den Mittelwert

→ können nur für numerische Daten berechnet werden

› MULTIVARIATE STATISTIKEN / PARAMETER

ZUSAMMENGHANGSMAßE

HOCHSCHULE HEILBRONN

Häufig möchte man messen, ob zwei Merkmale eine Beziehung haben

Beispiel. Zusammenhang zwischen Größe und Gewicht.

Person i	1	2	3	4	5
Height in cm (x_i)	172	175	177	186	191
Weight in kg (y_i)	67	74	72	81	86

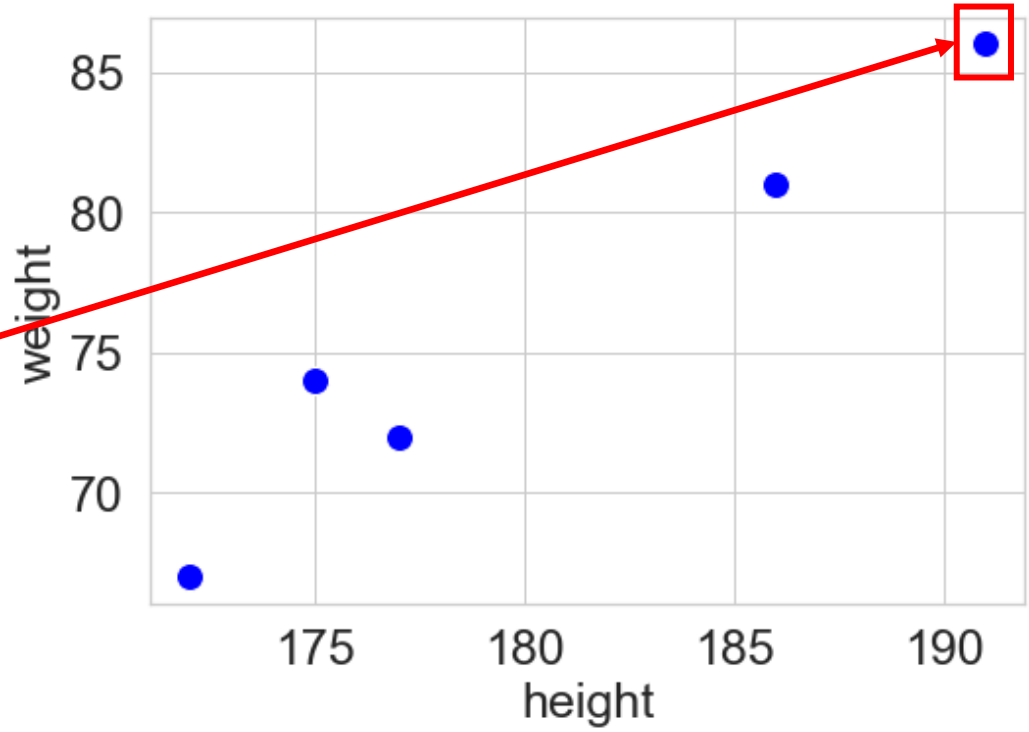

ZUSAMMENHANGSMAß: KOVARIANZ

Kovarianz: Misst Stärke der linearen Beziehung zwischen 2 Merkmalen X und Y

Positive Kovarianz:
$X \uparrow \rightarrow Y \uparrow$

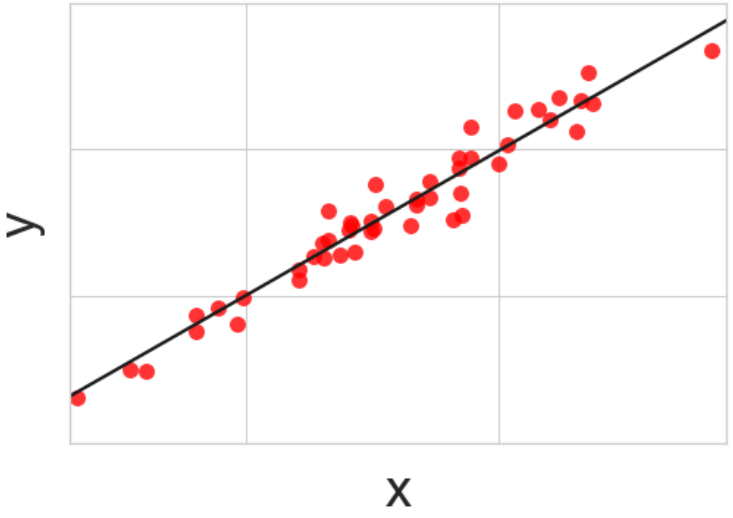

Kovarianz nahe 0:
Keine lin. Beziehung

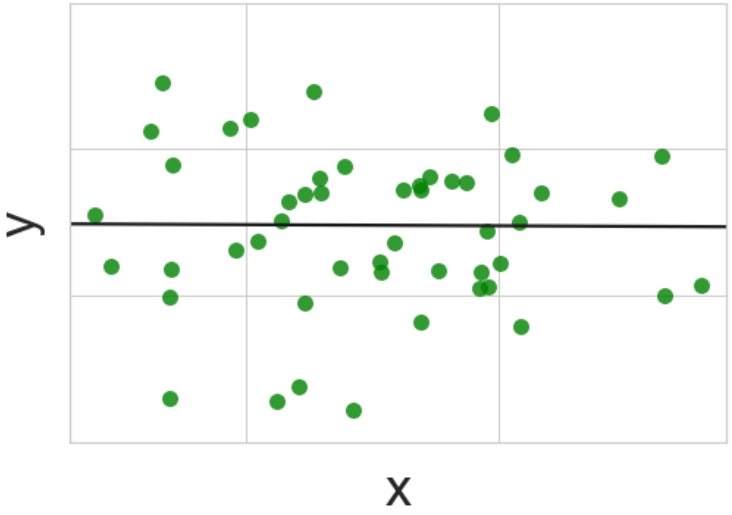

Negative Kovarianz:
$X \uparrow \rightarrow Y \downarrow$

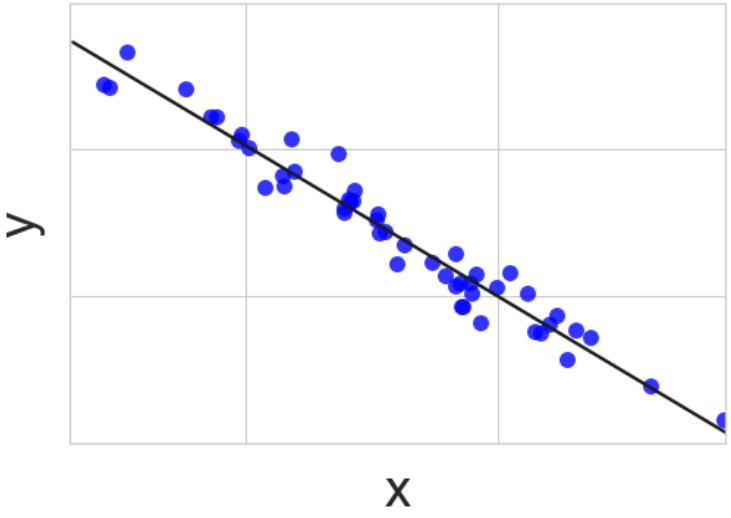

ZUSAMMENHANGSMAß: KOVARIANZ

HOCHSCHULE HEILBRONN

Beispiel (Fortsetzung). Beziehung zw. Größe und Gewicht.

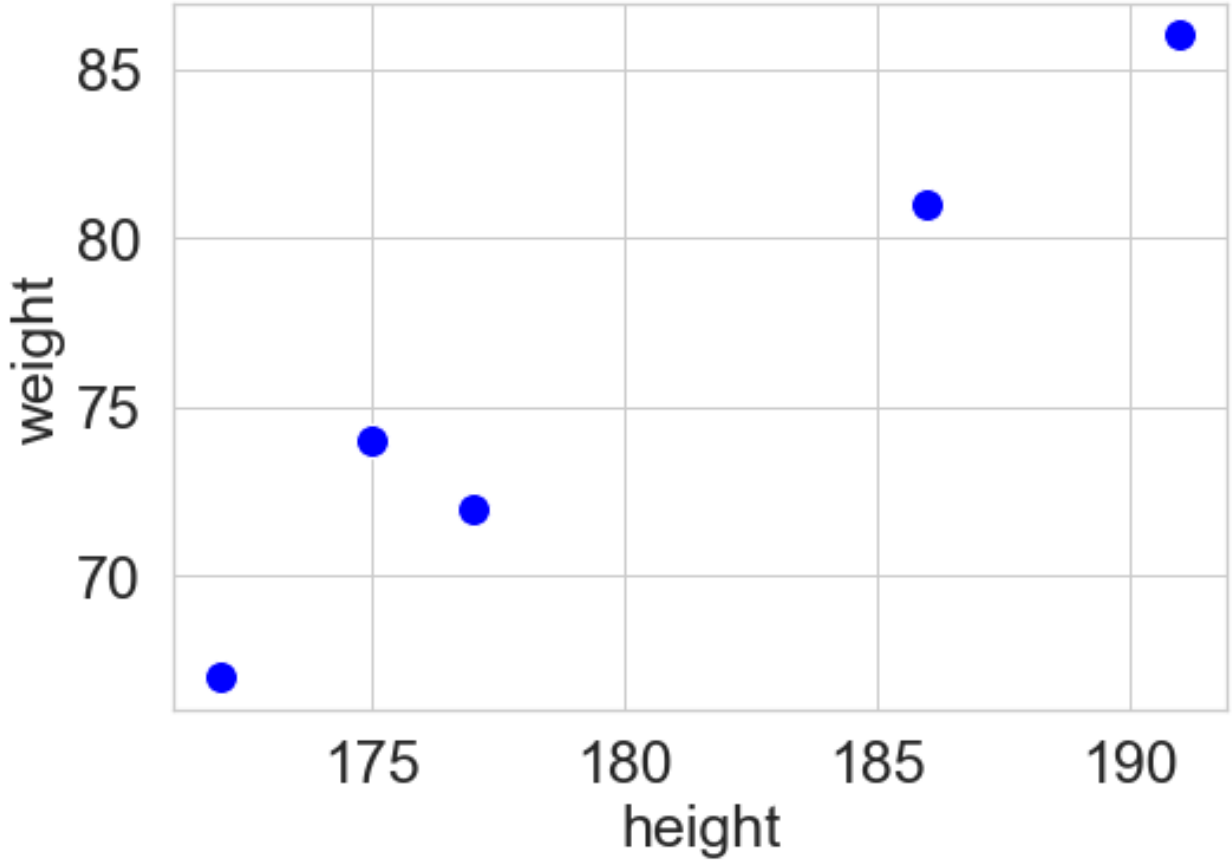

ZUSAMMENHANGSMAß: KOVARIANZ

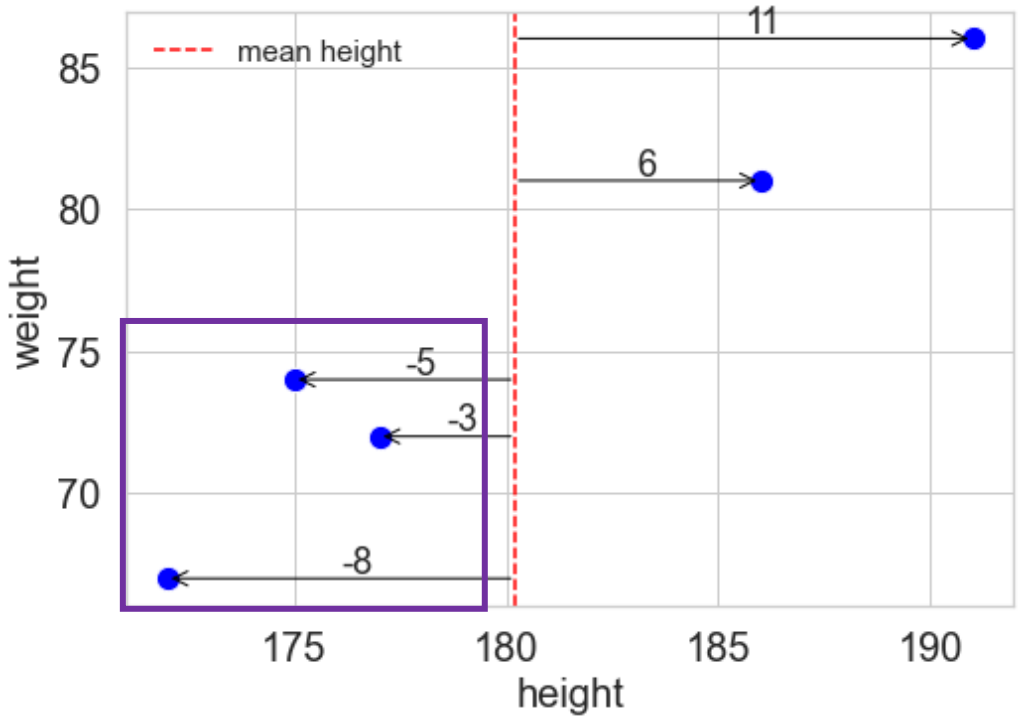

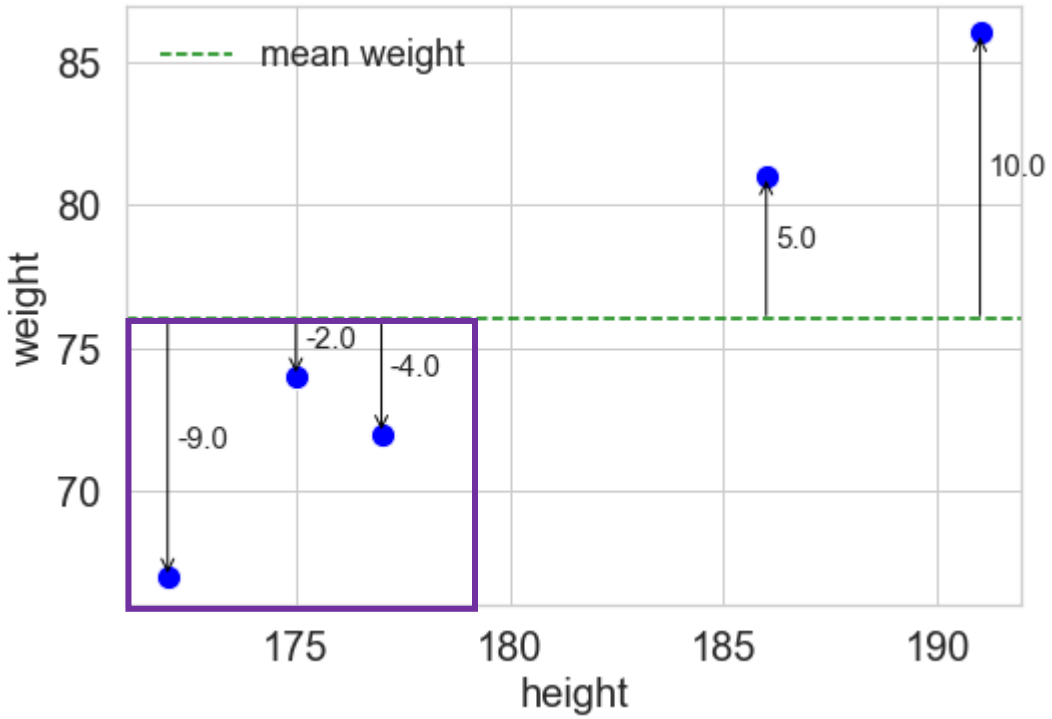

Gewicht und Größer der **ersten 3 Personen** liegen **unter dem Durchschnitt**

ZUSAMMENHANGSMAß: KOVARIANZ

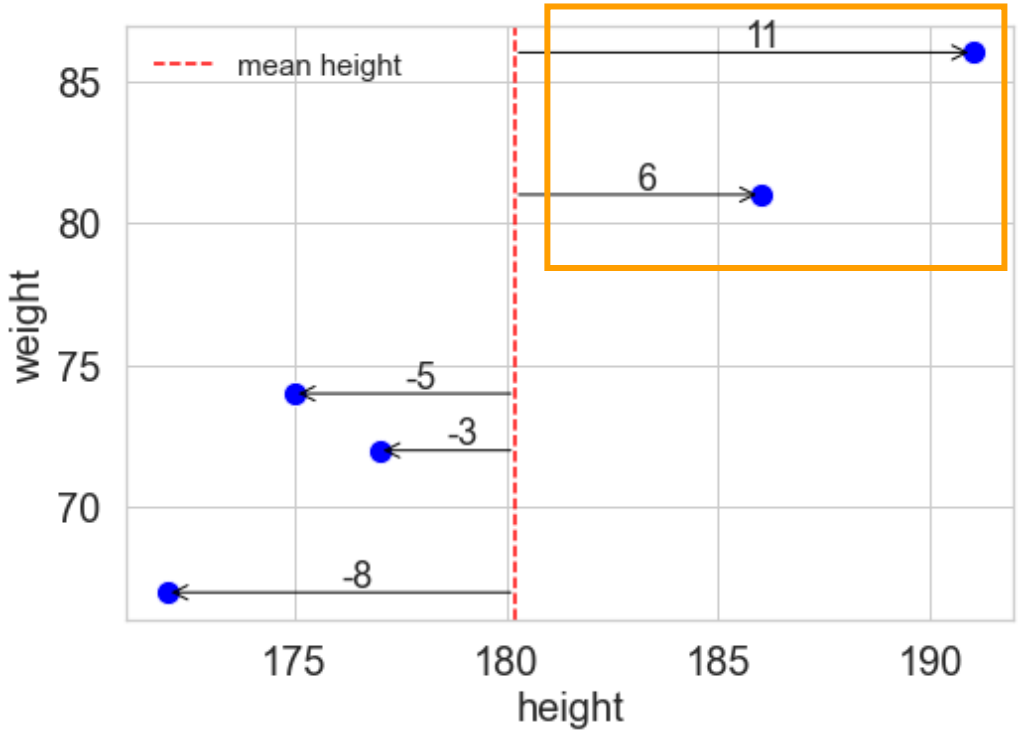

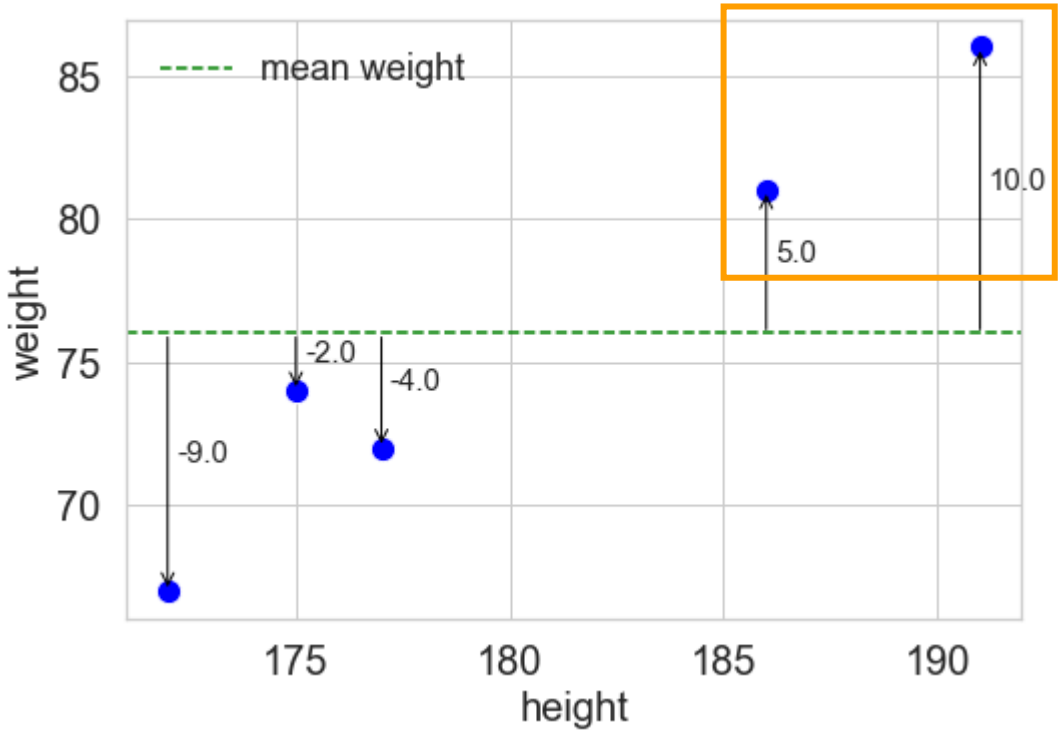

Gewicht und Größer der letzten **beiden Personen** liegen **über dem Durchschnitt**

ZUSAMMENHANGSMAß: KOVARIANZ

HOCHSCHULE HEILBRONN

Berechnung.

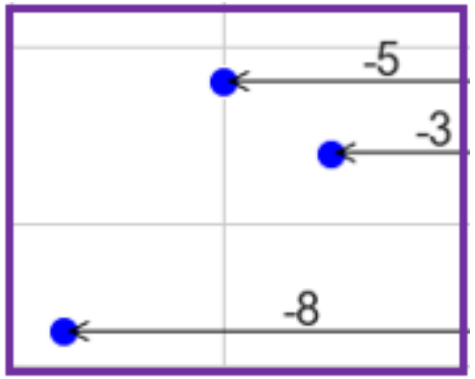

×

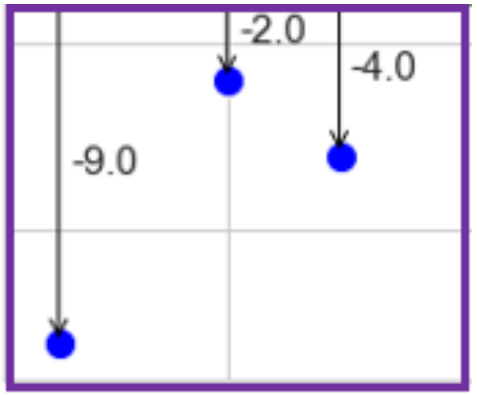

=

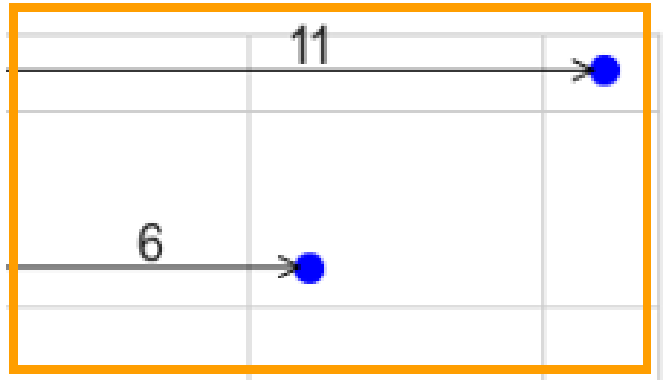

×

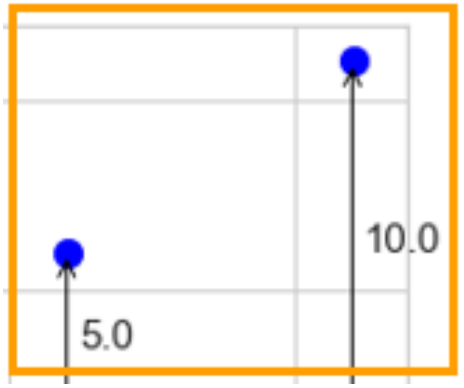

=

Produkt Abweichungen: $(height_i - MW_h) \cdot (weight_i - MW_w)$
72
10
12
30
110
Summe/ n	$cov(height, weight) = 234/5 = 46.8$

ZUSAMMENHANGSMAß: KOVARIANZ

HOCHSCHULE HEILBRONN

Sei $(x_1, y_1), \dots, (x_n, y_n)$ ein Datensatz mit zwei Merkmalen der Länge n:

> $Kovarianz$ der Merkmale = Durchschnitt Produkt Abweichungen vom Mittelwert:

$$cov(x, y) = \frac{(x_1 - MW_x) \cdot (y_1 - MW_y) + \cdots + (x_n - MW_x) \cdot (y_n - MW_y)}{n}.$$

ZUSAMMENHANGSMAß: KOVARIANZ

HOCHSCHULE HEILBRONN

Beispiel (Fortsetzung). Ausführliche Berechnung.

> Was passiert mit der Kovarianz, wenn man Größe (height) in m statt in cm misst?

Beobachtung: height (in cm)	Abweichungen: $height_i - MW_{height}$	Beobachtung: weight (in kg)	Abweichungen: $weight_i - MW_{weight}$	Produkt Abweichungen: $(height_i - MW_{height}) \cdot (weight_i - MW_{weight})$
172	-8	67	-9	72
175	-5	74	-2	10
177	-3	72	-4	12
186	6	81	5	30
191	11	86	10	110
$MW_{height} = 180$		$MW_{weight} = 76$		$cov(height, weight) = 46.8$

ZUSAMMENHANGSMAß: PEARSON KORRELATIONSKOEFFIZIENT

HOCHSCHULE HEILBRONN

> Wir möchten ein normiertes Maß, das nicht von der Einheit abhängt

Sei $(x_1, y_1), \ldots, (x_n, y_n)$ ein Datensatz mit zwei Merkmalen der Länge n:

> $Pearson\ Korrelationskoeffizient\ r$ = Kovarianz durch Produkt Standardabweichungen:

$$r = \frac{cov(x, y)}{sd(x) \times sd(y)}.$$

ZUSAMMENHANGSMAß: PEARSON KORRELATIONSKOEFFIZIENT

HOCHSCHULE HEILBRONN

$r_{x,y} = 1$
perfekt positiv linear

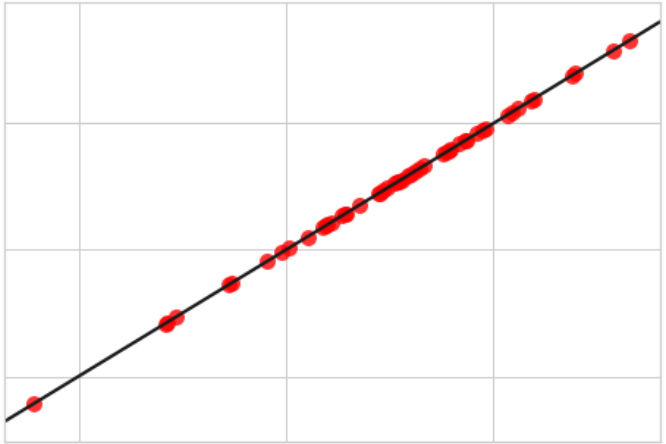

$r_{x,y} = 0$
nicht linear

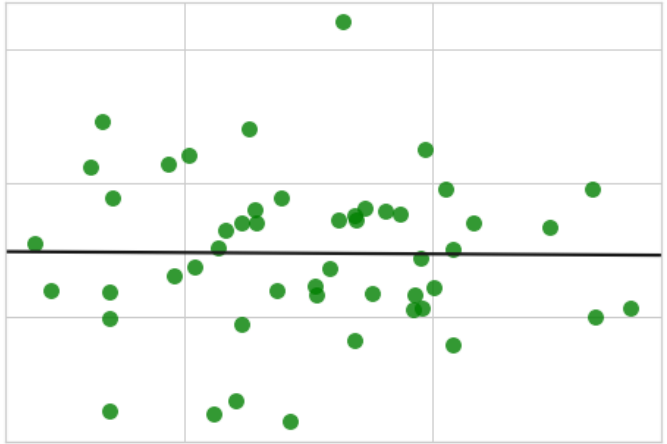

$r_{x,y} = -1$
perfekt negativ linear

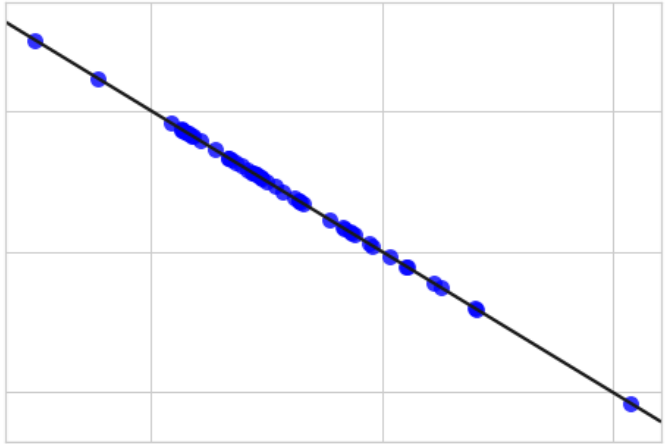

KOVARIANZ UND PEARSON KORRELATION: EIGENSCHAFTEN

HOCHSCHULE HEILBRONN

- Kovarianz nimmt Werte zwischen $-\infty$ und ∞ an
- Korrelationskoeffizient nimmt Werte zwischen -1 und +1 an
- Kovarianz hängt von der Einheit der Messungen ab, Korrelationskoeffizient nicht
- Je negativer (positiver), desto stärker ist der negative (positive) lineare Zusammenhang

KOVARIANZ UND PEARSON KORRELATION: ERFORDERLICHE MESSNIVEAUS

HOCHSCHULE HEILBRONN

Für die Berechnung von Kovarianz und Pearson Korrelationen braucht man den Mittelwert

→ können nur für numerische Daten berechnet werden

ZUSAMMENFASSUNG: STATISTIKEN UND ERFORDERLICHE MESSNIVEAUS

HOCHSCHULE HEILBRONN

Art	Statistik	Messniveau		
		Numerisch	Kategorial Ordinal	Kategorial Nominal
Lagemaß	Modalwert	✓	✓	✓
	Median	✓	✓	X
	Mittelwert	✓	X	X
Streuungsmaß	Alle	✓	X	X
Zusammenhang	Kovarianz, Pearson	✓	X	X
	Spearman Rho	✓	✓	X

THE END!

Please refer any questions to:
Prof. Dr. Florian Kauffeldt
Faculty of International Business
florian.kauffeldt@hs-heilbronn.de

HOCHSCHULE HEILBRONN

› WAHRSCHEINLICHKEITS-THEORIE

Statistik | Prof. Dr. Florian Kauffeldt

WAHRSCHEINLICHKEITSTHEORIE
INHALT

HOCHSCHULE HEILBRONN

1. Wahrscheinlichkeit
   > Wahrscheinlichkeitsbegriffe (Laplace, Frequentistisch, Bayesianisch)
   > Axiome von Kolmogorov

2. Zufallsexperimente und -variablen

3. Univariate Wahrscheinlichkeitsverteilungen
   > Diskrete Verteilungen (Gleichverteilung, Binomialverteilung)
   > Stetige Verteilungen (Gleichverteilung, Normalverteilung)
   > Abschätzung von stetigen Verteilungen (Empirische Regel, Chebyshev Ungleichung)

4. Multivariate Wahrscheinlichkeitsverteilungen
   > Diskrete gemeinsame Verteilung
   > Bedingte Wahrscheinlichkeiten und Unabhängigkeit

› WAHRSCHEINLICHKEIT

WAS SIND WAHRSCHEINLICHKEITEN?

HOCHSCHULE HEILBRONN

In Alltag sagen wir Sätze wie:

- Ich bin sicher, dass Bayern München morgen gewinnt
- Wahrscheinlich werde ich Statistik bestehen
- Möglicherweise wird es morgen regnen

→ Ausdruck unterschiedlicher Grade von Unsicherheit über künftige Ereignisse

- Wahrscheinlichkeiten formalisieren dieses Konzept

WAS SIND WAHRSCHEINLICHKEITEN?

HOCHSCHULE HEILBRONN

> Wahrscheinlichkeit = Maß zwischen 0 und 1, das Unsicherheit repräsentiert

> Je höher die Wahrscheinlichkeit eines Ereignisses, desto eher wird es eintreten

Notation. Die Wahrscheinlichkeit eines Ereignisses E bezeichnen wir mit $P(E)$

> Ein Ereignis E mit $P(E) = 0$ heißt *unmöglich*

> Ein Ereignis E mit $P(E) = 1$ heißt *sicher*

WAHRSCHEINLICHKEITS-BEGRIFFE

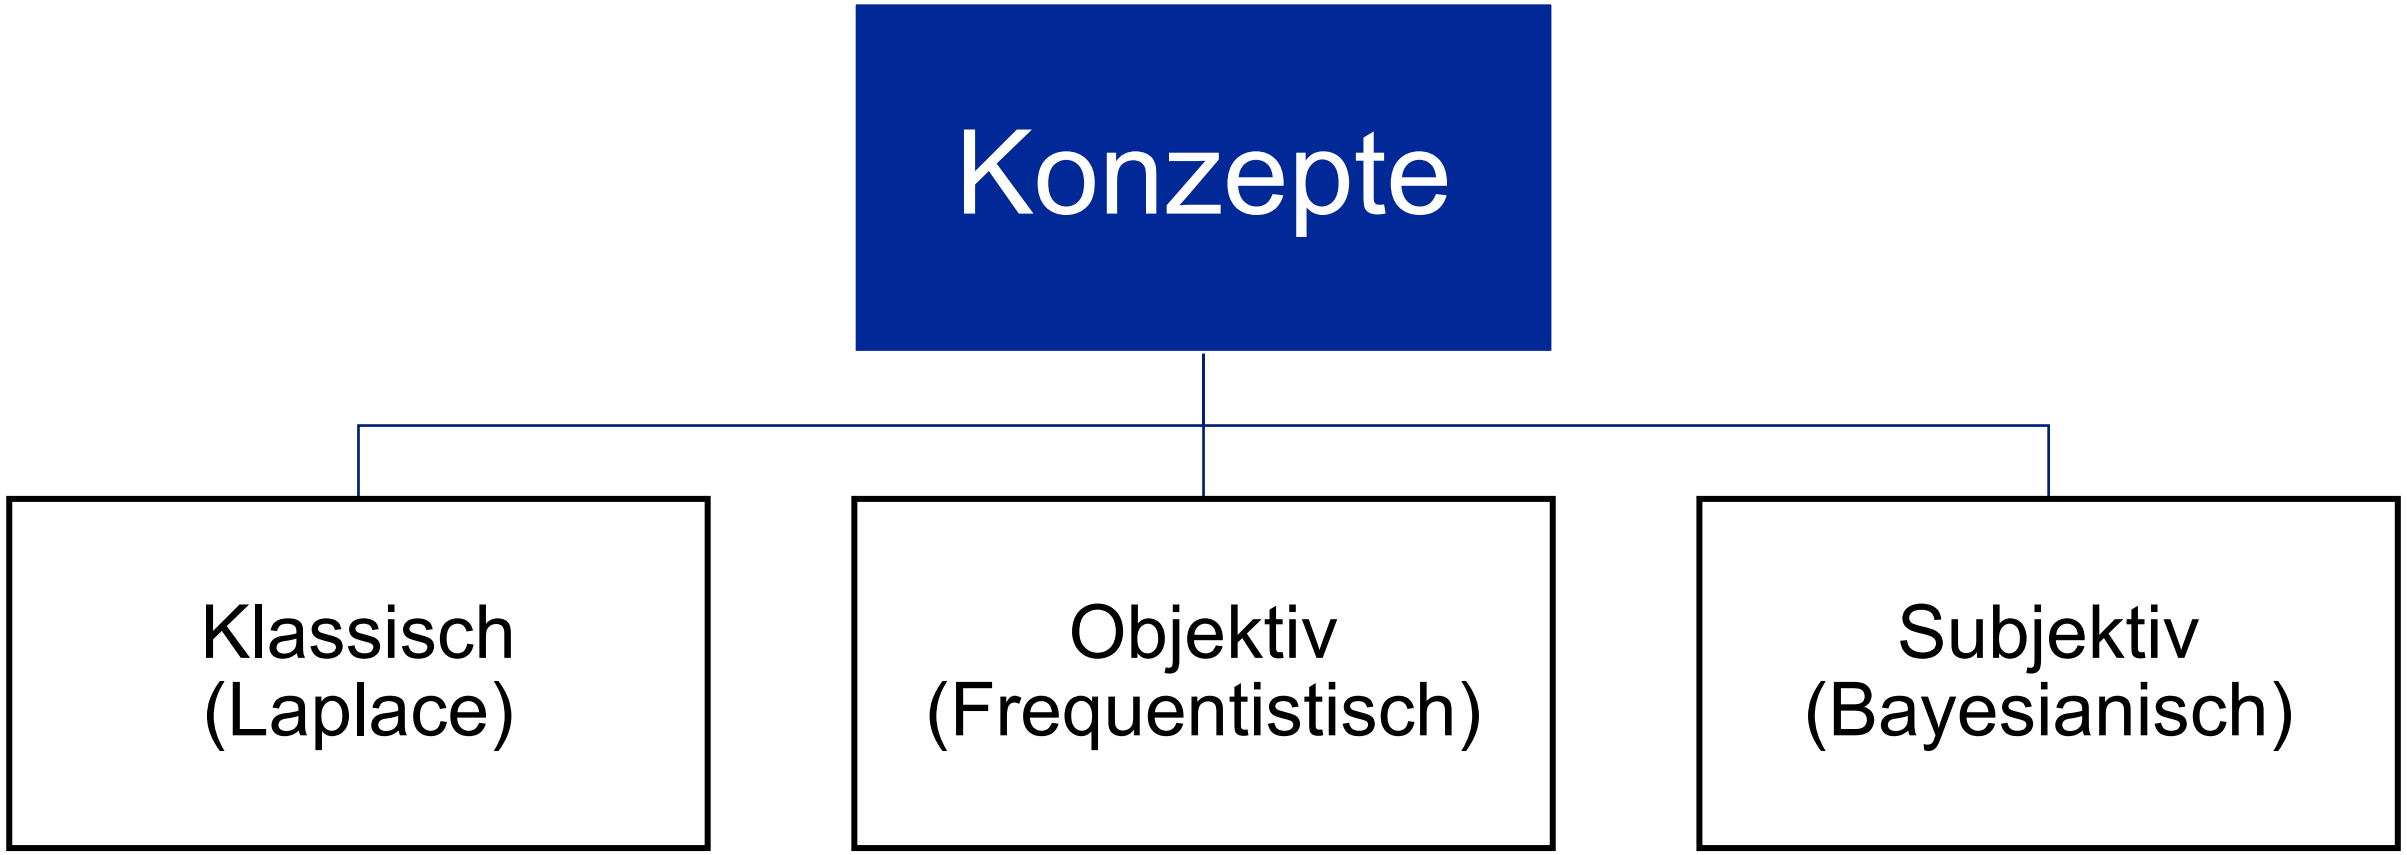

WAHRSCHEINLICHKEITSBEGRIFFE: LAPLACE

HOCHSCHULE HEILBRONN

Pierre-Simon Laplace (1749 – 1827)

> Reduktion Ereignisse auf gleichwahrscheinliche symmetrische Fälle

> **Prinzip des unzureichenden Grundes**: Kein Grund für andere Wahrscheinlichkeit

> Wahrscheinlichkeit Ereignisses E:

$$P(E) = \frac{Anzahl\ Fälle\ bei\ denen\ E\ eintritt}{Gesamtanzahl\ Fälle}$$

WAHRSCHEINLICHKEITSBEGRIFFE: FREQUENTISTISCH

HOCHSCHULE HEILBRONN

Richard von Mises, Egon Pearson, John Venn,…

> Häufige Wiederholung Zufallsexperiment:

Relative Häufigkeiten → "Wahre" Wahrscheinlichkeiten

> Die Wahrscheinlichkeit eines Ereignisses E kann wie folgt geschätzt werden:

$$P(E) = \frac{Anzahl\ Versuche\ bei\ denen\ E\ eingetreten\ ist}{Gesamtanzahl\ Versuche}$$

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Thomas Bayes (1701 – 1761)

- Wahrscheinlichkeiten = subjektive Einschätzungen
- Bedingte Wahrscheinlichkeiten = Aktualisierte Wahrscheinlichkeit bei neuer Information
- Regel = Bayes-Theorem

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Bayesianischer Ansatz. Unterscheidung zwischen:

A−Priori Wahrscheinlichkeit:
Subjektive Wahrscheinlichkeit $P(E)$

↓

Beobachtung
Ereignis F

↓

A-Posteriori Wahrscheinlichkeit:
Bedingte Wahrscheinlichkeit $P(E \mid F)$

> Bedingte Wahrscheinlichkeit $P(E \mid F)$: W'keit von E nachdem F beobachtet wurde

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel. Bayesianischer Ansatz: Würfelwurf: $E = \{⚅, ⚄\}$ und $F = \{⚅\}$.

> Wahrscheinlichkeiten von E und F?

> Wahrscheinlichkeit von E unter der Bedingung, dass F eingetreten ist?

> Wahrscheinlichkeit von F unter der Bedingung, dass E eingetreten ist?

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Bayes-Theorem und totale Wahrscheinlichkeit.

Bayes-Theorem

Die bedingte Wahrscheinlichkeit von Ereignis E nachdem F beobachtet wurde ist:

$$P(E \mid F) = \frac{P(F \mid E) \times P(E)}{P(F)} = \frac{P(E \cap F)}{P(F)}.$$

> $Bayes - Theorem$: Anpassung A-priori Wahrscheinlichkeiten im Lichte neuer Information

> Anwendung Bayes-Theorem erfordert häufig den $Satz\ der\ totalen\ Wahrscheinlichkeit$

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel aus der Einführung. Erinnerung

> Texas: 38% fahren einen SUV, 57% wählen die Republikaner

> Umfrage unter SUV-Fahrern: 78% sind Republikaner

Wir müssen folgende Wahrscheinlichkeiten unterscheiden:

> Bedingte W'keit Republikaner gegeben man ist SUV-Fahrer:

$$P(Republikaner \mid SUV) = 78\%$$ **Das misst die Studie**

> Bedingte W'keit SUV-Fahrer gegeben man ist Republikanter:

$$P(SUV \mid Republikaner) = ?$$ **Das wollte die Studie messen**

MULTIVARIATE VERTEILUNGEN: BEDINGTE WAHRSCHEINLICHKEITEN

Wir können nun das Bayes-Theorem anwenden, um den Machern der Studie zu helfen

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Betrachten Sie einen Corona-Test der 90% sensitiv ist und 80% spezifisch.

> 90% sensitiv: 90% der Leute, die Corona haben, erhalten ein positives Testresultat

> 80% spezifisch: 80% der Leute, die gesund sind, erhalten ein negatives Testresultat

> Außerdem hat ca. 5% der Bevölkerung Corona

Frage: Wahrscheinlichkeit, dass man Corona hat gegeben ein positives Testresultat?

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel (Fortsetzung).

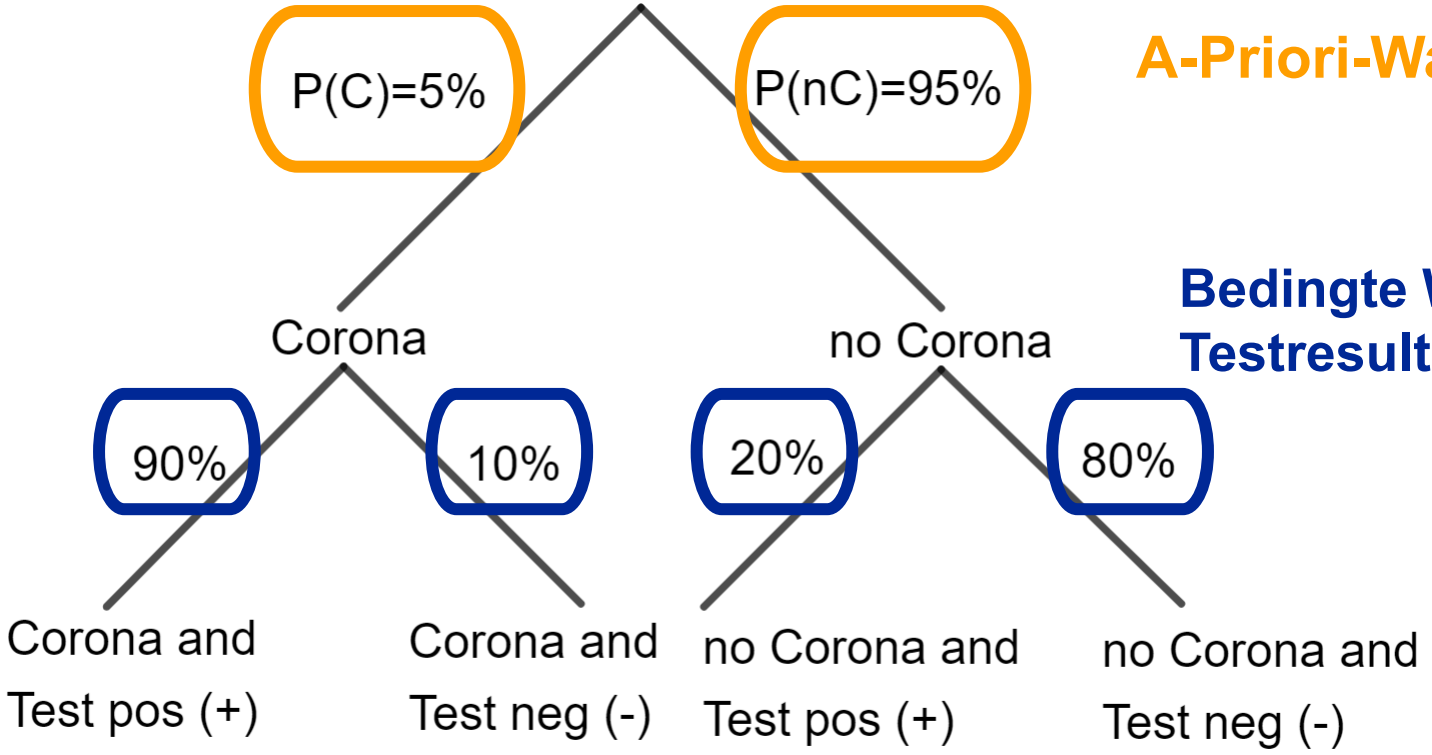

A-Priori-Wahrscheinlichkeiten

Bedingte Wahrscheinlichkeiten der Testresultate gegeben Corona / kein Corona

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel (Fortsetzung).

Wir müssen folgende Wahrscheinlichkeiten unterscheiden:

> Wahrscheinlichkeit einer Corona-Infektion (C):

$$P(C) = 5\%$$

> Bedingte Wahrscheinlichkeit eines positiven Tests (+) gegeben man hat Corona (C):

$$P(+ \mid C) = 90\%$$

> Bedingte Wahrscheinlichkeit einer Corona-Infektion (C) gegeben ein positiver Test (+):

$P(C \mid +) = ?$ Diese möchten wir wissen

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel (Fortsetzung).

> Bayes-Theorem:

$$P(Corona \mid +) = \frac{P(+ \mid Corona) \times P(Corona)}{P(+)}$$

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel (Fortsetzung).

> Satz der totalen Wahrscheinlichkeit:

$$P(+) = P(+ \mid Corona) \times P(Corona) + P(+ \mid KeinCorona) \times P(KeinCorona)$$

WAHRSCHEINLICHKEITSBEGRIFFE: BAYESIANISCH (BEDINGTE WAHRSCHEINLICHKEIT)

Beispiel (Fortsetzung).

> Bayes-Theorem:

$$P(Corona \mid +) = \frac{\overset{90\%}{\boxed{P(+ \mid Corona)}} \cdot \overset{5\%}{\boxed{P(Corona)}}}{\underset{23.5\%}{\boxed{P(+)}}} = 19.15\%$$

→ Die W'keit Corona zu haben bei einem positiven Test ist 19.15%

Beispiel. 200 Menschen. 47 (= 23.5%) werden positiv getestet → 10 (= 5%) haben Corona.

WAHRSCHEINLICHKEIT: DAS LINDA PROBLEM

HOCHSCHULE HEILBRONN

Linda ist 31 Jahre alt, Single, offen und sehr intelligent. Sie hat Philosophie studiert. Als Studentin hat sie sich intensive mit Diskriminierung und sozialer Gerechtigkeit beschäftigt sowie an Anti-Atomkraft-Demonstrationen teilgenommen.

Was ist wahrscheinlicher?

1. Linda ist eine Bankangestellte.
2. Linda ist eine Bankangestellte und aktive Feministin.

WAHRSCHEINLICHKEIT: AXIOME VON KOLMOGOROV

Andrey Kolmogorov (1903 – 1987)

> hat Wahrscheinlichkeiten anhand von mathematischen Eigenschaften (Axiome) definiert

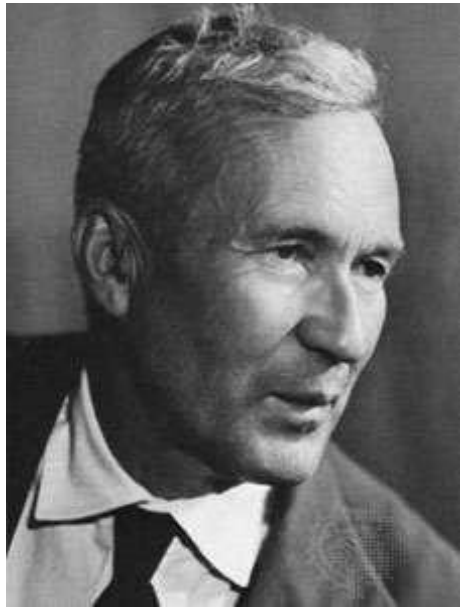

WAHRSCHEINLICHKEIT: AXIOME VON KOLMOGOROV

Axiome der Wahrscheinlichkeitsrechnung (Kolmogorov, 1928):

(A1) Nichtnegativität. Die Wahrscheinlichkeit jedes Ereignisses E ist größer oder gleich 0:

$$P(E) \geq 0.$$

(A2) Normalisierung. Irgendetwas muss passieren: Der Stichprobenraum S ist sicher:

$$P(S) = 1.$$

(A3) Additivität. Die Wahrscheinlichkeit von disjunkten Ereignissen E, F ist:

$$P(E \cup F) = P(E) + P(F).$$

Zwei Ereignisse sind disjunkt, wenn sie sich nicht überschneiden ($E \cap F = \emptyset$)

WAHRSCHEINLICHKEIT: IMPLIKATIONEN DER AXIOME VON KOLMOGOROV

HOCHSCHULE HEILBRONN

> Irgendetwas muss passieren → Wahrscheinlichkeit, dass nichts passiert ist 0:

$$P(\emptyset) = 0$$

> Die Wahrscheinlichkeit jedes Ereignisses liegt zwischen 0 und 1:

$$0 \leq P(E) \leq 1$$

> "Kleinere" Ereignisse haben kleinere Wahrscheinlichkeiten:

$$Wenn\ E\ Teilmenge\ von\ F\ ist, dann\ P(E) \leq P(F)$$

WAHRSCHEINLICHKEIT: IMPLIKATIONEN DER AXIOME VON KOLMOGOROV

HOCHSCHULE HEILBRONN

> Die Vereinigungswahrscheinlichkeit von zwei Ereignissen E und F ist:

$$P(E \cup F) = P(E) + P(F) - P(E \cap F)$$

AXIOME VON KOLMOGOROV: EXKURS (PARTITION)

HOCHSCHULE HEILBRONN

Eine *Partition* des Stichprobenraums S ist eine Menge von Ereignissen,

> die **paarweise disjunkt (= leere Schnittmenge)** sind und

> deren **Vereinigung der Stichprobenraum** ist

Beispiele. Würfelwurf. $Stichprobenraum = \{$⚀,⚁,⚂,⚃,⚄,⚅$\}$. Partitionen:

> $E_1 = \{$⚀,⚁,⚂$\}$ und $E_2 = \{$⚃,⚄,⚅$\}$

> $E_1 = \{$⚀,⚂$\}$ und $E_2 = \{$⚁,⚃,⚄,⚅$\}$

> Weitere?

WAHRSCHEINLICHKEIT: IMPLIKATIONEN DER AXIOME VON KOLMOGOROV

> Die Summe der Wahrscheinlichkeiten jeder Partition von S ist 1:

$$P(E_1) + \cdots + P(E_k) = 1 \text{ für jede Partition } \{E_1, \dots, E_k\} \text{ von } S.$$

› ZUFALLSEXPERIMENTE UND -VARIABLEN

ZUFALLSEXPERIMENTE: DEFINITION

HOCHSCHULE HEILBRONN

Ein *Zufallsexperiment* ist ein Vorgang der

> unter identischen Bedingungen wiederholt werden kann und

> dessen mögliche Ergebnisse im Vorhinein bekannt und unsicher sind

MEHRSTUFIGE ZUFALLSEXPERIMENTE

Mehrstufiges Zufallsexperiment = fixierten Anzahl von Wiederholungen eines Experiments.

> Mehrstufige Experimente haben größere Stichprobenräume

Beispiel. Münzwurf.

MEHRSTUFIGE ZUFALLSEXPERIMENTE

Mehrstufige Zufallsexperimente können in Baumdiagrammen dargestellt werden

Beispiel. Zweimaliger Münzwurf.

> Produktregel:

$$P(HH) = P(H) \times P(H) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

> Summenregel:

$$P(\{TH, TT\}) = P(TH) + P(TT) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

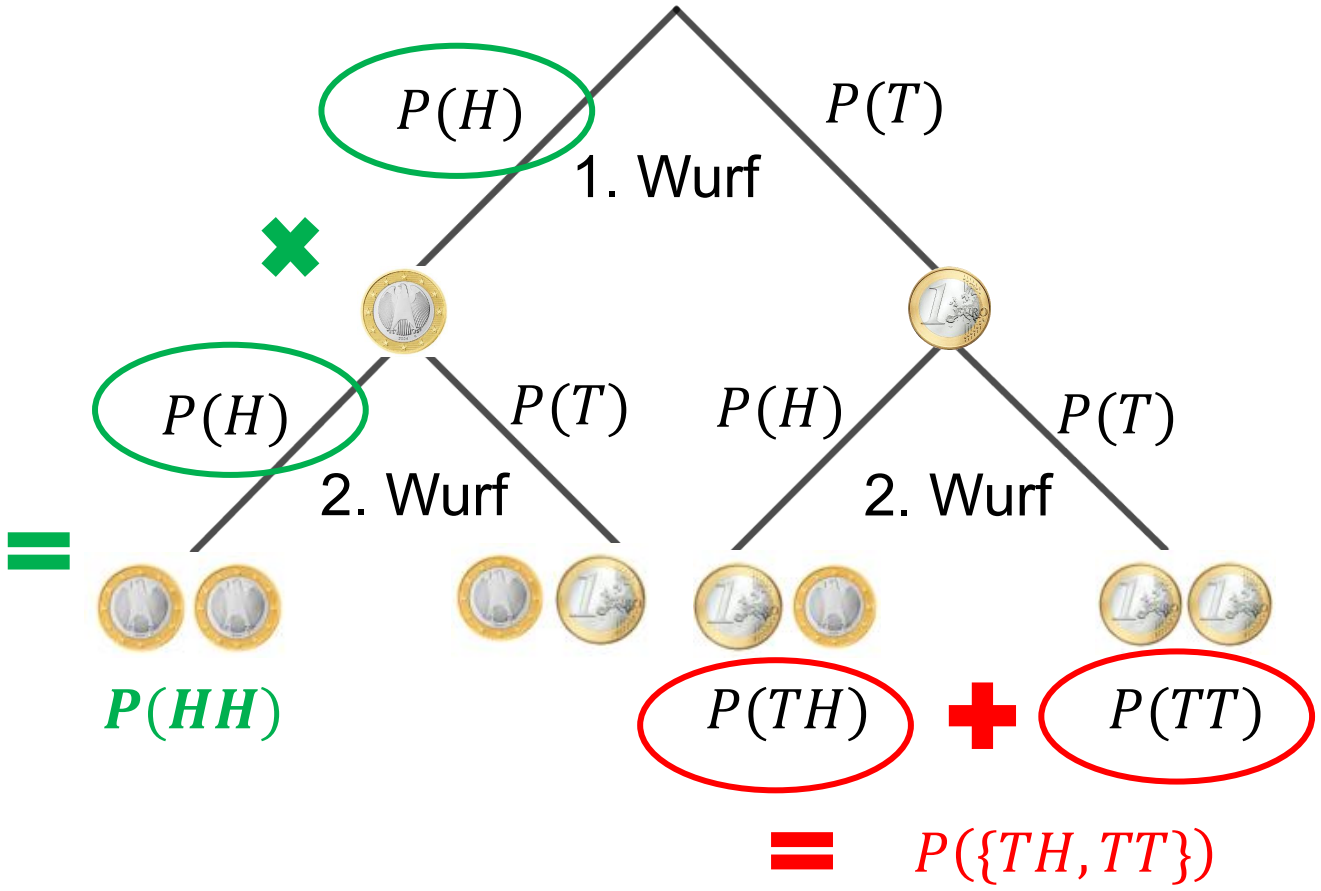

WAS SIND ZUFALLSVARIABLEN?

HOCHSCHULE HEILBRONN

Meistens interessieren wir uns nicht für alle Details eines Zufallsexperiments.

Eine $Zufallsvariable$

> hängt von den Ergebnissen eines Zufallsexperiments ab

> misst relevante Charakteristika des Experiments

Beispiel. Mehrfacher Münzwurf.

> Wie häufig wird "Kopf" geworfen?

> Zufallsvariable, die zählt wie häufig "Kopf" geworfen wurde

WAS SIND ZUFALLSVARIABLEN?

HOCHSCHULE HEILBRONN

Beispiel. Zweifacher Münzwurf. Zufallsvariable: Funktion X = Anzahl "Kopf".

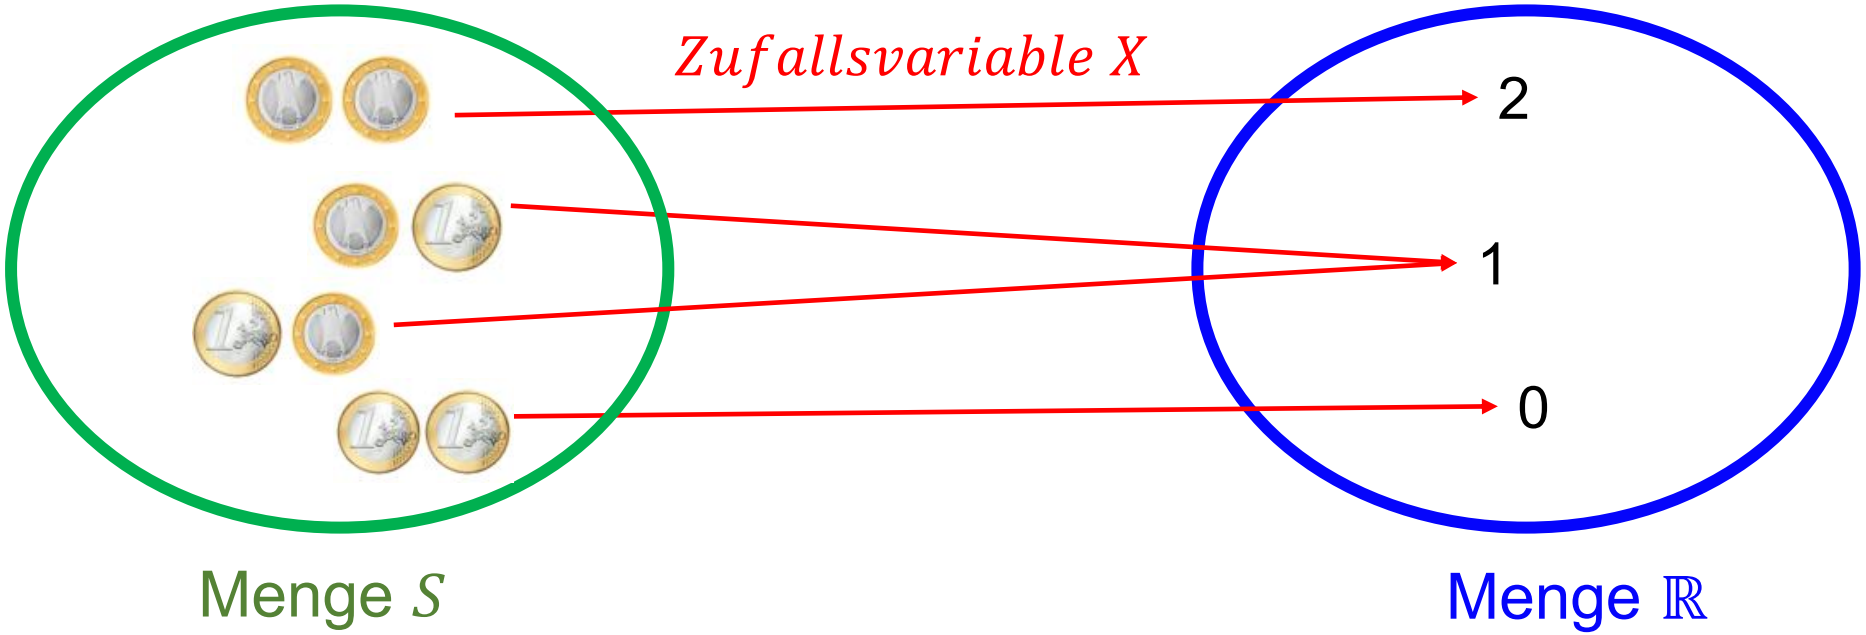

WAS SIND ZUFALLSVARIABLEN?

HOCHSCHULE HEILBRONN

Zufallsvariable

Eine $Zufallsvariable\ X$ ist eine Funktion, die jedem Ergebnis $s \in S$ eines Zufalls-experiments ein Element s' einer Menge S' zuordnet (häufig eine Zahl: $S' = \mathbb{R}$):

$$X: S \to S'.$$

Beispiel. Zweimaliges Werfen einer Münze. X = Anzahl Kopf.

> X ist eine Stufenfunktion, die wie folgt geschrieben werden kann:

$$X(s) = \begin{cases} 2, & wenn\ s = HH \\ 1, & wenn\ s = HT\ oder\ TH \\ 0, & wenn\ s = TT \end{cases}$$

ZUFALLSVARIABLEN UND ZUFALLSEXPERIMENTE

HOCHSCHULE HEILBRONN

Beispiel. Zweifacher Münzwurf.

Zufallsexperiment

$s \in S$	$P(s)$
	¼
	¼
	¼
	¼

X

Zufallsvariable X = Anzahl "Kopf"

$x \in S'$	$P'(X = x)$
2	¼
1	½
0	¼

ZUFALLSVARIABLEN UND ZUFALLSEXPERIMENTE

Das Konzept einer Zufallsvariablen = Natürliche Erweiterung Zufallsexperiment

$$Zufallsvariable\colon X\colon S \to S'$$

> Wahl $S' = S \to$ Ursprüngliches Zufallsexperiment

ZUFALLSVARIABLEN: ANMERKUNGEN

HOCHSCHULE HEILBRONN

> Kombinationen von Zufallsvariablen

$$X + Y, X \cdot Y, \ldots$$

UND

> Kombinationen von Zufallsvariablen mit einer Konstanten

$$X + Konstante, X \cdot Konstante, \ldots$$

sind ebenfalls Zufallsvariablen

ZUFALLSVARIABLEN: DISKRET UND STETIG

HOCHSCHULE HEILBRONN

Diskrete Zufallsvariable

Nimmt eine **abzählbare** Anzahl (endlich oder unendlich) von Werten an.

Stetige Zufallsvariable

Nimmt eine **nicht abzählbare** unendliche Anzahl von Werten an.

Beispiel. Anzahl an Sechsen bei vierfachem Würfelwurf:

$$0, 1, 2, 3, 4$$

Beispiel. Größe einer zufällig ausgewählten Person:

$$145\ cm \ \leq \ X \ \leq \ 220\ cm$$

ZUFALLSVARIABLEN: DISKRET UND STETIG

HOCHSCHULE HEILBRONN

Zufallsvariable	Art
Anzahl Verkäufe eines Verkäufers in einer Woche	
Die Größe eines zufällig ausgewählten Erwachsenen	
Die Zeit zwischen der Ankunft zweier Touristen an einem Urlaubsort	
Anzahl Kunden in einer Stichprobe, die ein bestimmtes Produkt gegenüber allen Wettbewerbern bevorzugen	
Neuer Wohnkomplex – die Zeit zwischen der Fertigstellung und dem Verkauf der letzten Wohnung	
Erwartete Anzahl Studierende in einer Vorlesung	
Die Tiefe, bis zu der gebohrt werden muss, bis man auf Öl stößt	

› WAHRSCHEINLICHKEITS-VERTEILUNGEN

WAHRSCHEINLICHKEITSVERTEILUNGEN: DISKRET UND STETIG

HOCHSCHULE HEILBRONN

- $Diskrete\ Verteilung$ = Verteilung einer diskreten Zufallsvariablen

- $Stetige\ Verteilung$ = Verteilung einer stetigen Zufallsvariablen

DISKRETE VERTEILUNGEN: WAHRSCHEINLICHKEITSFUNKTION

HOCHSCHULE HEILBRONN

Eine diskrete Verteilung

> ist definiert durch eine $Wahrscheinlichkeitsfunktion\ P(X = x)$

> Liste aller Werte der Zufallsvariablen und Ihrer Wahrscheinlichkeiten

Beispiel. Zweifacher Münzwurf. X = Anzahl "Kopf". Wahrscheinlichkeitsverteilung:

x	$P(X = x)$
2	¼
1	½
0	¼

DISKRETE VERTEILUNGEN: WAHRSCHEINLICHKEITSFUNKTION

HOCHSCHULE HEILBRONN

Wahrscheinlichkeitsfunktion – graphisch:

x	$P(X = x)$
2	¼
1	½
0	¼

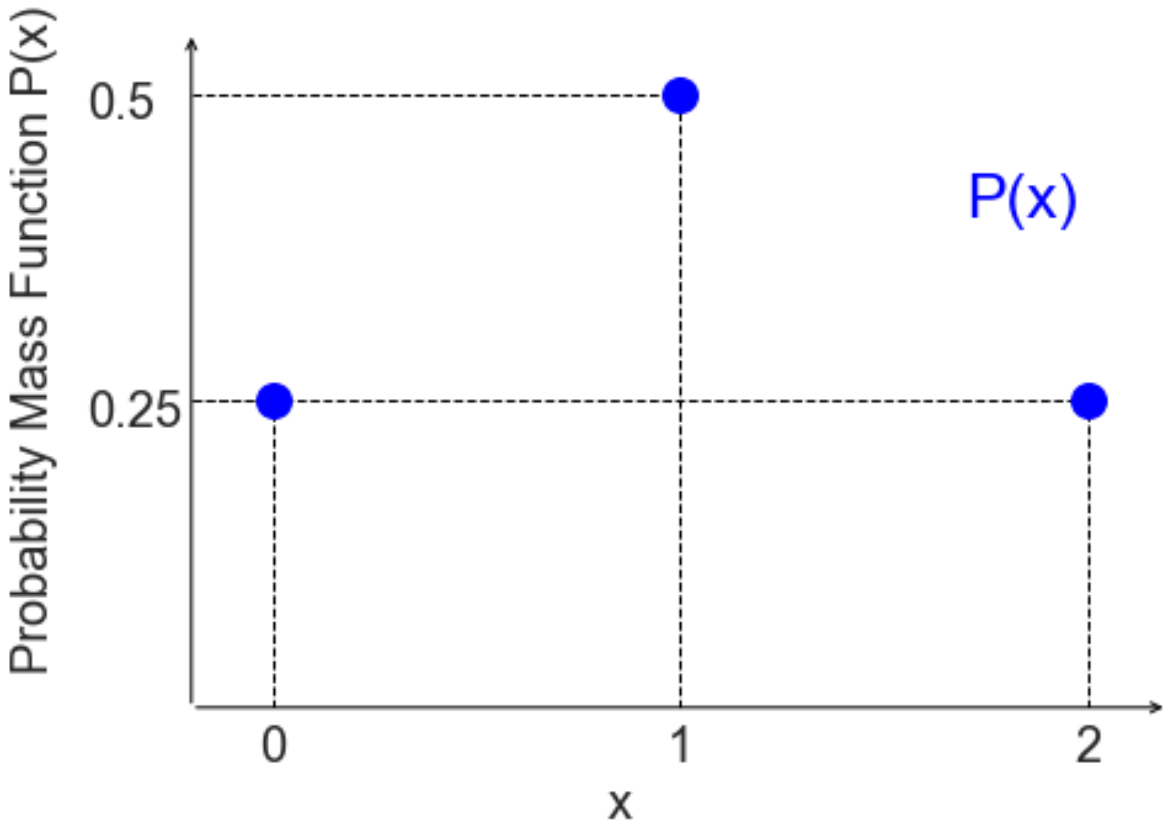

DISKRETE VERTEILUNGEN: BERECHNUNG VON WAHRSCHEINLICHKEITEN

HOCHSCHULE HEILBRONN

x	$P(X = x)$
2	¼
1	½
0	¼

> Was ist die Wahrscheinlichkeit, dass mindestens 1x "Kopf" geworden wird $P(X \geq 1)$?

DISKRETE VERTEILUNGEN: BERECHNUNG VON WAHRSCHEINLICHKEITEN

HOCHSCHULE HEILBRONN

Die Wahrscheinlichkeit, dass X einen Wert aus einer Menge M annimmt ist:

$$P(X \in M) = \sum_{x \in M} P(X = x)$$

DISKRETE VERTEILUNGEN: GLEICHVERTEILUNG

Eine diskrete Zufallsvariable heißt $gleichverteilt$,

> wenn alle ihre Werte gleichwahrscheinlich sind.

Beispiele?

DISKRETE VERTEILUNGEN: BERNOULLI-VERTEILUNG

HOCHSCHULE HEILBRONN

Eine diskrete Zufallsvariable heißt $Bernoulli - verteilt$,

> wenn sie nur zwei Werte hat (0 and 1). Wert 1 heißt $Erfolg$ und Wert 0 $Misserfolg$.

Beispiele?

DISKRETE VERTEILUNGEN: BERNOULLI-VERTEILUNG

HOCHSCHULE HEILBRONN

Die Wahrscheinlichkeitsfunktion der Bernoulli-Verteilung ist

$$P(X) = \begin{cases} \pi & f\ddot{u}r\ X = 1 \\ (1-\pi) & f\ddot{u}r\ X = 0 \end{cases},$$

> wobei π = Erfolgswahrscheinlichkeit

DISKRETE VERTEILUNGEN: BERNOULLI-VERTEILUNG

Vereinfachte Formel Varianz Bernoulli-verteilte Zufallsvariable X:

$$Varianz\ X = \pi \times (1 - \pi),$$

> wobei $\pi =$ Erfolgswahrscheinlichkeit

STETIGE VERTEILUNGEN: WAHRSCHEINLICHKEITSDICHTEFUNKTION

Bei stetigen Verteilungen ist die Wahrscheinlichkeit einzelner Werte (Atome) 0

→ Wir können hier also keine Wahrscheinlichkeitsfunktion verwenden

STETIGE VERTEILUNGEN: WAHRSCHEINLICHKEITSDICHTEFUNKTION

HOCHSCHULE HEILBRONN

Lösung: $Wahrscheinlichkeitsdichtefunktion\ f(x)$

> identifiziert Regionen mit höherer bzw. niedrigerer Wahrscheinlichkeit

$f(2) > f(8)$: Wahrscheinlichkeit, dass Zufallsvariable Wert nahe 2 annimmt ist höher

> Wahrscheinlichkeitsdichten $\neq$ Wahrscheinlichkeiten! Es ist z.B. möglich, dass $f(x) > 1$

STETIGE VERTEILUNGEN: BERECHNUNG VON WAHRSCHEINLICHKEITEN

HOCHSCHULE HEILBRONN

Wahrscheinlichkeit eines Bereichs = Fläche unter Wahrscheinlichkeitsdichtefunktion $f(x)$

Beispiel. X = Größe $(145\ cm \leq X \leq 220\ cm)$ eine zufällig ausgewählten Person.

> Annahme: Alle Größen sind gleichwahrscheinlich ($f(x) = \frac{1}{75}$ für alle Größen x)

> P(Größe zwischen 160 und 180)?

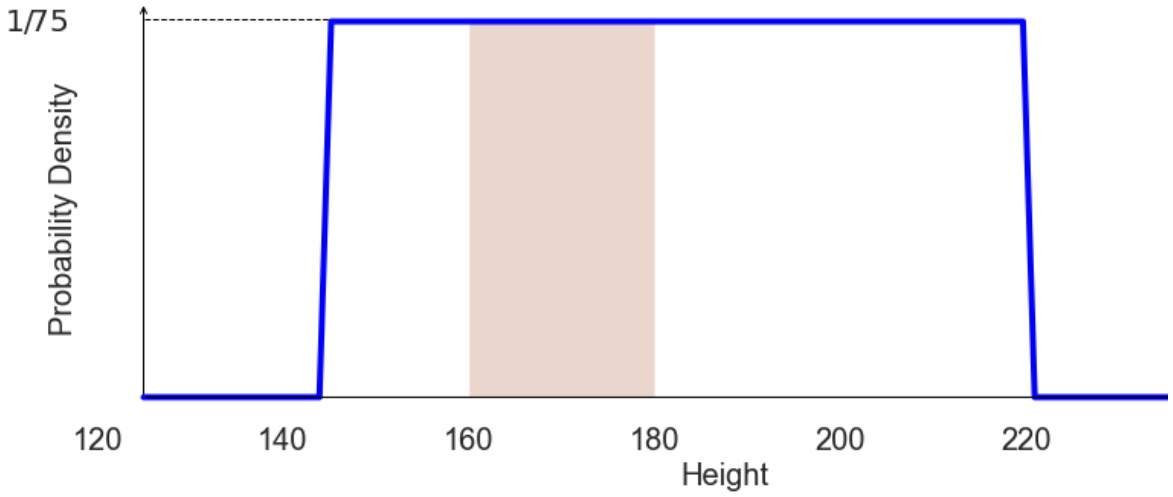

STETIGE VERTEILUNGEN: BERECHNUNG VON WAHRSCHEINLICHKEITEN

Die Wahrscheinlichkeit, dass X einen Wert zwischen x_1 und x_2 annimmt:

$$P(X \in [x_1, x_2]) = \int_{x_1}^{x_2} f(x)\,\mathrm{d}x$$

STETIGE VERTEILUNGEN: GLEICHVERTEILUNG

Eine stetige Zufallsvariable X heißt $gleichverteilt$,

> wenn alle Werte x die gleiche Wahrscheinlichkeitsdichte $f(x)$ haben.

Beispiel.

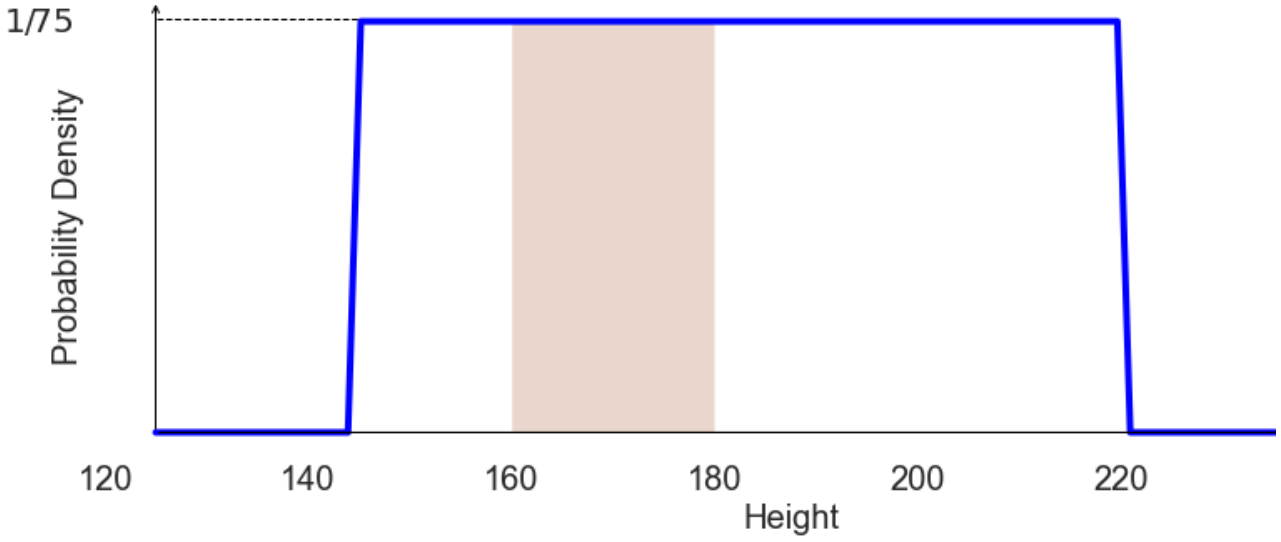

STETIGE VERTEILUNGEN: NORMALVERTEILUNG

In der Realität haben die meisten Verteilungen eine Glockenform:

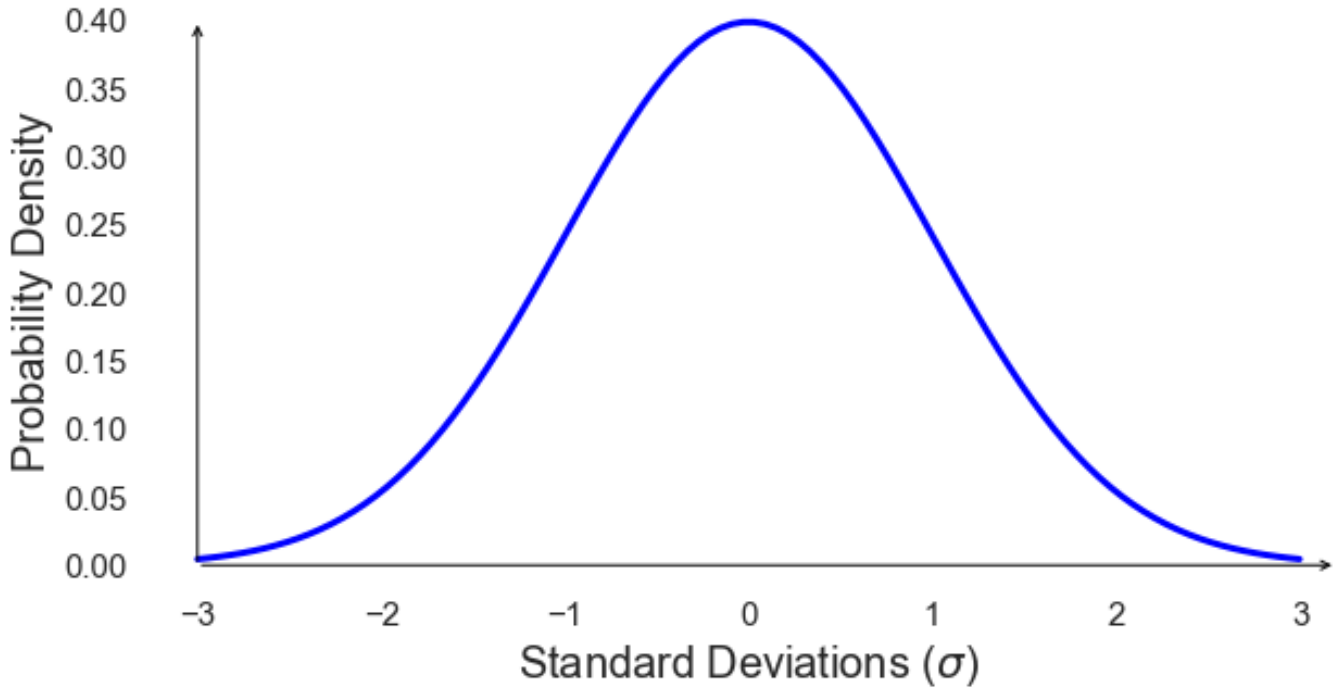

> Derartige Verteilungen heißen *Normal-* oder *Gaußverteilung*

> Glockenform: Extremwerte (Ränder) sind unwahrscheinlicher als mittlere Werte

STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Normalverteilung für verschiedene Erwartungswerte μ und Standardabweichungen σ:

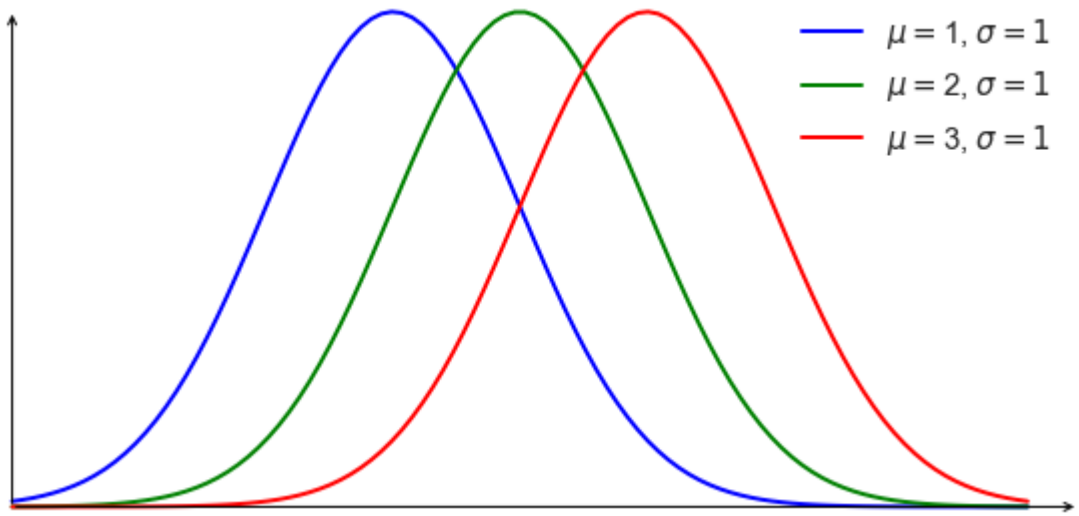

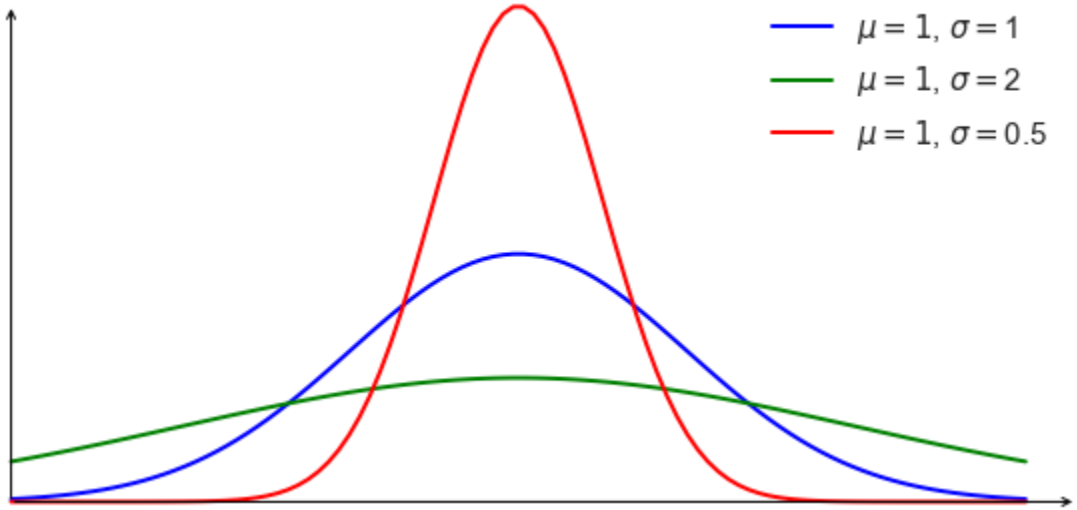

STETIGE VERTEILUNGEN: NORMALVERTEILUNG

Symmetrie der Normalverteilung:

> Die Normalverteilung ist perfekt symmetrisch um Ihren Erwartungswert μ:

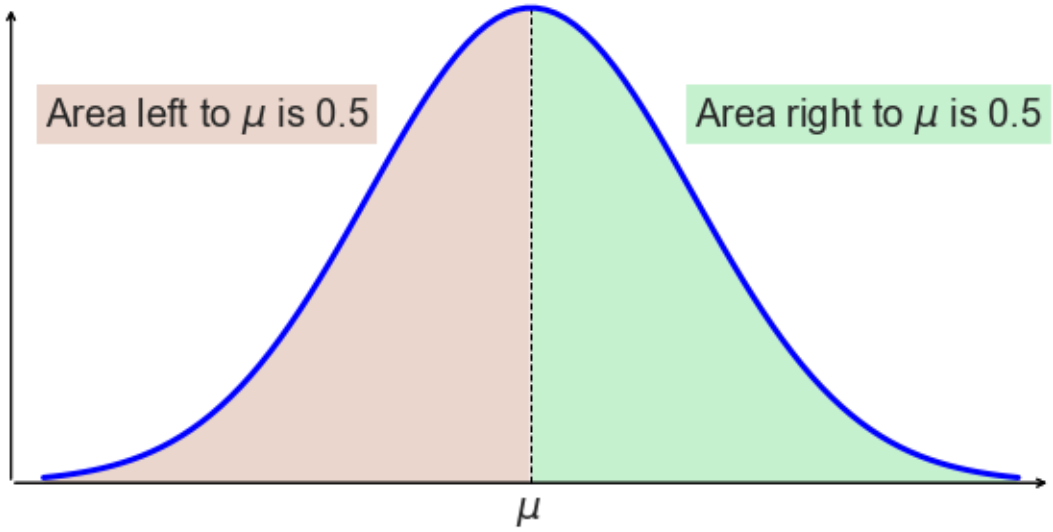

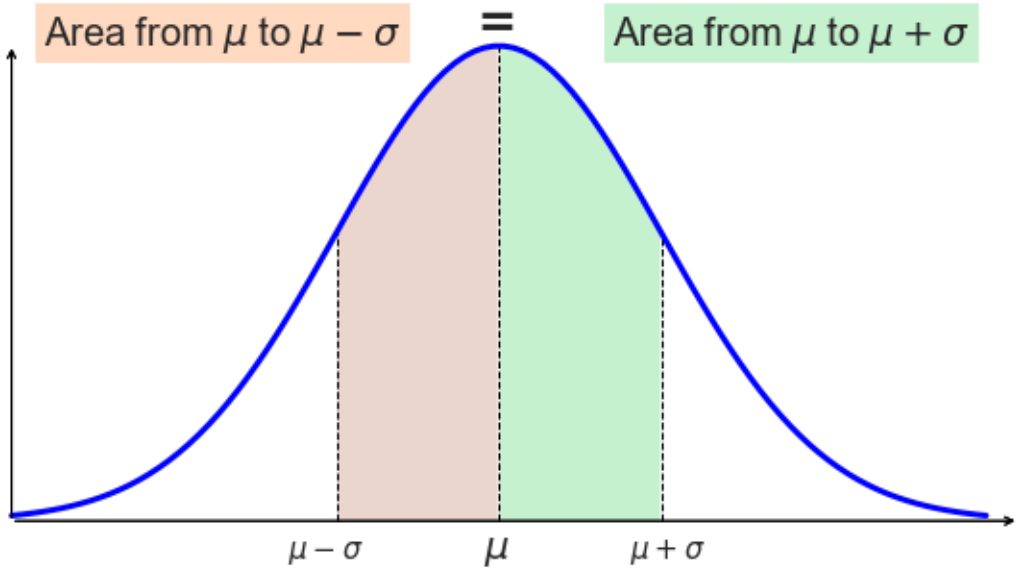

STETIGE VERTEILUNGEN: NORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Eine stetige Zufallsvariable X heißt $normalverteilt$,

> wenn sie folgende Dichtefunktion hat:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

> e ($\approx$ 2.7183) und π ($\approx$ 3.1416) sind mathematische Konstanten

> μ = Erwartungswert und σ = Standardabweichung der Verteilung

Die Normalverteilung heißt $Standardnormalverteilung$, wenn $\mu = 0$ und $\sigma = 1$

STETIGE VERTEILUNGEN: NORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Berechnung Wahrscheinlichkeiten Normalverteilung:

Integrale mit Dichtefunktion $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$

=

> Gute Nachrichten! Wir können Integralrechnung vermeiden:

Tabelle mit Wahrscheinlichkeiten (Flächen) für Standardnormalverteilung

STETIGE VERTEILUNGEN: Z-TRANSFORMATION NORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Gegeben eine Zufallsvariable X mit Erwartungswert μ und Standardabweichung σ.

> Der $z - Wert$ eines Wertes x von X ist:

$$z(x) = \frac{x - \mu}{\sigma}.$$

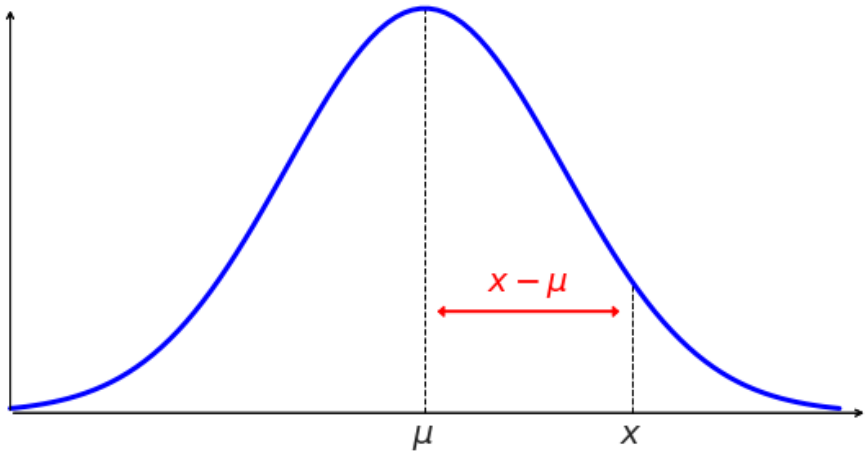

> $z(x)$ = Distanz zwischen μ und x in Standardabweichungen σ

> Wenn X normalverteilt ist, dann ist $Z(X)$ standardnormalverteilt

STETIGE VERTEILUNGEN: Z-TRANSFORMATION NORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Beispiel. Z-Transformation.

Wahrscheinlichkeitsverteilung:

x	p	$p \cdot x$
2	0.1	0.2
4	0.2	0.8
6	0.4	2.4
8	0.2	1.6
10	0.1	1
Summe		$\boldsymbol{\mu_x = 6}$
		$\boldsymbol{\sigma_X = 2.19}$

Z-transformierte Wahrscheinlichkeitsverteilung:

$z(x)$	p	$p \cdot z(x)$
-1.83	0.1	-0.18
-0.91	0.2	-0.18
0	0.4	0
0.91	0.2	0.18
1.83	0.1	0.18
Summe		$\boldsymbol{\mu_Z = 0}$
		$\boldsymbol{\sigma_Z = 1}$

$$z(x) = \frac{x - \mu_x}{\sigma_x}$$

STETIGE VERTEILUNGEN: TABELLE STANDARDNORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Z-Tabelle: Wahrscheinlichkeit $P([0,z])$

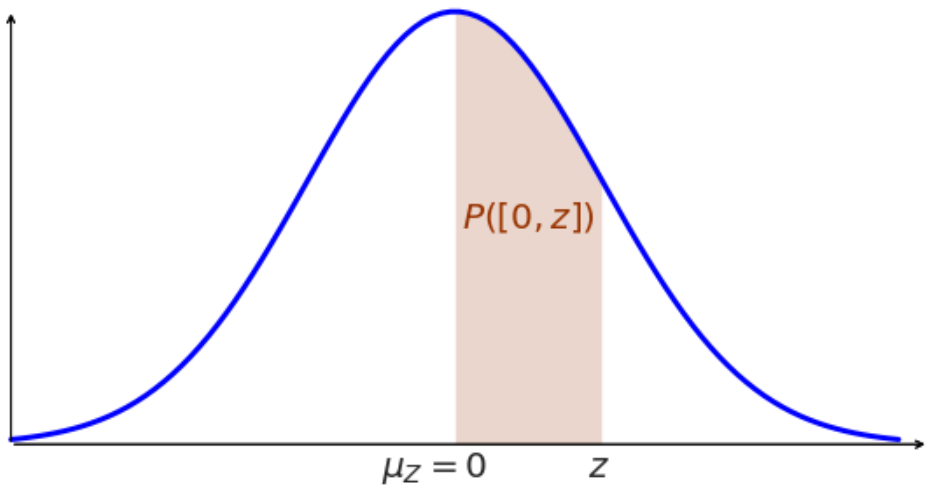

Z	0.00	0.01	0.02	0.03	0.04
0.00	0.0000	0.0040	0.0080	0.0120	0.0160
0.10	0.0398	0.0438	0.0478	0.0517	0.0557
0.20	0.0793	0.0832	0.0871	0.0910	0.0948
0.30	0.1179	0.1217	0.1255	0.1293	0.1331
0.40	0.1554	0.1591	0.1628	0.1664	0.1700
0.50	0.1915	0.1950	0.1985	0.2019	0.2054
0.60	0.2257	0.2291	0.2324	0.2357	0.2389
0.70	0.2580	0.2611	0.2642	0.2673	0.2704
0.80	0.2881	0.2910	0.2939	0.2967	0.2995
0.90	0.3159	0.3186	0.3212	0.3238	0.3264
1.00	0.3413	0.3438	0.3461	0.3485	0.3508
1.10	0.3643	0.3665	0.3686	0.3708	0.3729
1.20	0.3849	0.3869	0.3888	0.3907	0.3925
1.30	0.4032	0.4049	0.4066	0.4082	0.4099
1.40	0.4192	0.4207	0.4222	0.4236	0.4251
1.50	0.4332	0.4345	0.4357	0.4370	0.4382

> Z-Wert bis 1. Nachkommastelle

> 2. Nachkommastelle

Beispiel. $P([0,1.22])?$ $= 0.3888$

STETIGE VERTEILUNGEN: TABELLE STANDARDNORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Beispiel. Eine Person wird zufällig ausgewählt. $X = Größe$.

> Größe ist normalverteilt mit $\mu_X = 167cm$ und $\sigma_X = 10cm$.

a) Berechne die W'keit, dass die Person zwischen 167 und 178cm ist. $P_X([167,178])$

b) Wahrscheinlichkeit, dass X zwischen 150 und 181 cm ist?: $P_X([150,181])$

c) Bestimme die Wahrscheinlichkeit, dass die Person größer als 175 ist: $P_X(X > 175)$

d) Wahrscheinlichkeit, dass X zwischen 170 und 175 cm ist?: $P_X([170,175])$

STETIGE VERTEILUNGEN: TABELLE STANDARDNORMALVERTEILUNG

HOCHSCHULE HEILBRONN

Beispiel. Aggresivitäts-Score. $X = Score\ Frauen, Y = Score\ Männer$

> X ist normalverteilt mit $\mu_X = 38.82$ und $\sigma_X = 7.91$ (*)

> Y ist normalverteilt mit $\mu_Y = 40.86$ und $\sigma_Y = 8.69$ (*)

(*) Siehe “Gender Differences in Aggression-related Responses on EEG and ECG” in *Exp Neurobiol.* 27

Eine Frau und ein Mann werden zufällig ausgewählt.

> Wie wahrscheinlich ist es, dass der Mann aggressiver ist als die Frau?

ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)

HOCHSCHULE HEILBRONN

Empirische Regel: Abschätzung der Normalverteilung

Wahrscheinlichkeit, dass eine normalverteilte Variable im Intervall

Mittelwert (μ) bis μ +1 Standardabweichung? +2 St.abw.? +3 St.abw.?

> Z-Werte für $[\mu, \mu + \sigma]$?

$$z(\mu) = 0$$

$$z(\mu + \sigma) = \frac{\mu + \sigma - \mu}{\sigma} = 1$$

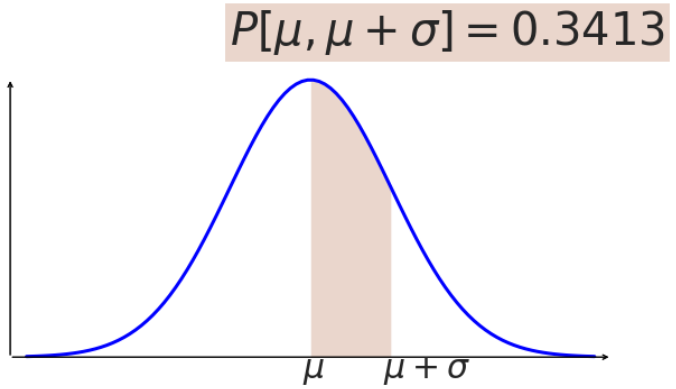

ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)

HOCHSCHULE HEILBRONN

Empirische Regel: Abschätzung der Normalverteilung

Analog:

1.00	0.3413

2.00	0.4772

3.00	0.4987

$P[\mu, \mu + \sigma] = 0.3413$

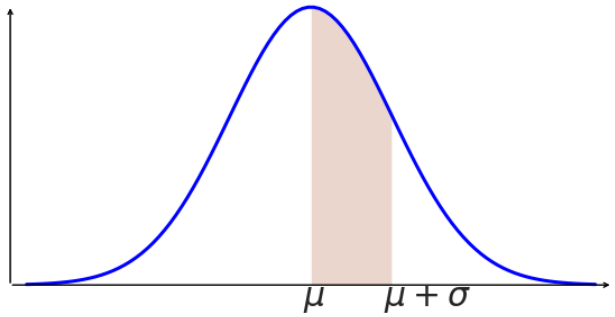

$P[\mu, \mu + 2\sigma] = 0.4772$

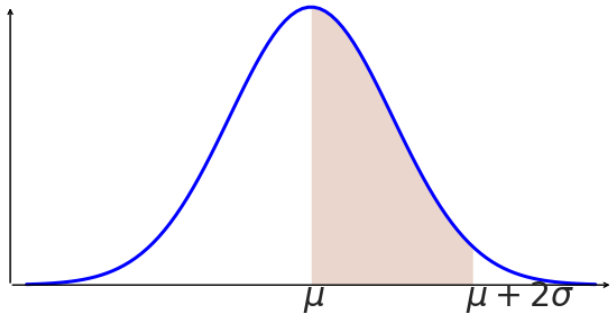

$P[\mu, \mu + 3\sigma] = 0.4987$

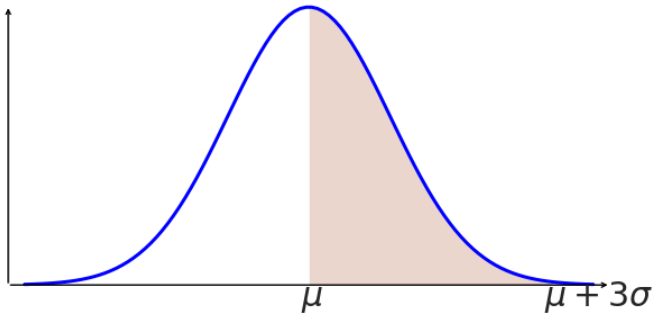

ABSCHÄTZUNG STETIGER VERTEILUNGEN: EMPIRISCHE REGEL (NORMALVERTEILUNG)

HOCHSCHULE HEILBRONN

$P[\mu, \mu + \sigma] = 0.3413$

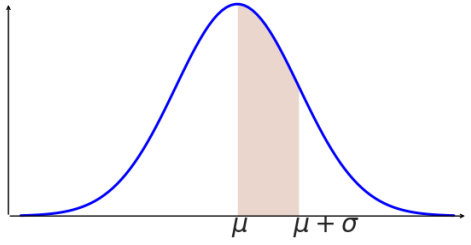

$P[\mu, \mu + 2\sigma] = 0.4772$

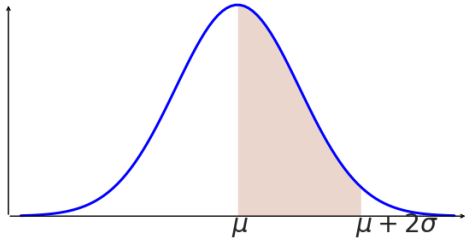

$P[\mu, \mu + 3\sigma] = 0.4987$

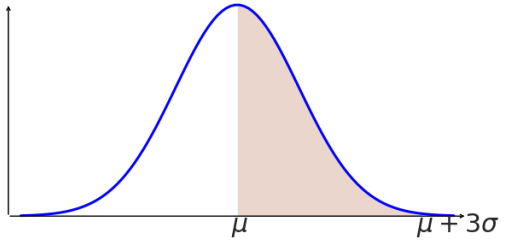

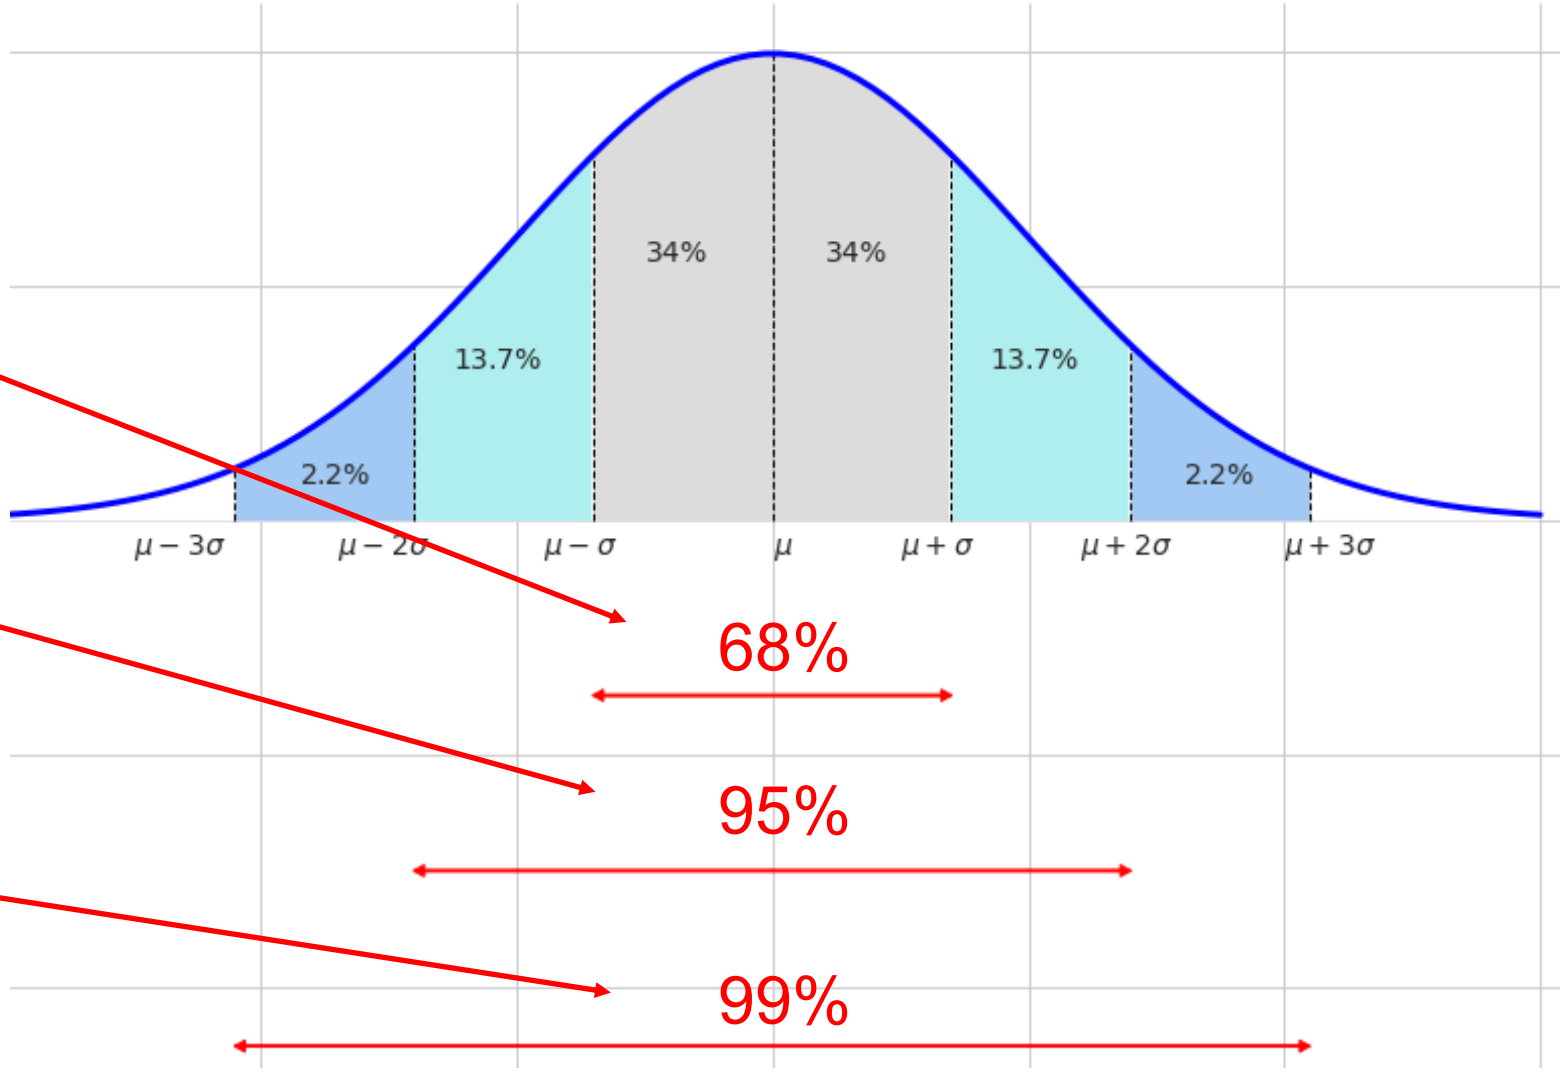

THE END!

Please refer any questions to:
Prof. Dr. Florian Kauffeldt
Faculty of International Business
florian.kauffeldt@hs-heilbronn.de

HOCHSCHULE HEILBRONN

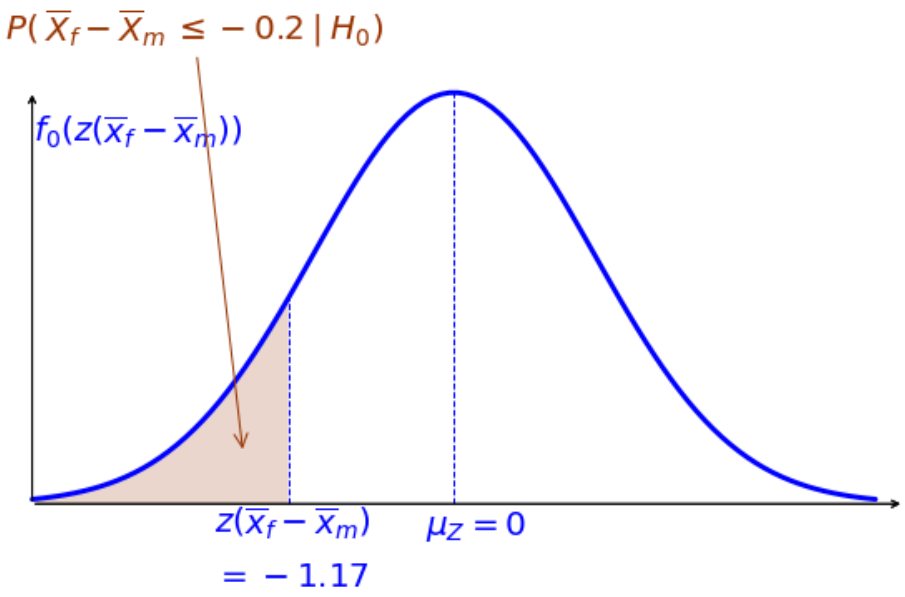

› INFERENZSTATISTIK

TEILGEBIETE DER STATISTIK

HOCHSCHULE HEILBRONN

Statistik

Deskriptive Statistik	Inferenzstatistik
> Beschreibung von Daten	> Induktive Rückschlüsse basierend auf Daten

WAS IST INFERENZSTATISTIK?

HOCHSCHULE HEILBRONN

> Inferenzstatistik: Rückschlüsse von Stichproben auf die Population

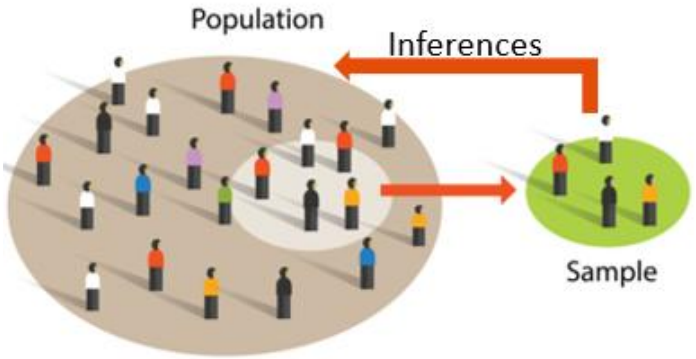

Beispiel. In einer Stichprobe verdienen Frauen im Schnitt 211 € mehr als Männer.

> Können wir daraus schließen, dass Frauen im Allgemeinen mehr verdienen?

Solche und ähnliche Fragen werden mit inferenzstatistischen Methoden beantwortet.

INFERENZSTATISTIK
INHALT

HOCHSCHULE HEILBRONN

1. Statistische Schätzer

- Punktschätzer und Schätzwertverteilung
- Zentraler Grenzwertsatz
- Intervallschätzer

2. Hypothesentests

- Komponenten
- Parametrische Tests (Ein- und Zweistichproben Z-Test, Korrelationstest)
- Nicht-Parametrische Tests (Mann-Whitney U, Spearman Rho, Chi2)

› STATISTISCHE SCHÄTZER

WAS IST EIN SCHÄTZER?

HOCHSCHULE HEILBRONN

Täglich werden Entscheidungen basierend auf Daten getroffen:

> Die Regierung möchte Güterströme von Auslandsmärkten vorhersagen

> Aktienhändler möchten Aktienentwicklungen vorhersagen

> Konsumenten möchten eine Einschätzung über Güter erlangen

I.d.R. sind die Verteilungsparameter (Mittelwert, Standardabweichung,…) unbekannt

$Schätzer$ = Regel zur Schätzung eines Parameters basierend auf einer Stichprobe

ARTEN VON SCHÄTZERN

HOCHSCHULE HEILBRONN

Schätzer

Punktschätzer	Intervallschätzer (Konfidenzintervall)
> Einzige Zahl als Schätzung Beispiel. Durchschnittsgröße = 176 cm	> Intervall: Obere und untere Schätzgrenze Beispiel. Durchschnittsgröße liegt zwischen 175 cm und 180 cm

ARTEN VON SCHÄTZERN

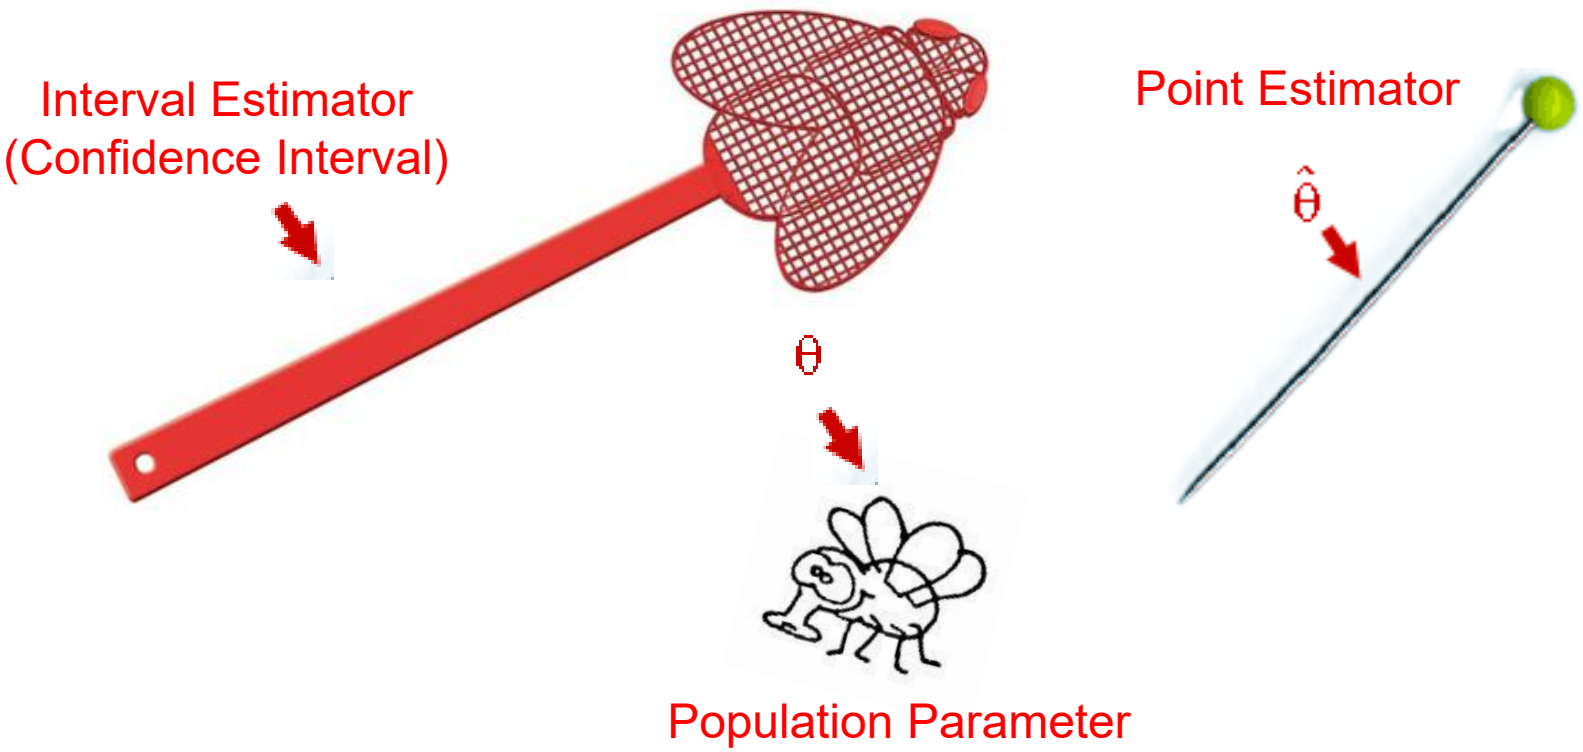

SCHÄTZER: NOTATION

HOCHSCHULE HEILBRONN

Notation. Schätzwerte werden mit überdachten griechischen Buchstaben $\widehat{\ }$ bezeichnet.

Beispiel. $\hat{\mu}$ ist der Schätzwert für den Erwartungswert μ.

PUNKTSCHÄTZER: MITTELWERT

HOCHSCHULE HEILBRONN

Beispiel. Betrachten Sie folgende Population:

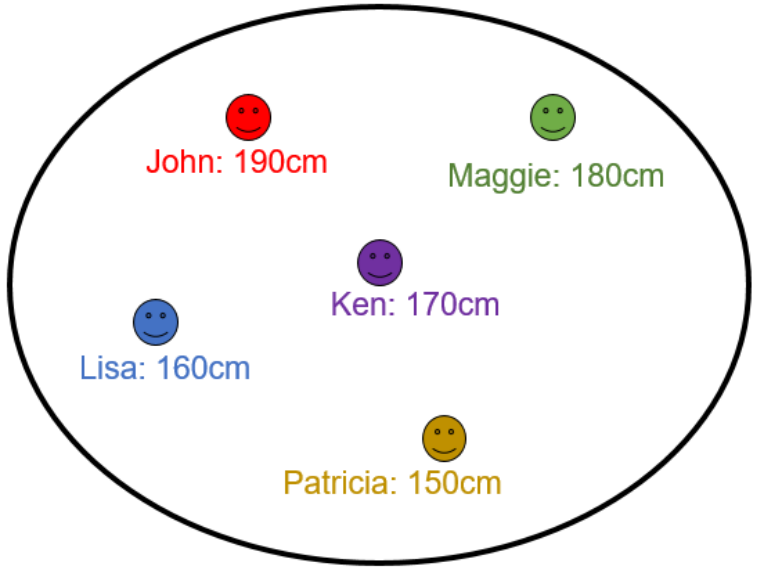

> Der Populationsmittelwert ist:

$$\boldsymbol{\mu} = \frac{150 + 160 + 170 + 180 + 190}{5} = \mathbf{170}$$

PUNKTSCHÄTZER: MITTELWERT

HOCHSCHULE HEILBRONN

Beispiel (Fortsetzung). Der Mittelwert $\mu = 170$ sei **unbekannt.**

> Schätzer Populationsmittelwert (μ) = Stichprobenmittelwert ($\bar{x}$)

> Ziehe eine Stichprobe, z.B. Größe $n = 3$

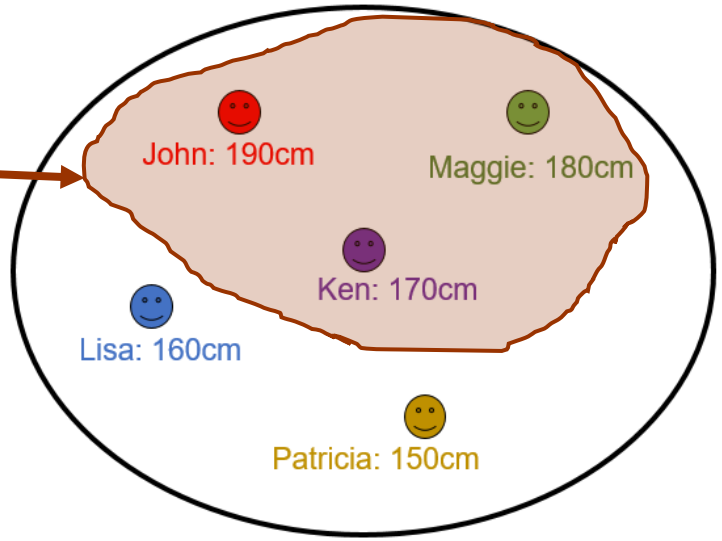

> Dann Schätzwert Populationsmittelwert:

$$\hat{\mu} = \bar{x} = \frac{170 + 180 + 190}{3} = 180$$

VERTEILUNG DER SCHÄTZWERTE

HOCHSCHULE HEILBRONN

- Unsere Stichprobe überschätzt den wahren Mittelwert

- Andere Stichproben unterschätzen den wahren Mittelwert

- Können wir etwas über den möglichen Schätzfehler sagen?

Ja → Wir müssen die Verteilung der Schätzwerte untersuchen

VERTEILUNG DER SCHÄTZWERTE: ANZAHL STICHPROBEN

HOCHSCHULE HEILBRONN

Beispiel.

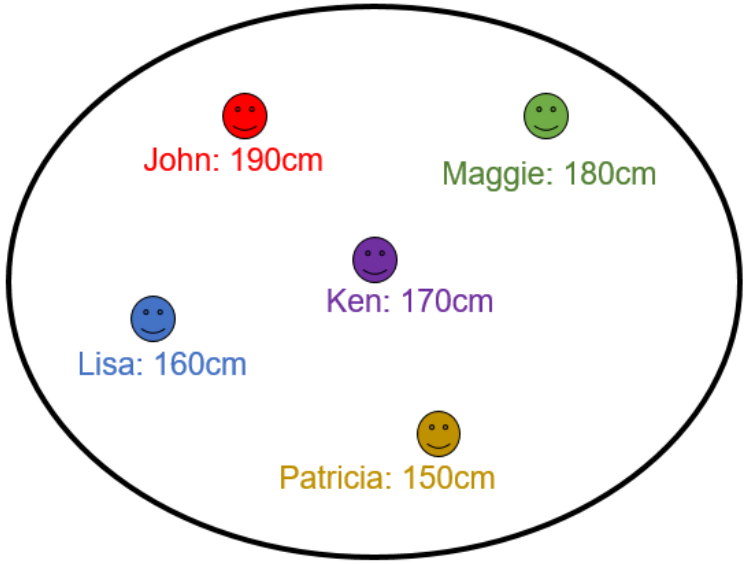

> Wie viele unterschiedliche Stichproben mit $n = 3$ können wir ziehen?

$$\binom{Populationsgröße}{Stichprobengröße} = \binom{5}{3} = \frac{5!}{3!\,2!} = \frac{5 \cdot 4}{2} = 10$$

VERTEILUNG DER SCHÄTZWERTE: WAHRSCHEINLICHKEIT EINER STICHPROBE

HOCHSCHULE HEILBRONN

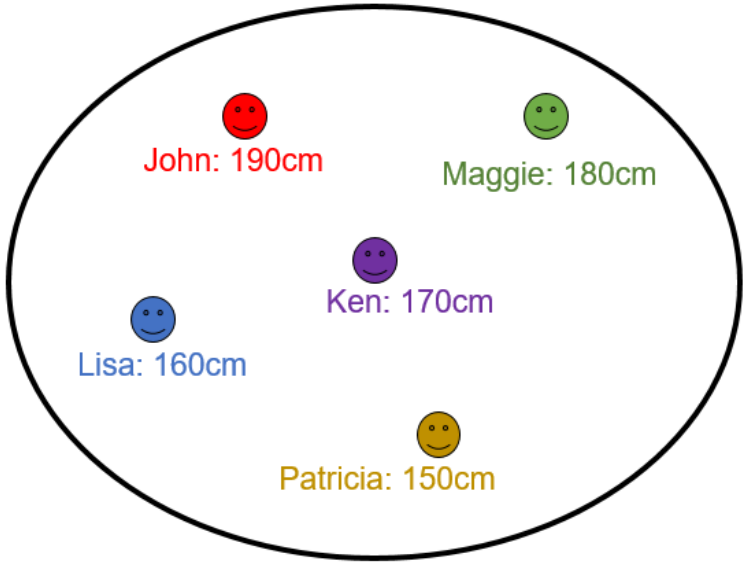

	Verteilung Stichproben	
i	Stichprobe i	$P(i)$
1	150, 160, 170	10%
2	150, 160, 180	10%
3	150, 160, 190	10%
4	150, 170, 180	10%
5	150, 170, 190	10%
6	150, 180, 190	10%
7	160, 170, 180	10%
8	160, 170, 190	10%
9	160, 180, 190	10%
10	170, 180, 190	10%

Zufallsstichprobe = Jedes Element der Population wird mit gleicher W'keit ausgewählt

VERTEILUNG DER SCHÄTZWERTE: SCHÄTZER MITTELWERT

HOCHSCHULE HEILBRONN

Stichprobenmittelwert = Schätzer Populationsmittelwert

	Verteilung Stichproben		
i	Stichprobe i	$P(i)$	Mittelw. $\bar{x}_i$
1	150, 160, 170	10%	160
2	150, 160, 180	10%	163.34
3	150, 160, 190	10%	166.67
4	150, 170, 180	10%	166.67
5	150, 170, 190	10%	170
6	150, 180, 190	10%	173.34
7	160, 170, 180	10%	170
8	160, 170, 190	10%	173.34
9	160, 180, 190	10%	176.67
10	170, 180, 190	10%	180

Verteilung Stichprobenmittelwerte	
$\bar{x}$	$P(\bar{x})$
160	10%
163.34	10%
166.67	20%
170	20%
173.34	20%
176.67	10%
180	10%

7 unterschiedliche Stichprobenmittelwerte

VERTEILUNG DER SCHÄTZWERTE: SCHÄTZER MITTELWERT

HOCHSCHULE HEILBRONN

Verteilung Stichprobenmittelwerte	
$\bar{x}$	$P(\bar{x})$
160	10%
163.34	10%
166.67	20%
170	20%
173.34	20%
176.67	10%
180	10%

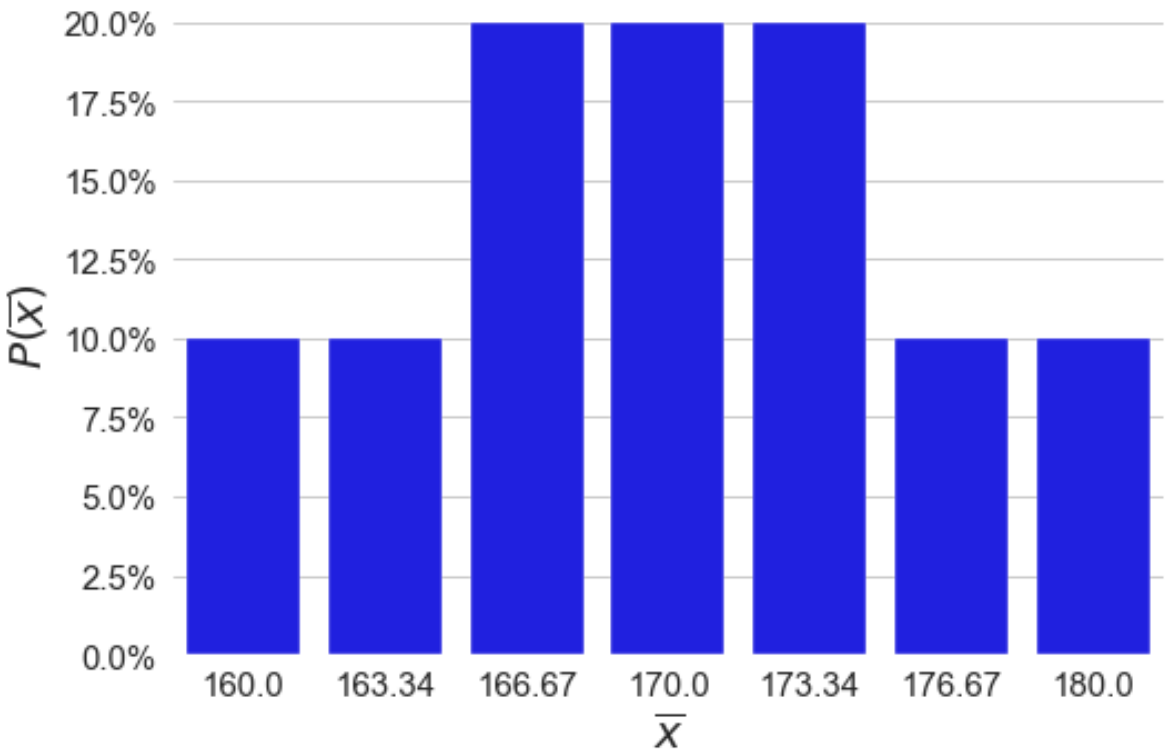

VERTEILUNG DER SCHÄTZWERTE: SCHÄTZER MITTELWERT

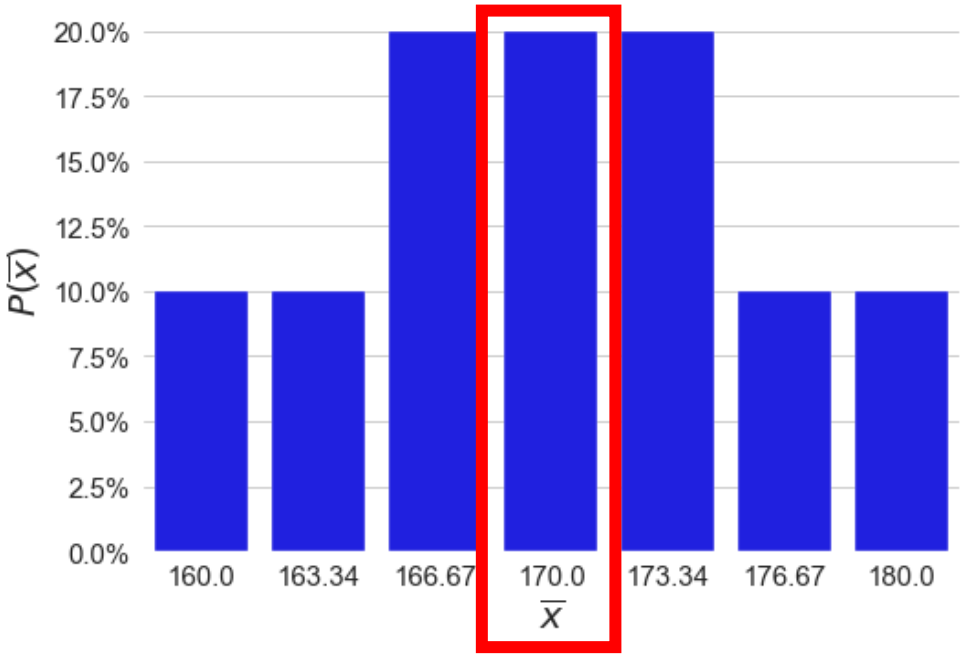

20% Wahrscheinlichkeit dass $Schätzwert\ \bar{x} = Populationsmittelwert\ \mu = 170$

VERTEILUNG DER SCHÄTZWERTE: SCHÄTZER MITTELWERT

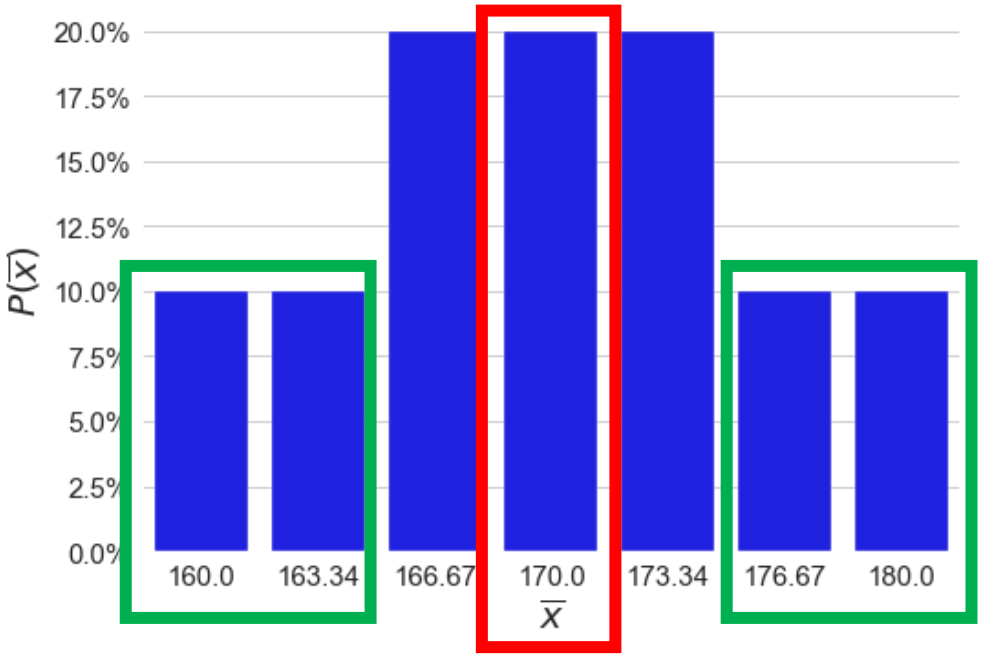

> Wahrscheinlichkeit, dass der Schätzfehler mindestens 5cm ist?

40%

VERTEILUNG DER SCHÄTZWERTE: MITTELWERT UND STANDARDABWEICHUNG

HOCHSCHULE HEILBRONN

Verteilung der Stichprobenmittelwerte:

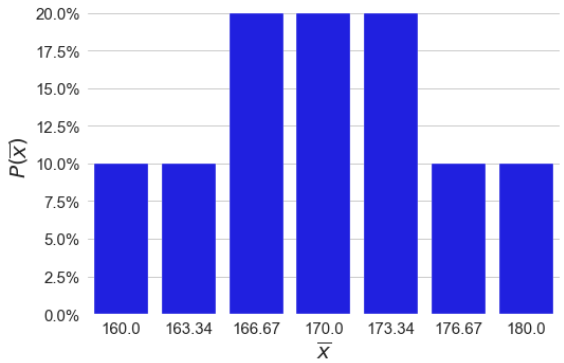

> Mittelwert:

$$\mu_{\bar{X}} = \text{Populationsmittelwert } \mu$$

> Standardabweichung = Standardfehler:

$$se_{\bar{X}} = \frac{Populationsstandardabweichung}{\sqrt{Stichprobengröße}} = \frac{\sigma}{\sqrt{n}}$$

Je höher der Standardfehler, desto wahrscheinlicher ist ein großer Schätzfehler

PUNKTSCHÄTZER UND STANDARDFEHLER IHRER VERTEILUNG

HOCHSCHULE HEILBRONN

Parameter	Punktschätzer	Standardfehler
Mittelwert μ	Stichprobenmittelwert $\bar{x}$	$se_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$
Differenz Mittelwerte $\mu_X - \mu_Y$	Differenz Stichprobenmittelwerte $\bar{x} - \bar{y}$	$se_{\bar{X}-\bar{Y}} = \sqrt{se_{\bar{X}}^2 + se_{\bar{Y}}^2}$
Varianz σ	Bessel-korrigierte Stichprobenvarianz: $\hat{\sigma}^2 = Stichprobenvarianz \cdot \frac{n}{n-1}$	$se_{\hat{\sigma}^2} = \sqrt{\frac{2}{n-1}} \times \hat{\sigma}^2$

ZENTRALER GRENZWERTSATZ

HOCHSCHULE HEILBRONN

Beispiel 1:

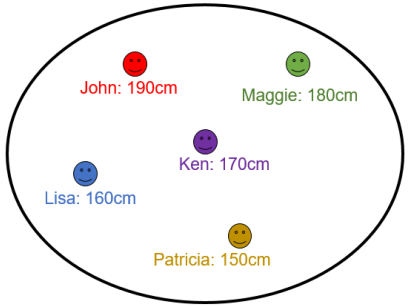

Population:
Gleichverteilung

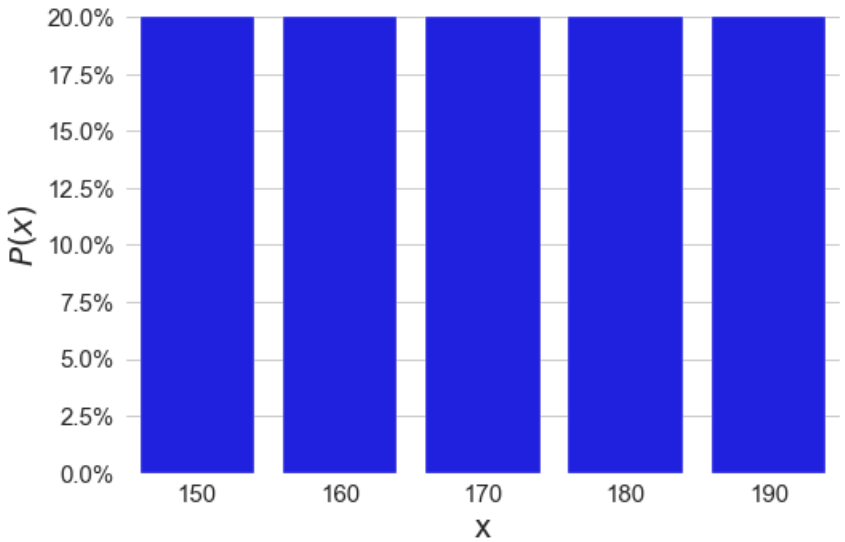

Stichproben
$(n = 3)$

Verteilung Stichprobenmittelwerte:
Keine Gleichverteilung

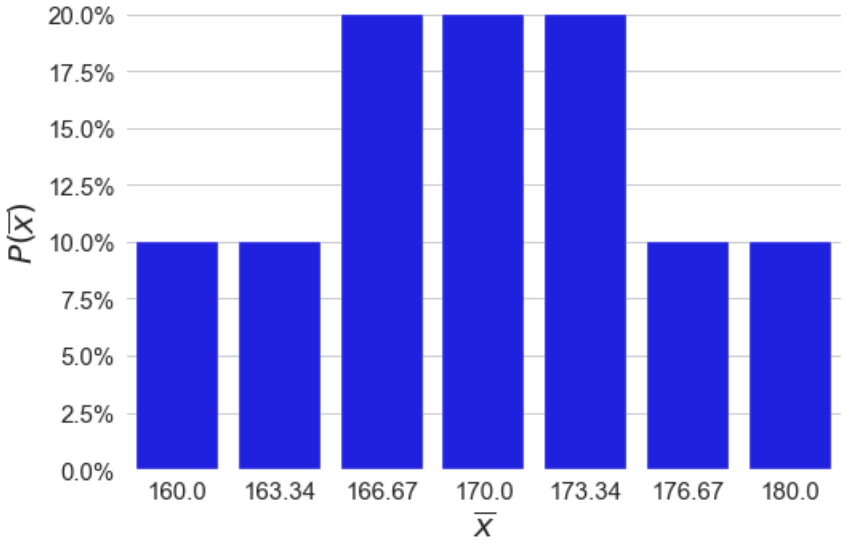

ZENTRALER GRENZWERTSATZ

HOCHSCHULE HEILBRONN

Beispiel 2. Zweimaliger Würfelwurf: Stichprobenmittelwert = Durchschnitt der Augenzahlen.

Population:
Gleichverteilung

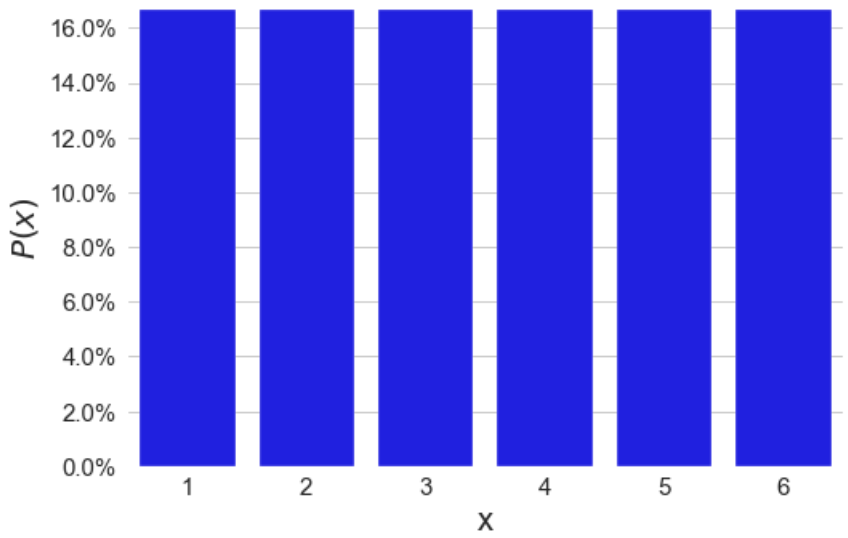

100'000
Stichproben

Verteilung Stichprobenmittelwerte:
Keine Gleichverteilung

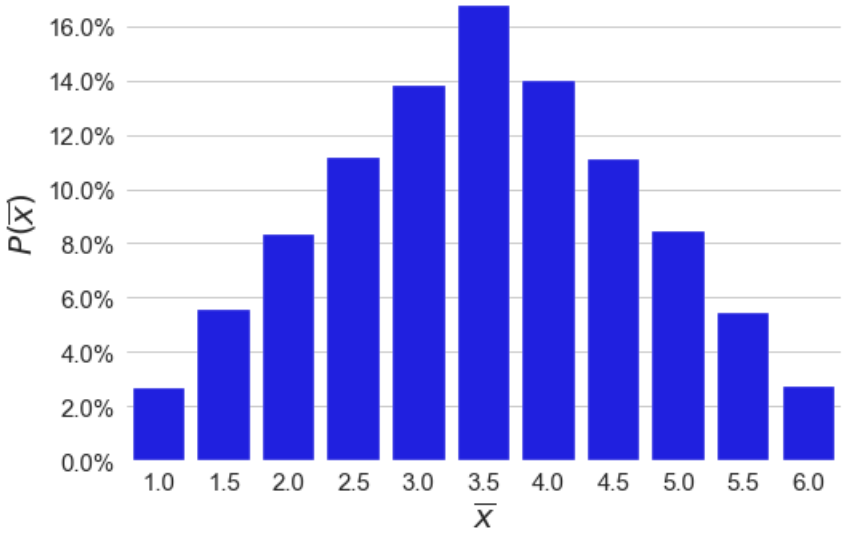

ZENTRALER GRENZWERTSATZ

HOCHSCHULE HEILBRONN

Zentraler Grenzwertsatz

Summe und Mittelwert von n unabhängig und identisch verteilten Zufallsvariablen sind approximativ normalverteilt, wenn n hinreichend groß ist.

Implikationen:

> Normalverteilung Population → Stichprobenverteilung normal (n egal)

> Keine Normalverteilung Population → Stichprobenverteilung normal (wenn n groß)

Daumenregel: Die Stichprobenverteilung ist annähernd normalverteilt, wenn

$$Stichprobengröße \geq 30$$

ZENTRALER GRENZWERTSATZ

Illustration. Populationen: Bernoulli-verteilt mit $\pi = 50\%$ und $\pi = 75\%$

> Relative Häufigkeitsverteilung des Stichprobenmittels bei 100'000 Stichproben:

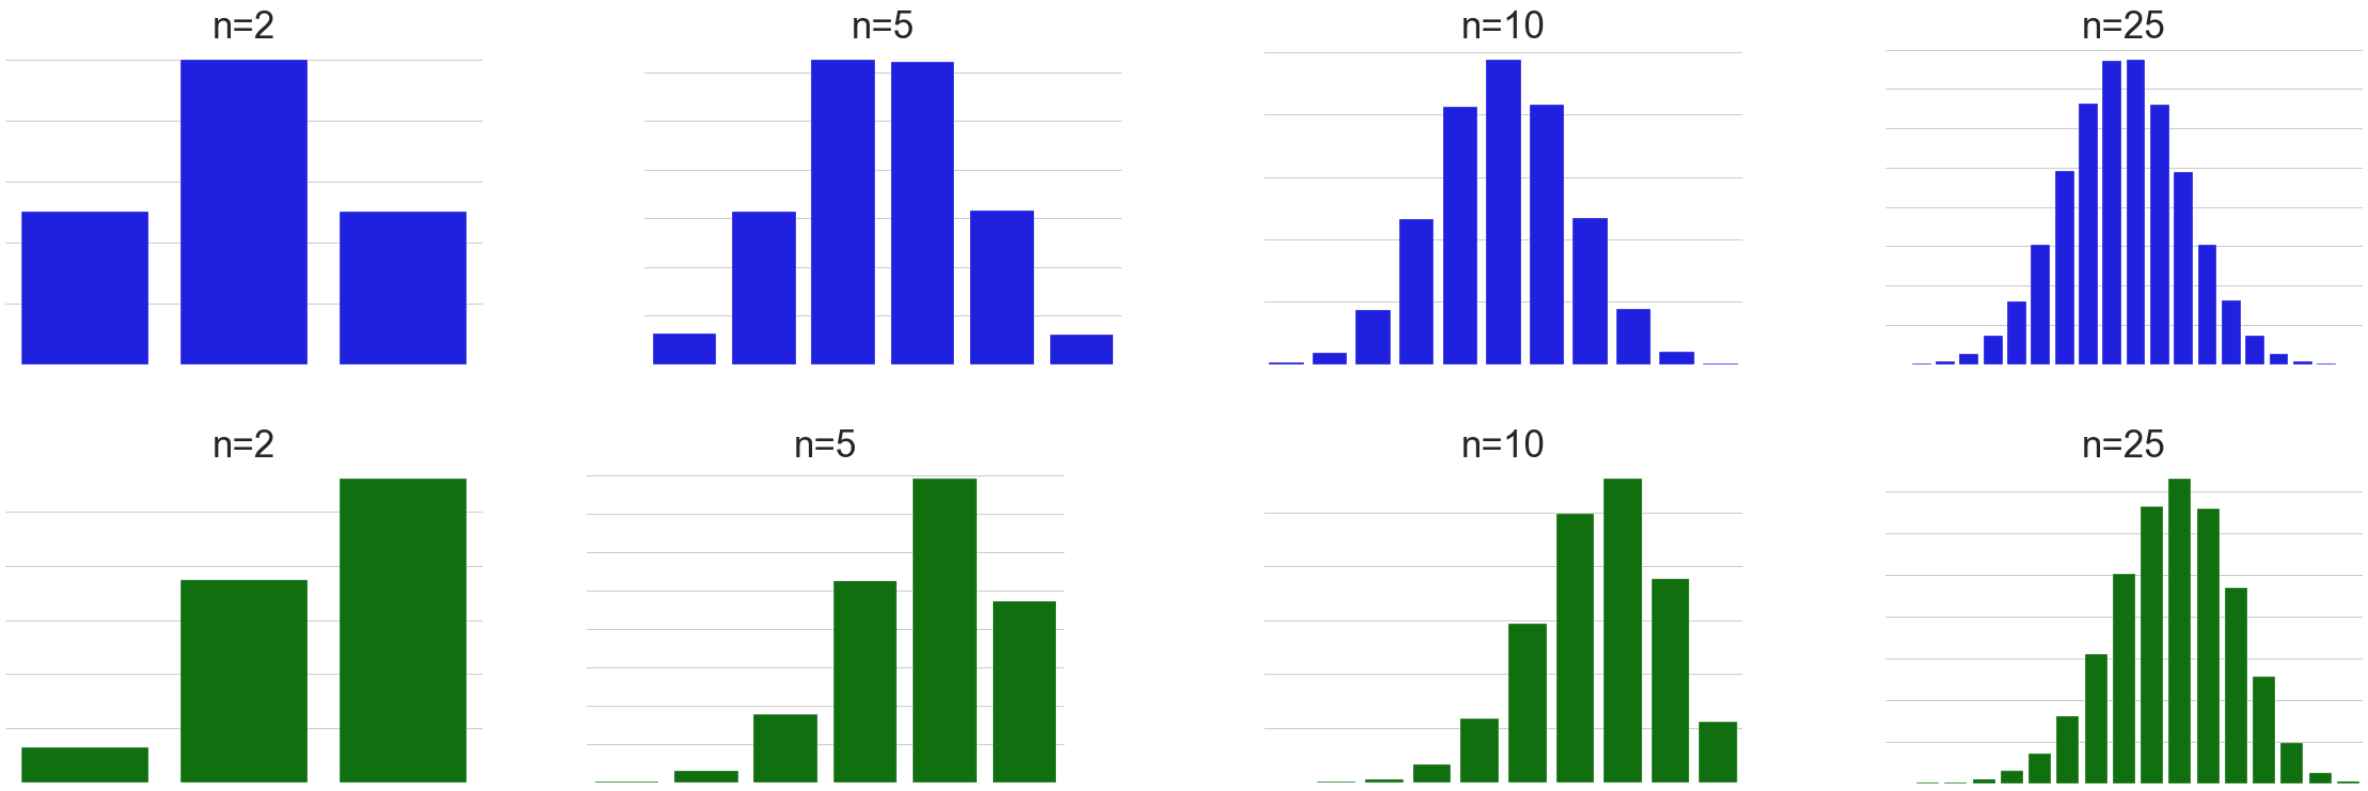

ZENTRALER GRENZWERTSATZ: SCHÄTZFEHLER

$$Schätzfehler = Schätzwert - Wahrer\ Parameter$$

> Mittelwert:

$$Schätzfehler = Schätzer - \mu = \text{Stichprobenmittelwert } (\bar{x}) - \mu$$

> Welche der folgenden Verteilungen ergibt im Schnitt den kleinsten Schätzfehler?

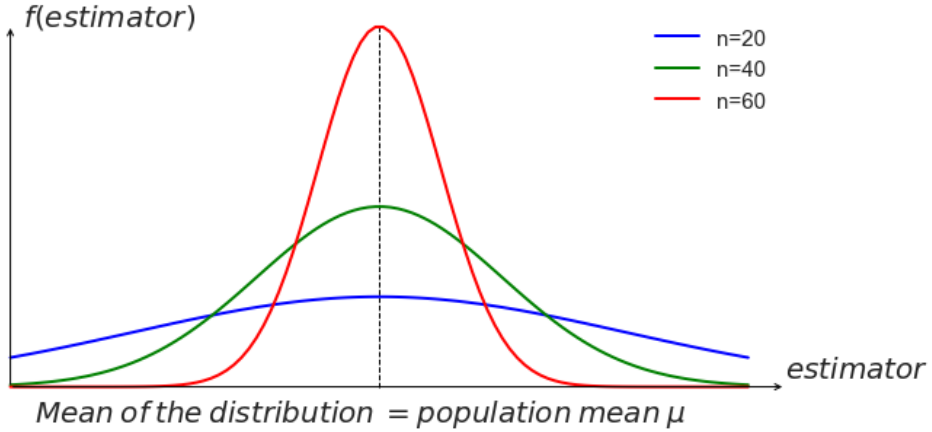

ZENTRALER GRENZWERTSATZ: SCHÄTZFEHLER

HOCHSCHULE HEILBRONN

Beispiel. Körpergröße ist verteilt mit Mittelwert 167cm (Standardabweichung = 10cm).

> Stichprobe mit n = 36 Personen

> Wahrscheinlichkeit, dass der Mittelwert um mindestens 3cm überschätzt wird?

ZENTRALER GRENZWERTSATZ: SCHÄTZFEHLER

HOCHSCHULE HEILBRONN

Beispiel. Monatliches Einkommen von Männern (M) und Frauen (W).

- Mittelwerte: $\mu_M = 3'201€$ und $\mu_W = 3'001€$
- Standardabweichungen: $\sigma_M = 420€$ und $\sigma_W = 305€$
- Stichprobe mit 36 Frauen und 49 Männer
- Wahrscheinlichkeit, dass Durchschnittseinkommen Frauen $\geq$ Männer?

INTERVALLSCHÄTZER: MARGIN OF ERROR (MOE)

HOCHSCHULE HEILBRONN

> Schätzfehler Mittelwert = Stichprobenmittelwert – Populationsmittelwert (unbekannt)

> Z-Wert:

Zufallsvariable des Schätzfehlers

$$Z(\bar{X}) = \frac{\bar{X} - \mu}{Standardfehler\ (se)}$$

> Also:

$$Schätzfehler\ (moe) = Z \cdot se$$

> Standardfehler ist bekannt, Z muss festgelegt werden

INTERVALLSCHÄTZER: KONFIDENZNIVEAU z FESTLEGEN

HOCHSCHULE HEILBRONN

> Wir können ein Konfidenzniveau $(1-\alpha)$ festlegen

> $(1-\alpha)$ = 95% bedeutet z.B., dass der Schätzfehler zu 95% in dem Bereich liegt

> Wir lassen eine Fehlerwahrscheinlichkeit von $\alpha/2 = 2.5\%$ auf jeder Seite zu:

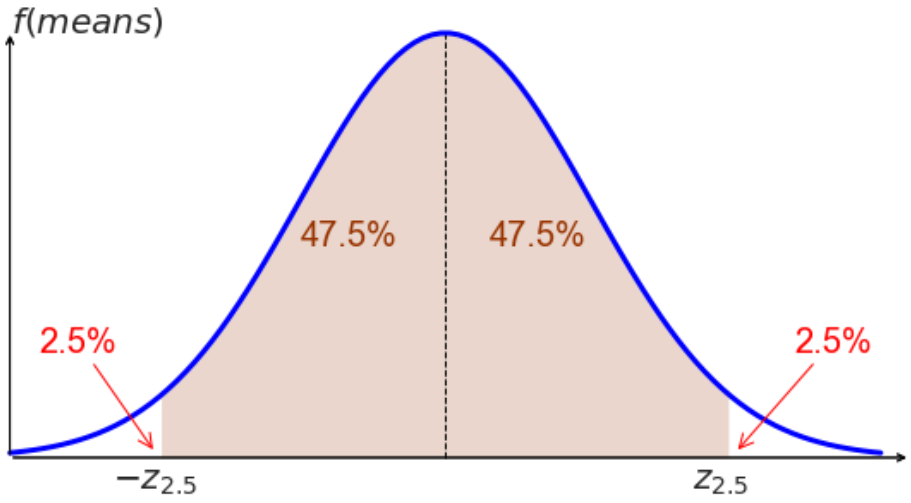

BEREICH $z_{-\alpha/2}$ BIS $z_{\alpha/2}$

Beispiel. $\alpha = 5\% \rightarrow z_{2.5}$?

> Nun: Z-Wert für Fläche finden!

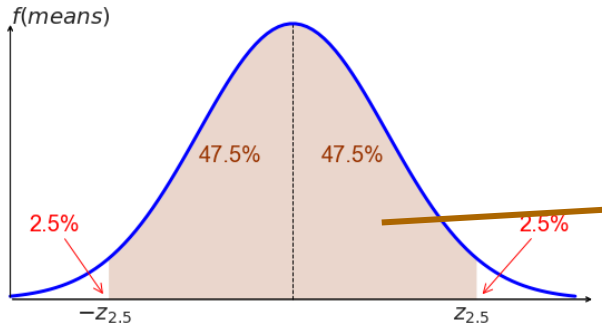

Z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.10	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.20	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.30	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.40	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.50	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.60	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.70	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.80	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.90	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.00	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.10	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.20	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.30	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.40	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.50	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.60	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.70	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.80	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.90	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767
2.00	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.10	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.20	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.30	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.40	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936
2.50	0.4938	0.4940	0.4941	0.4943	0.4945	0.4946	0.4948	0.4949	0.4951	0.4952
2.60	0.4953	0.4955	0.4956	0.4957	0.4959	0.4960	0.4961	0.4962	0.4963	0.4964
2.70	0.4965	0.4966	0.4967	0.4968	0.4969	0.4970	0.4971	0.4972	0.4973	0.4974
2.80	0.4974	0.4975	0.4976	0.4977	0.4977	0.4978	0.4979	0.4979	0.4980	0.4981
2.90	0.4981	0.4982	0.4982	0.4983	0.4984	0.4984	0.4985	0.4985	0.4986	0.4986
3.00	0.4987	0.4987	0.4987	0.4988	0.4988	0.4989	0.4989	0.4989	0.4990	0.4990

> Also:

$$z_{2.5} = 1.96$$

INTERVALLSCHÄTZER: KONFIDENZINTERVALLE

HOCHSCHULE HEILBRONN

1. Fixiere ein Konfidenzniveau $(1-\alpha)$ und bestimme hierfür den Wert $z_{\alpha/2}$

2. Bestimme margin of error:

$$moe = z_{\alpha/2} \cdot Standardfehler$$

3. $(1-\alpha)$-Konfidenzintervall:

$$Punktschätzer \pm moe$$

INTERVALLSCHÄTZER: KONFIDENZINTERVALLE

HOCHSCHULE HEILBRONN

Beispiel. Zahlungsbereitschaft von Kunden für eine Übernachtung im Hotel bestimmen.

> In einer Stichprobe von n = 39 Befragten liegt die Zahlungsbereitschaft bei 86 €

> Standardabweichung = 26 €

a) Bestimmen Sie das 99%-Konfidenzintervall

Hausaufgabe.

b) Bestimmen Sie das 90%-Konfidenzintervall

Lösung: 90%-Konfidenzintervall = $[79, 93]$

INTERVALLSCHÄTZER: KONFIDENZINTERVALLE

HOCHSCHULE HEILBRONN

Beispiel. Wir möchten den durchschnittlichen IQ von Studierenden der Hochschule Heilbronn schätzen.

> In einer Stichprobe mit 47 Studierenden ist der durchschnittliche IQ 102

> Standardabweichung = 13

a) Bestimmen Sie das 90%-Konfidenzintervall

Hausaufgabe.

b) Bestimmen Sie das 95%-Konfidenzintervall

Lösung: 95%-Konfidenzintervall = $[98.28, 105.72]$

INTERVALLSCHÄTZER: DESIDERATA

HOCHSCHULE HEILBRONN

Optimales Konfidenzintervall: So **schmal wie möglich** und **Konfidenzniveau nahe 1**

- Je größer das Konfidenzniveau, desto sicherer ist wahrer Parameter enthalten
- Je enger das Konfidenzintervall, desto exakter ist die Schätzung
- Je größer die Stichprobe, desto enger ist das Intervall

Aber:

- Je höher das Konfidenzniveau, desto breiter das Intervall

INTERVALLSCHÄTZER: OPTIMALE STICHPROBENGRÖßE

HOCHSCHULE HEILBRONN

Frage wenn Daten erhoben werden → Welche Stichprobengröße?

> Frage:

Wie akkurat sollen die Schätzungen sein?

> Wir können den moe benutzen, um diese Frage zu beantworten

INTERVALLSCHÄTZER: OPTIMALE STICHPROBENGRÖßE

HOCHSCHULE HEILBRONN

Beispiel. Sie besitzen eine große Brauerei und möchten Ihre Tagesproduktion schätzen.

> Ihre durchschnittliche Tagesproduktion der letzten 30 Tage ist 871 Kubikmeter Bier

> Standardabweichung: 21

Wie viele Tage müssen Sie die Tagesproduktion beobachten, um die langfristige Tagesproduktion mit 95% zu schätzen bei einem moe von 4 Kubikmetern?

› HYPOTHESEN-TESTS

WARUM HYPOTHESENTESTS?

In einer Stichprobe mit 35 Frauen und 44 Männer ist das Durchschnittseinkommen der Frauen um 200 € niedriger als das der Männer

> Ist dies ein Beleg dafür, dass Frauen allgemein im Schnitt weniger verdienen?

Der Umsatz einer Firma war im letzten Jahr 300'000 € höher als der Durchschnitt ihres langfristigen jährlichen Umsatzes

> Ist dies ein Beleg dafür, dass sich die Nachfrage für die Produkte erhöht hat?

Derartige Fragen werden anhand von Hypothesentests beantwortet

HYPOTHESENTEST: KOMPONENTEN

HOCHSCHULE HEILBRONN

1. Einem Hypothesenpaar:
   - $Alternativhypothese\ H_1$ = die Hypothese, welche man testen möchte
   - $Nullhypothese\ H_0$ = Gegenteil Alternativhypothese
2. Einer Teststatistik
   - Zahl, die auf Basis einer Stichprobe berechnet wird
3. Einer Entscheidung
   - $Ablehnung\ Nullhypothese$ = Beleg für Alternativhypothese
   - $Keine\ Ablehnung\ Nullhypothese$ = Kein Beleg für Alternativhypothese

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

HOCHSCHULE HEILBRONN

Beispiel. Wir möchten untersuchen, ob Frauen weniger verdienen als Männer.

> Alternativhypothese: $Durchschnittseinkommen_{Frauen} < Durchschnittseinkommen_{Männer}$

Wir untersuchen nun wie wahrscheinlich das Gegenteil ist:

> Nullhypothese: $Durchschnittseinkommen_{Frauen} \geq Durchschnittseinkommen_{Männer}$

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

HOCHSCHULE HEILBRONN

Hypothesen

Alternativhypothese H_1	Nullhypothese H_0
> Hypothese, die getestet werden soll > Postuliert üblicherweise ein Resultat	> Exaktes Gegenteil der Alternativhypothese > Verneint das Resultat

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

HOCHSCHULE HEILBRONN

Beispiele.

Wir möchten wissen…	Alternativhypothese (H_1)	Nullhypothese (H_0)
ob Absolventen der HS Heilbronn im Schnitt (μ_{Alter}) älter sind als 26 (μ_0)	$\mu_{Alter} > 26$	$\mu_{Alter} \leq 26$
ob sich der Durchschnitts-IQ (μ_{IQ}) von Studierenden verändert hat (langfristiger Durchschnitt: $\mu_0 = 101$)	$\mu_{IQ} \neq 101$	$\mu_{IQ} = 101$
ob die Nachfrage (μ_{Nach}) für das Produkt einer Firma abgenommen hat (langfristiger Durchschnitt: $\mu_0 = 41'000$)	$\mu_{Nach} < 41'000$	$\mu_{Nach} \geq 41'000$

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

HOCHSCHULE HEILBRONN

Beispiel. In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen $2.9\,T€$ $(Varianz = 0.7)$ und das der Männer $3.1\,T€$ $(Varianz = 0.4)$.

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?

a) Schreiben Sie die Null- und die Alternativhypothese zu dieser Fragestellung auf.

> Alternativhypothese:

$$Durchschnittseinkommen\ Pop.Frauen\ \mu_f < Durchschnittseinkommen\ Pop.Männer\ \mu_m$$

> Nullhypothese:

$$Durchschnittseinkommen\ Pop.Frauen\ \mu_f \geq Durchschnittseinkommen\ Pop.Männer\ \mu_m$$

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

HOCHSCHULE HEILBRONN

Null- und Alternativhypothese repräsentieren **zwei unterschiedliche Welten:**

Welt 0 (Nullhypothese H_0):

Frauen verdienen nicht weniger.

> Gleiche Einkommensverteilung

Welt 1 (Alternativhypothese H_1):

Frauen verdienen weniger.

> Unterschiedliche Einkommensverteilungen.

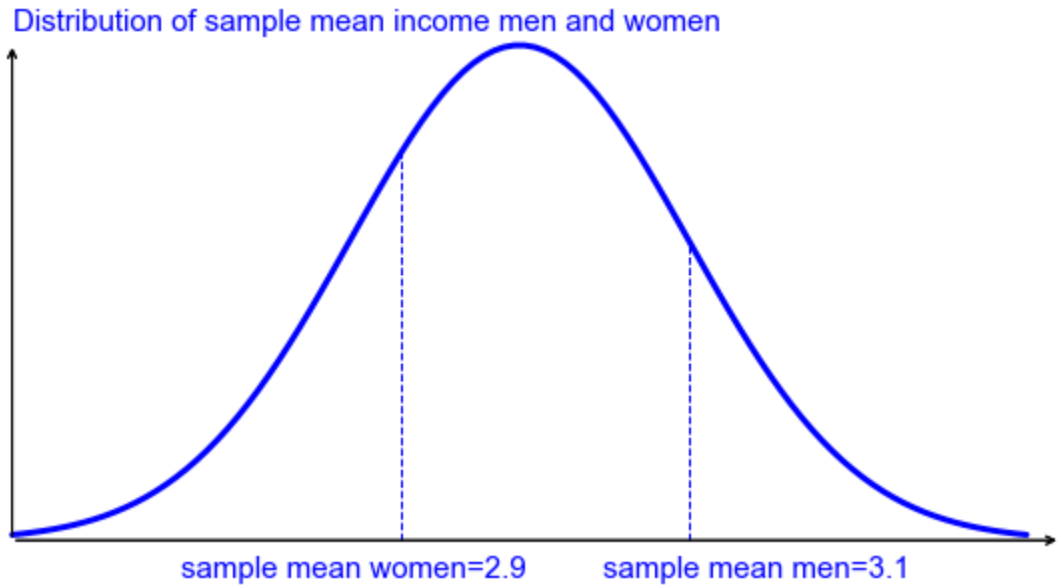

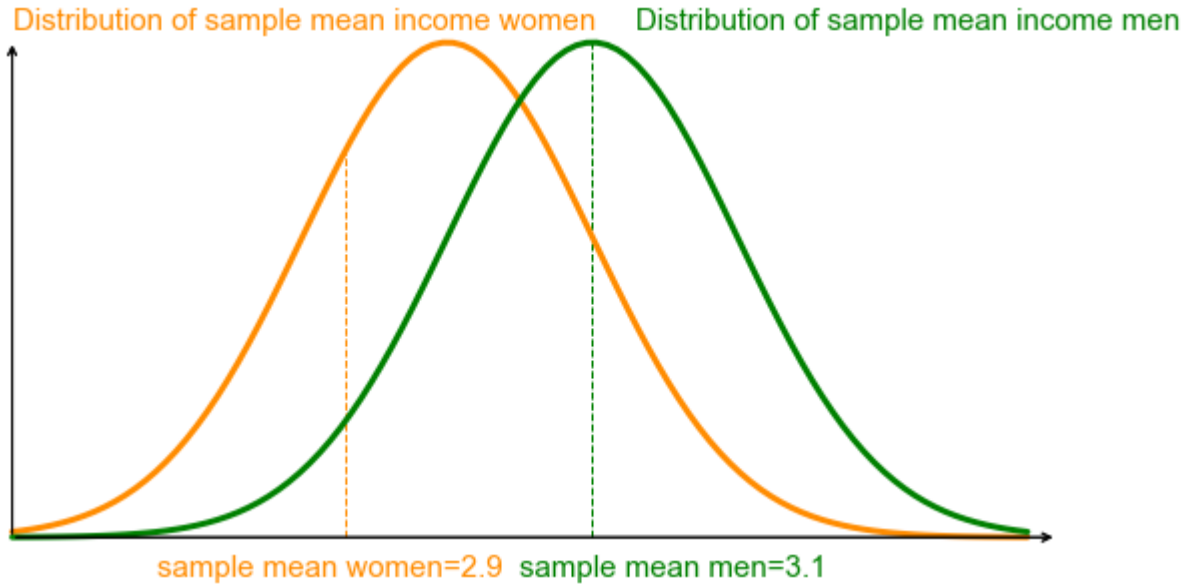

HYPOTHESENTEST: NULL- UND ALTERNATIVHYPOTHESE

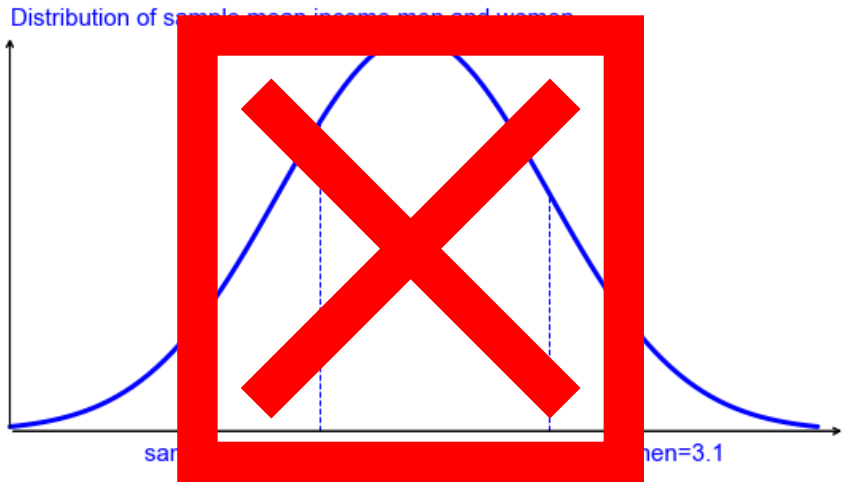

In welcher Welt leben wir?

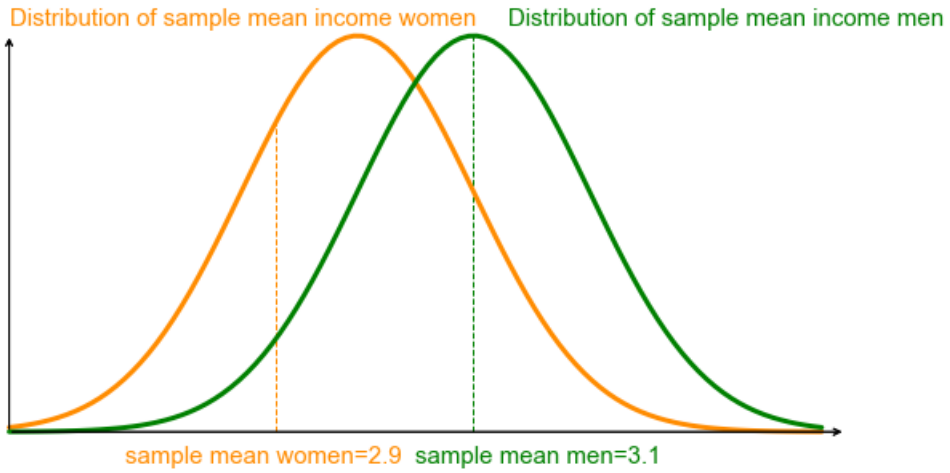

Welt 0 (Nullhypothese H_0)

Welt 1 (Alternativhypothese H_a)

> Ein Hypothesentest sagt uns, ob wir die Nullhypothese ablehnen können

> Wenn wir die Nullhypothese ablehnen können, dann ist der Test erfolgreich

HYPOTHESENTEST: TESTSTATISTIK

HOCHSCHULE HEILBRONN

Welches Kriterium bestimmt, ob wir die Nullhypothese (Welt 0) ablehnen können?

Schritt 1. Berechne Teststatistik:

$$Teststatistik = \frac{Punktschätzer\ - Populationsmittelwert\ Welt\ 0}{Standardfehler}$$

HYPOTHESENTEST: TESTSTATISTIK

Beispiel (Fortsetzung). In einer Stichprobe mit 35 Frauen und 44 Männer ist das monatliche Durchschnittseinkommen der Frauen $2.9\,T€$ $(Varianz = 0.7)$ und das der Männer $3.1\,T€$ $(Varianz = 0.4)$.

Ist dies ein Beleg dafür ist, dass Frauen im Schnitt weniger verdienen?

a) Schreiben Sie die Null- und die Alternativhypothese zu dieser Fragestellung auf.

b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.

HYPOTHESENTEST: P-WERT

HOCHSCHULE HEILBRONN

Welches Kriterium bestimmt, ob wir die Nullhypothese (Welt 0) ablehnen können?

Schritt 1. Berechne Teststatistik

Schritt 2. Berechne p-Wert

$$p - Wert = P(Teststatistik = wie\ beobachtet\ oder\ extremer \mid Nullhypothese\ wahr)$$

HYPOTHESENTEST: P-WERT EINSEITIG UND ZWEISEITIG

HOCHSCHULE HEILBRONN

> $Einseitige\ Tests$ haben eine Richtung: mehr/weniger, höher/niedriger, …

> $Zweiseitige\ Tests$ haben keine Richtung: Unterschied ja/nein

Beispiel. Überprüfen Sie, ob die folgenden Tests einseitig oder zweiseitig sind:

Wir möchten wissen…	Alternativhypothese (H_1)	Nullhypothese (H_0)
ob Absolventen der HS Heilbronn im Schnitt (μ_{Alter}) älter sind als 26 (μ_0)	$\mu_{Alter} > 26$	$\mu_{Alter} \leq 26$
ob sich der Durchschnitts-IQ (μ_{IQ}) von Studierenden verändert hat (langfristiger Durchschnitt: $\mu_0 = 101$)	$\mu_{IQ} \neq 101$	$\mu_{IQ} = 101$
ob die Nachfrage (μ_{Nach}) für das Produkt einer Firma abgenommen hat (langfristiger Durchschnitt: $\mu_0 = 41'000$)	$\mu_{Nach} < 41'000$	$\mu_{Nach} \geq 41'000$

HYPOTHESENTEST: P-WERT EINSEITIG UND ZWEISEITIG

HOCHSCHULE HEILBRONN

Sei $P_0 = P(X > Betrag(Teststatistik) \mid H_0\ wahr)$, dann

$$p - Wert\ einseitiger\ Test = P_0$$

$$p - Wert\ zweiseitiger\ Test = 2 \times P_0$$

HYPOTHESENTEST: P-WERT

HOCHSCHULE HEILBRONN

Beispiel (Fortsetzung).

b) Führen Sie einen Test durch, um zu überprüfen, ob der Unterschied signifikant ist.

Schritt 1. Teststatistik = -1.17 ✓

Schritt 2. Berechne p-Wert.

$$p - Wert = P(X > 1.17) = 0.5 - 0.379 = 12.1\%$$

HYPOTHESENTEST: ENTSCHEIDUNG

HOCHSCHULE HEILBRONN

Was sagt uns p-Wert = 12.1%?

> Wenn p-Wert ≤ konventionelle Obergrenzen → Ablehnung Nullhypothese

p-Wert ≤ Obergrenze α (*)	Interpretation
5%	Statistisch signifikant
1%	Stark statistisch signifikant

(*) Die Obergrenze α heißt *Signifikanzniveau*

> p-Wert = 12.1% > 5% → der Einkommensunterschied ist nicht statistisch signifikant

> Nullhypothese kann nicht abgelehnt werden → keine Evidenz für einen Unterschied

EINSTICHPROBEN Z-TEST

$Einstichproben\ Test$ = Vergleich Mittelwert **einer** Population mit einer Zahl

Beispiele. Fragen:

> Hat sich der durchschnittliche IQ (bisher: 101 = μ_0) von Studierenden verändert?

> Verbringen Studierende mehr als 4h / Tag (= μ_0) in sozialen Netzwerken?

EINSTICHPROBEN Z-TEST: BEISPIEL 1

HOCHSCHULE HEILBRONN

Das Einstiegsgehalt von Absolventen der Hochschule Heilbronn betrug im langfristigen Durchschnitt ca. 31 T€/Jahr (Standardabweichung: 21 T€). Das durchschnittliche Einstiegsgehalt in einer Stichprobe mit 44 Absolventen ist 26 T€/Jahr.

Ist das ein Beleg, dass sich das Einstiegsgehalt signifikant verschlechtert hat?

a) Handelt es sich um einen einseitigen oder zweiseitigen Test?

b) Schreiben Sie die Null- und Alternativhypothese auf.

c) Führen Sie einen Test durch, um die Frage zu beantworten.

d) Berechnen und interpretieren Sie die Effektstärke.

EINSTICHPROBEN Z-TEST: BEISPIEL 2

HOCHSCHULE HEILBRONN

Bei einem Online-Anbieter waren 54 der letzten 87 Kunden unter 30.

Ist dies Evidenz, dass der Anteil der unter 30-Jährigen Käufern von 50% abweicht?

a) Handelt es sich um einen einseitigen oder zweiseitigen Test?

b) Schreiben Sie die Null- und Alternativhypothese auf.

c) Führen Sie einen Test durch, um die Frage zu beantworten.

d) Berechnen und interpretieren Sie die Effektstärke.

ZWEISTICHPROBEN Z-TEST

$Zweistichproben\ Test$ = Vergleich Mittelwerte **zweier** Populationen

Beispiele. Fragen:

> Gibt es einen Unterschied im Einkommen von Frauen und Männern?

> Sind Nutzer von sozialen Netzwerken glücklicher?

ZWEISTICHPROBEN Z-TEST BEISPIEL 1

In einer Stichprobe mit 32 Mitarbeitern der Firma A und 35 Mitarbeitern der Firma B werden folgende Durchschnittsjahresgehälter gemessen: Firma A: 43 T€ (Varianz: 450.11), Firma B: 29.8 T€ (Varianz: 294.05).

Unterscheiden sich die Durchschnittsgehälter von Firma A und B (1%-Niveau)?

a) Handelt es sich um einen einseitigen oder zweiseitigen Test?

b) Schreiben Sie die Null- und Alternativhypothese auf.

c) Führen Sie einen Test durch, um die Frage zu beantworten.

d) Berechnen und interpretieren Sie die Effektstärke.

ZWEISTICHPROBEN Z-TEST BEISPIEL 2

In einer Stichprobe sind 63 von 90 Frauen und 27 von 52 Männer umweltbewusst. Die Stichprobenvarianz entspricht jeweils ungefähr der Populationsvarianz.

Ist der Anteil der umweltbewussten Frauen höher als der der Männer?

a) Handelt es sich um einen einseitigen oder zweiseitigen Test?

b) Schreiben Sie die Null- und Alternativhypothese auf.

c) Führen Sie einen Test durch, um die Frage zu beantworten.

THE END!

Please refer any questions to:
Prof. Dr. Florian Kauffeldt
Faculty of International Business
Florian.kauffeldt@hs-heilbronn.de